



RECONOCIMIENTO DE PATRONES EN IMÁGENES TICS 585

FACULTAD DE INGENIERÍA Y CIENCIAS
UNIVERSIDAD ADOLFO IBÁÑEZ

SEGUNDO SEMESTRE 2021

PROFESOR: MIGUEL CARRASCO

INTRODUCCIÓN

- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
- Visión general

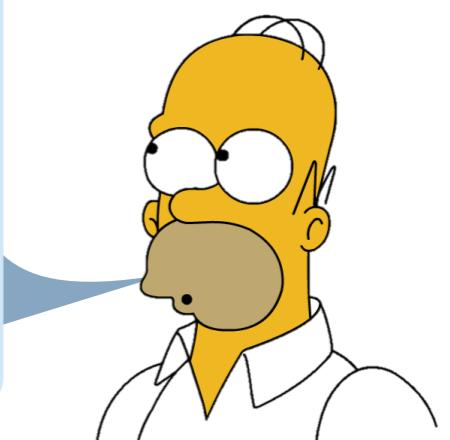
■ Formalidades

- Cátedra: Jueves desde **11:30** hasta **14:10** (módulo 3-4)
- Evaluación obligatoria: 1 Proyecto, Tareas, Examen (**cuando NP<5.0**)
- Consultas: email o reunión por zoom

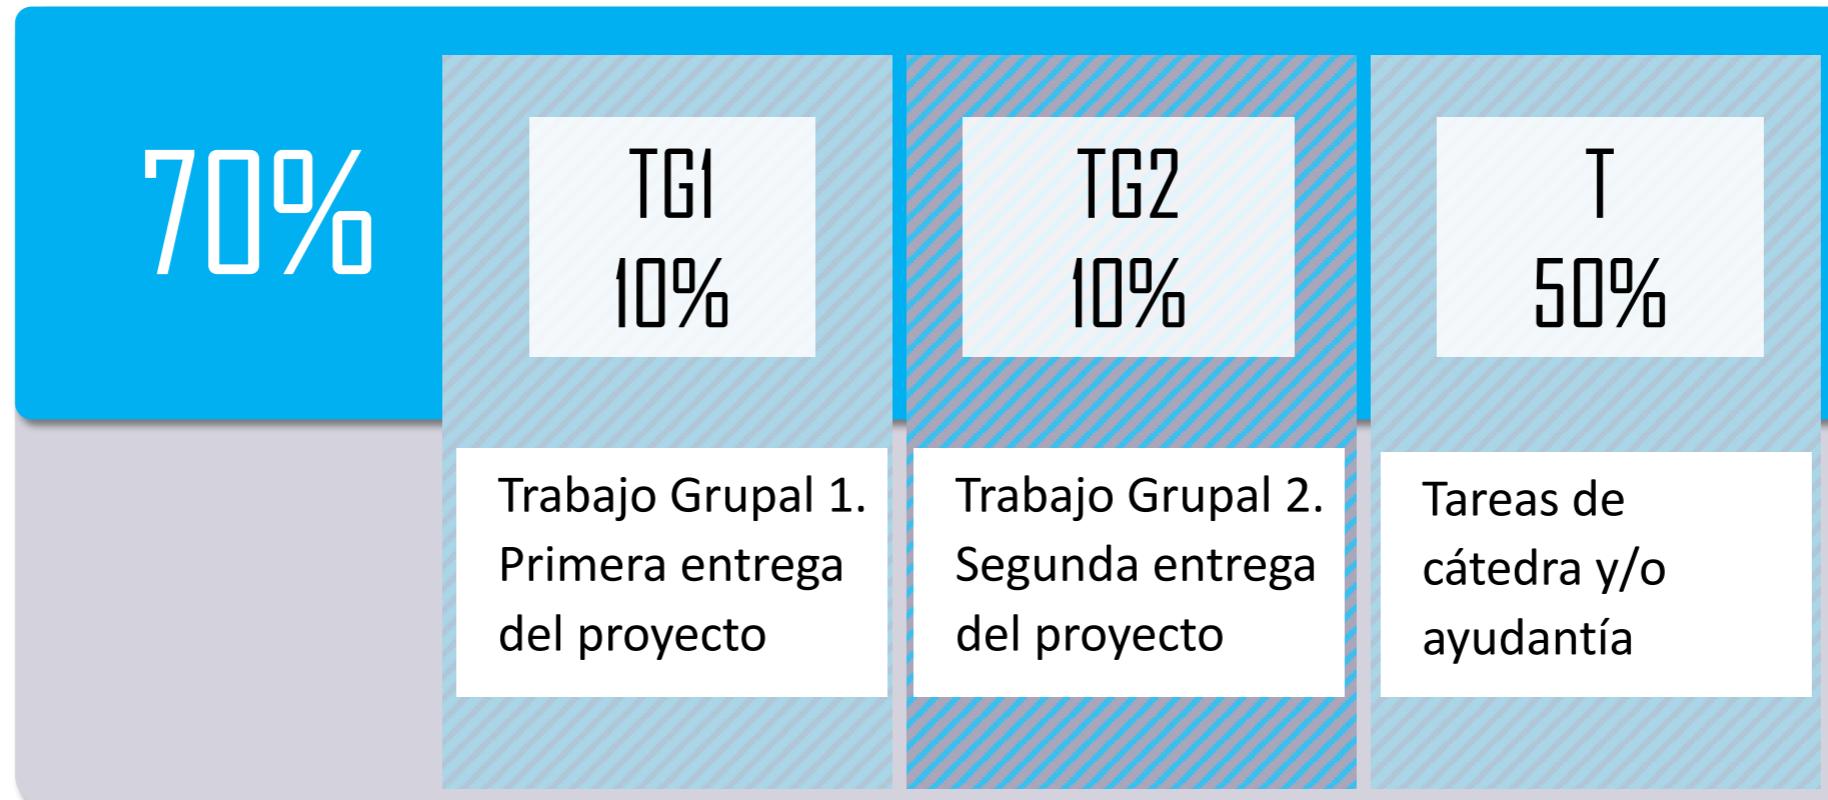
miguel.carrasco@uai.cl

MUY IMPORTANTE

- La clase comienza a las 11:30. No ingrese más tarde de 15 minutos atrasado
- Asistencia a clases no es obligatoria
- Cualquier copia sera evaluadada con nota 1 y notificada a la dirección académica. Esto es muy importante!



NF. Nota Presentación



NF. Nota Presentación

$$NF = TG1 \times 0.10 + TG2 \times 0.10 + T \times 0.5$$

NF. Nota Final

Si $NF > 5.0$

$$NF = NP$$

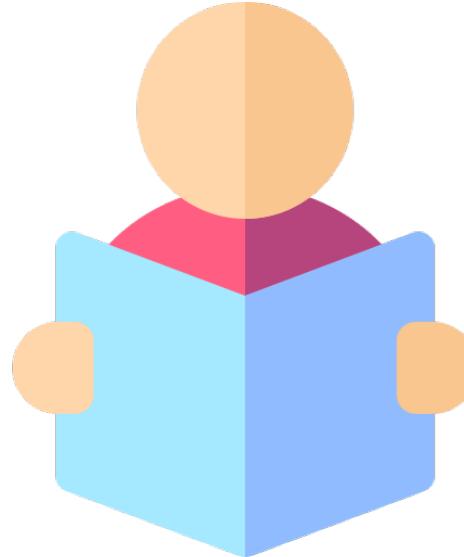
Sino

$$NF = EX \times 0.30 + NF \times 0.7$$



- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
- Visión general

Objetivos del curso



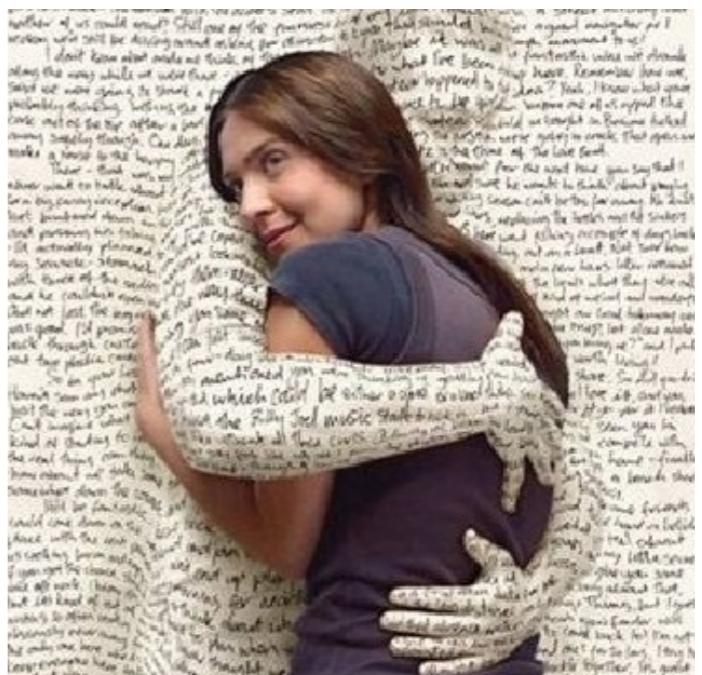
- Estudiar y aplicar distintas técnicas y algoritmos de reconocimiento, clasificación y agrupamiento de datos empleando como entrada imágenes digitales.
- Los algoritmos vistos en el curso pueden ser empleados en otros tópicos, como la biometría, el reconocimiento de la voz, análisis de correo no deseado, etc.
- Este curso es de tipo teórico práctico, poniendo énfasis en el trabajo en equipo clase a clase.

Objetivos del curso



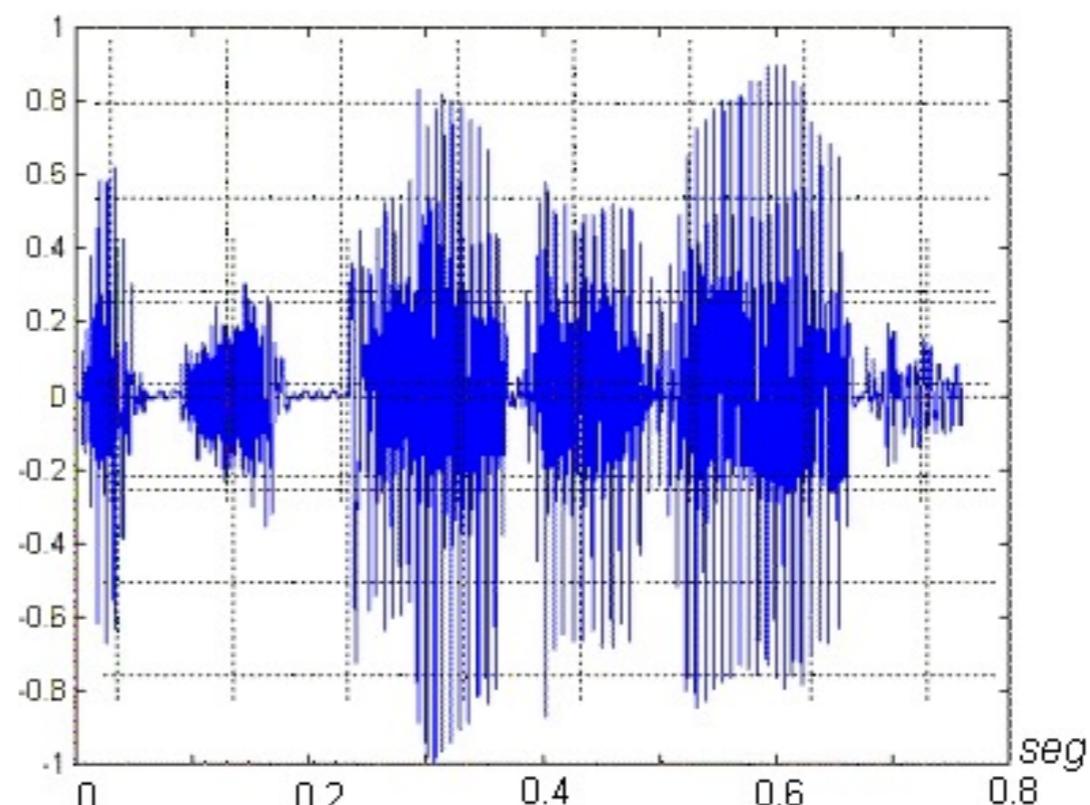
- Resolver problemas de reconocimiento de patrones en imágenes.
- Conocer distintas características que pueden ser extraídas en una imagen.
- Aprender técnicas para realizar la selección y clasificación de las muestras.
- Conocer técnicas de desempeño de los sistemas de reconocimiento.
- Aplicar la teoría y práctica en ejemplos reales.

- Cuando leemos un texto



- ¿Cómo aprendimos las letras?
- ¿Cómo aprendimos a formar las palabras?
- Detectaron algo extraño en alguna imagen anterior

- Cuando escuchamos una voz



- ¿Cómo es posible saber quien habla a partir de la voz?
- ¿Cómo aprendimos a decir palabras?

- Cuando miramos a alguien

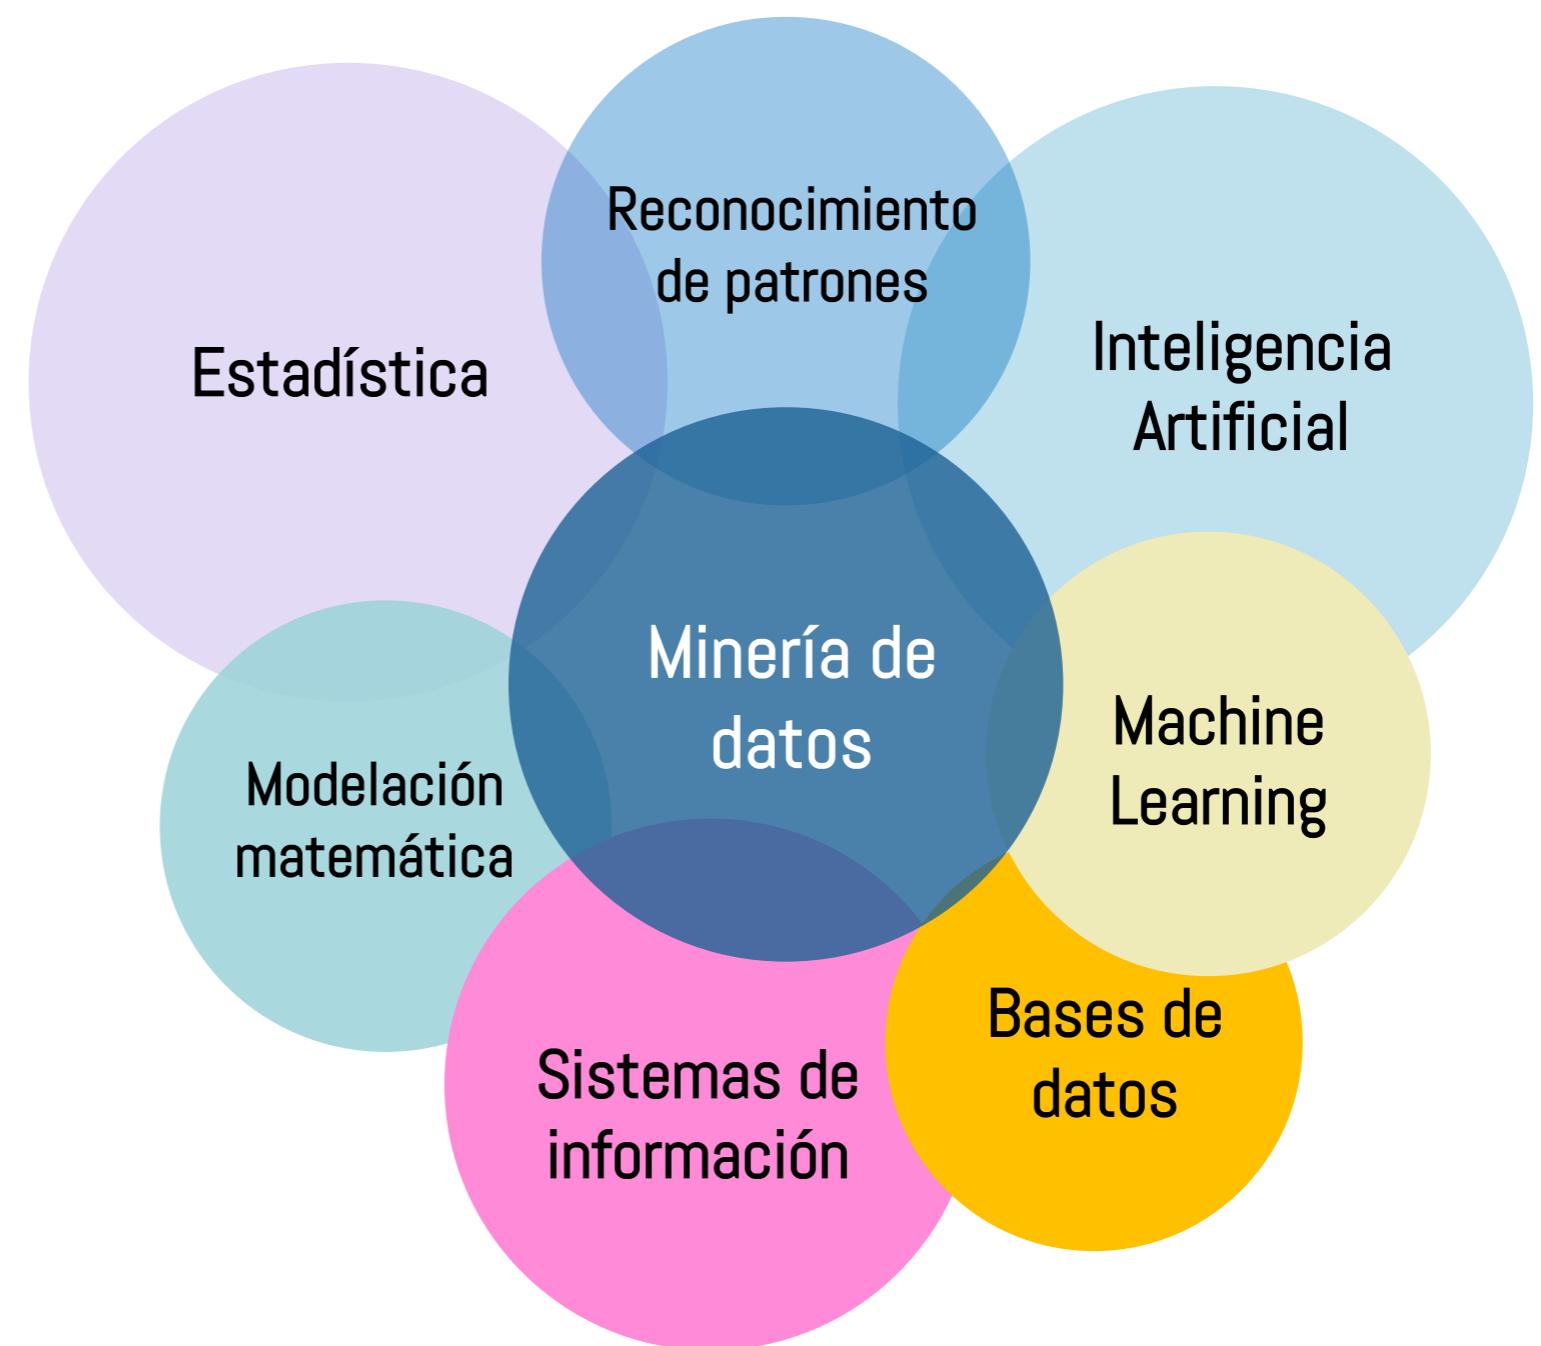


- ¿Cómo nos reconocemos a nosotros mismos?
- ¿Cómo reconocemos a nuestros amigos por su rostro?
- ¿Qué inferimos sobre de su estado de ánimo?

- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
 - Panorama general
 - Machine Learning (Ejemplo)
 - Big Data

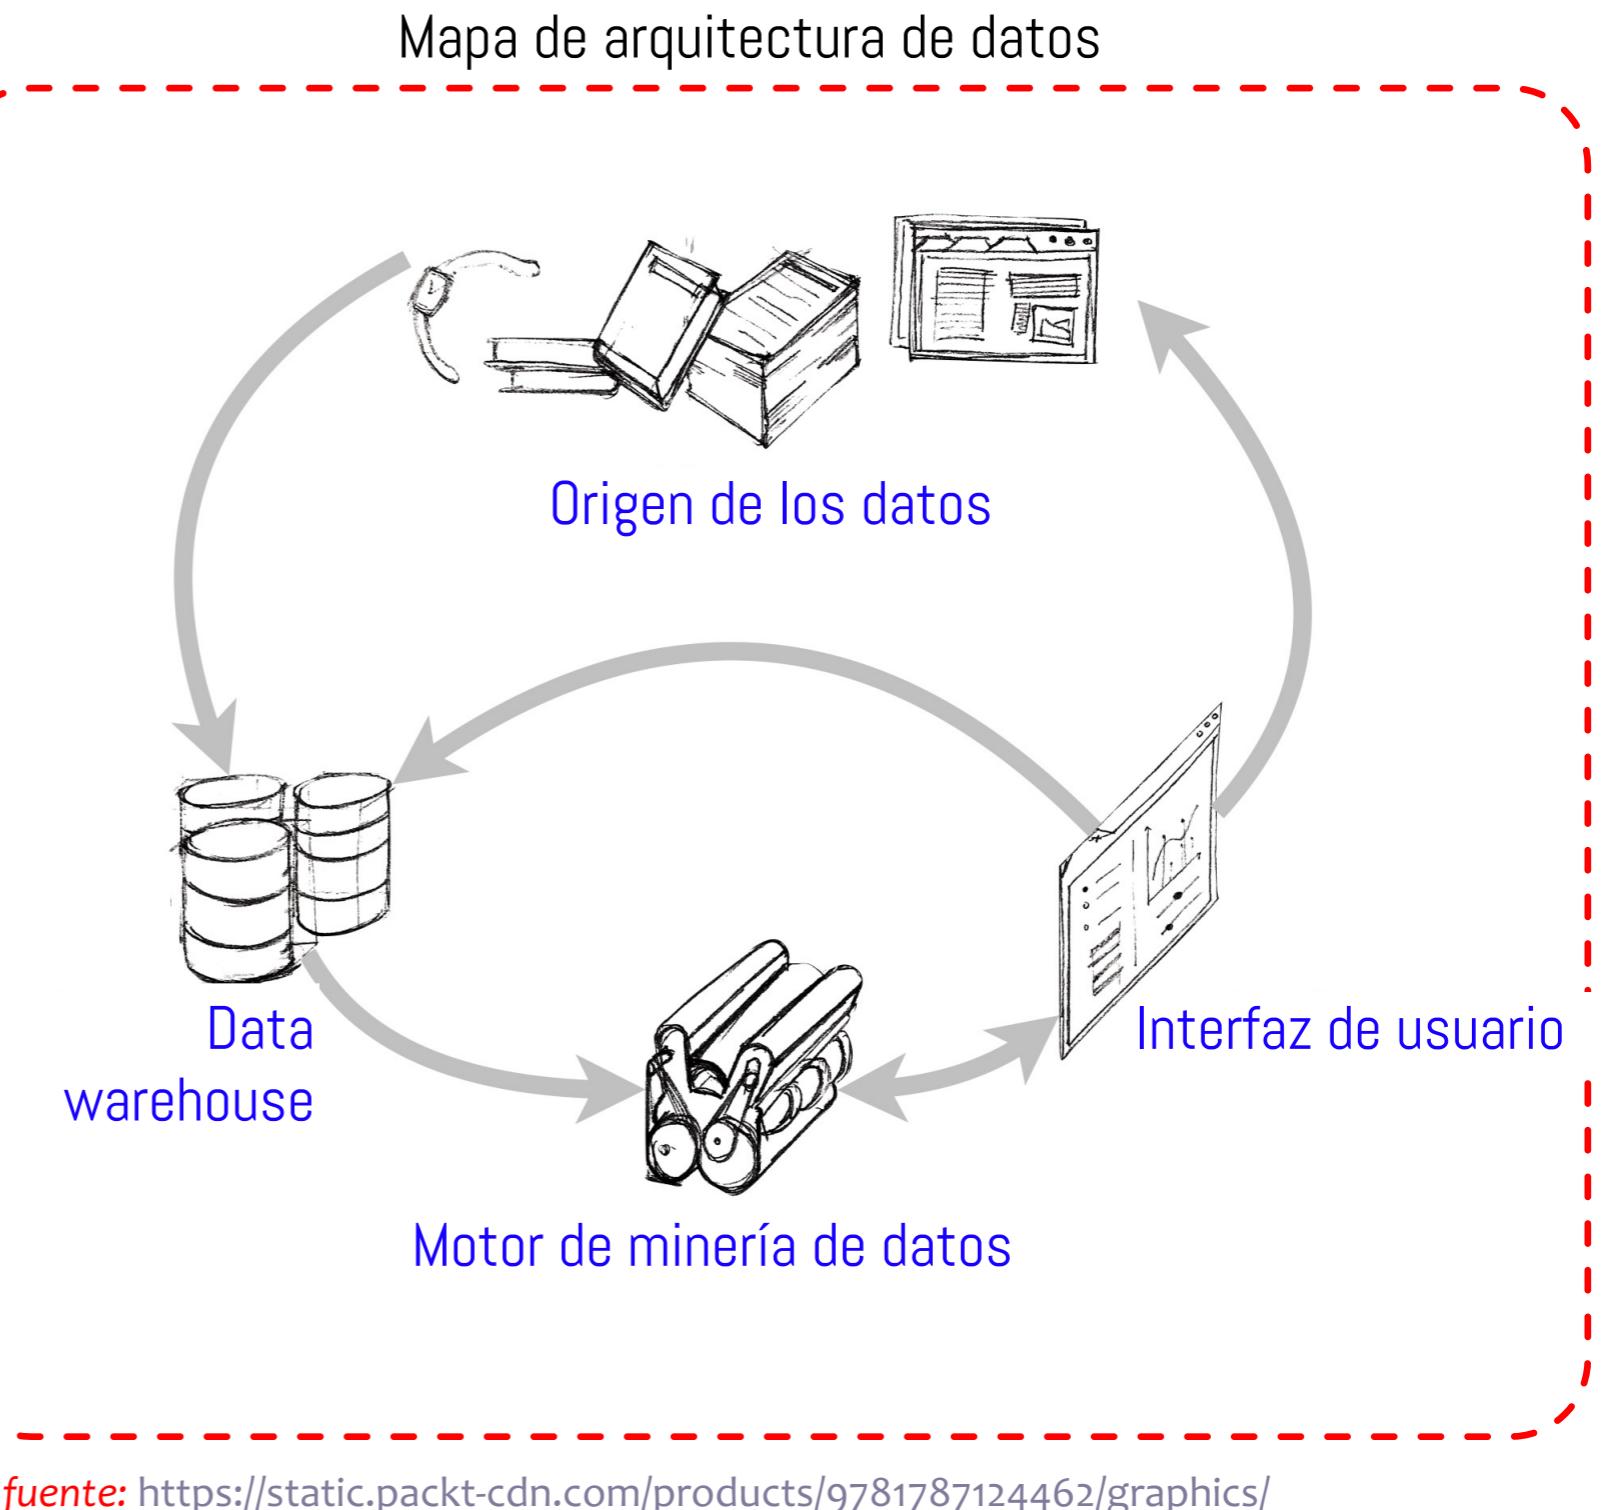
Minería de datos

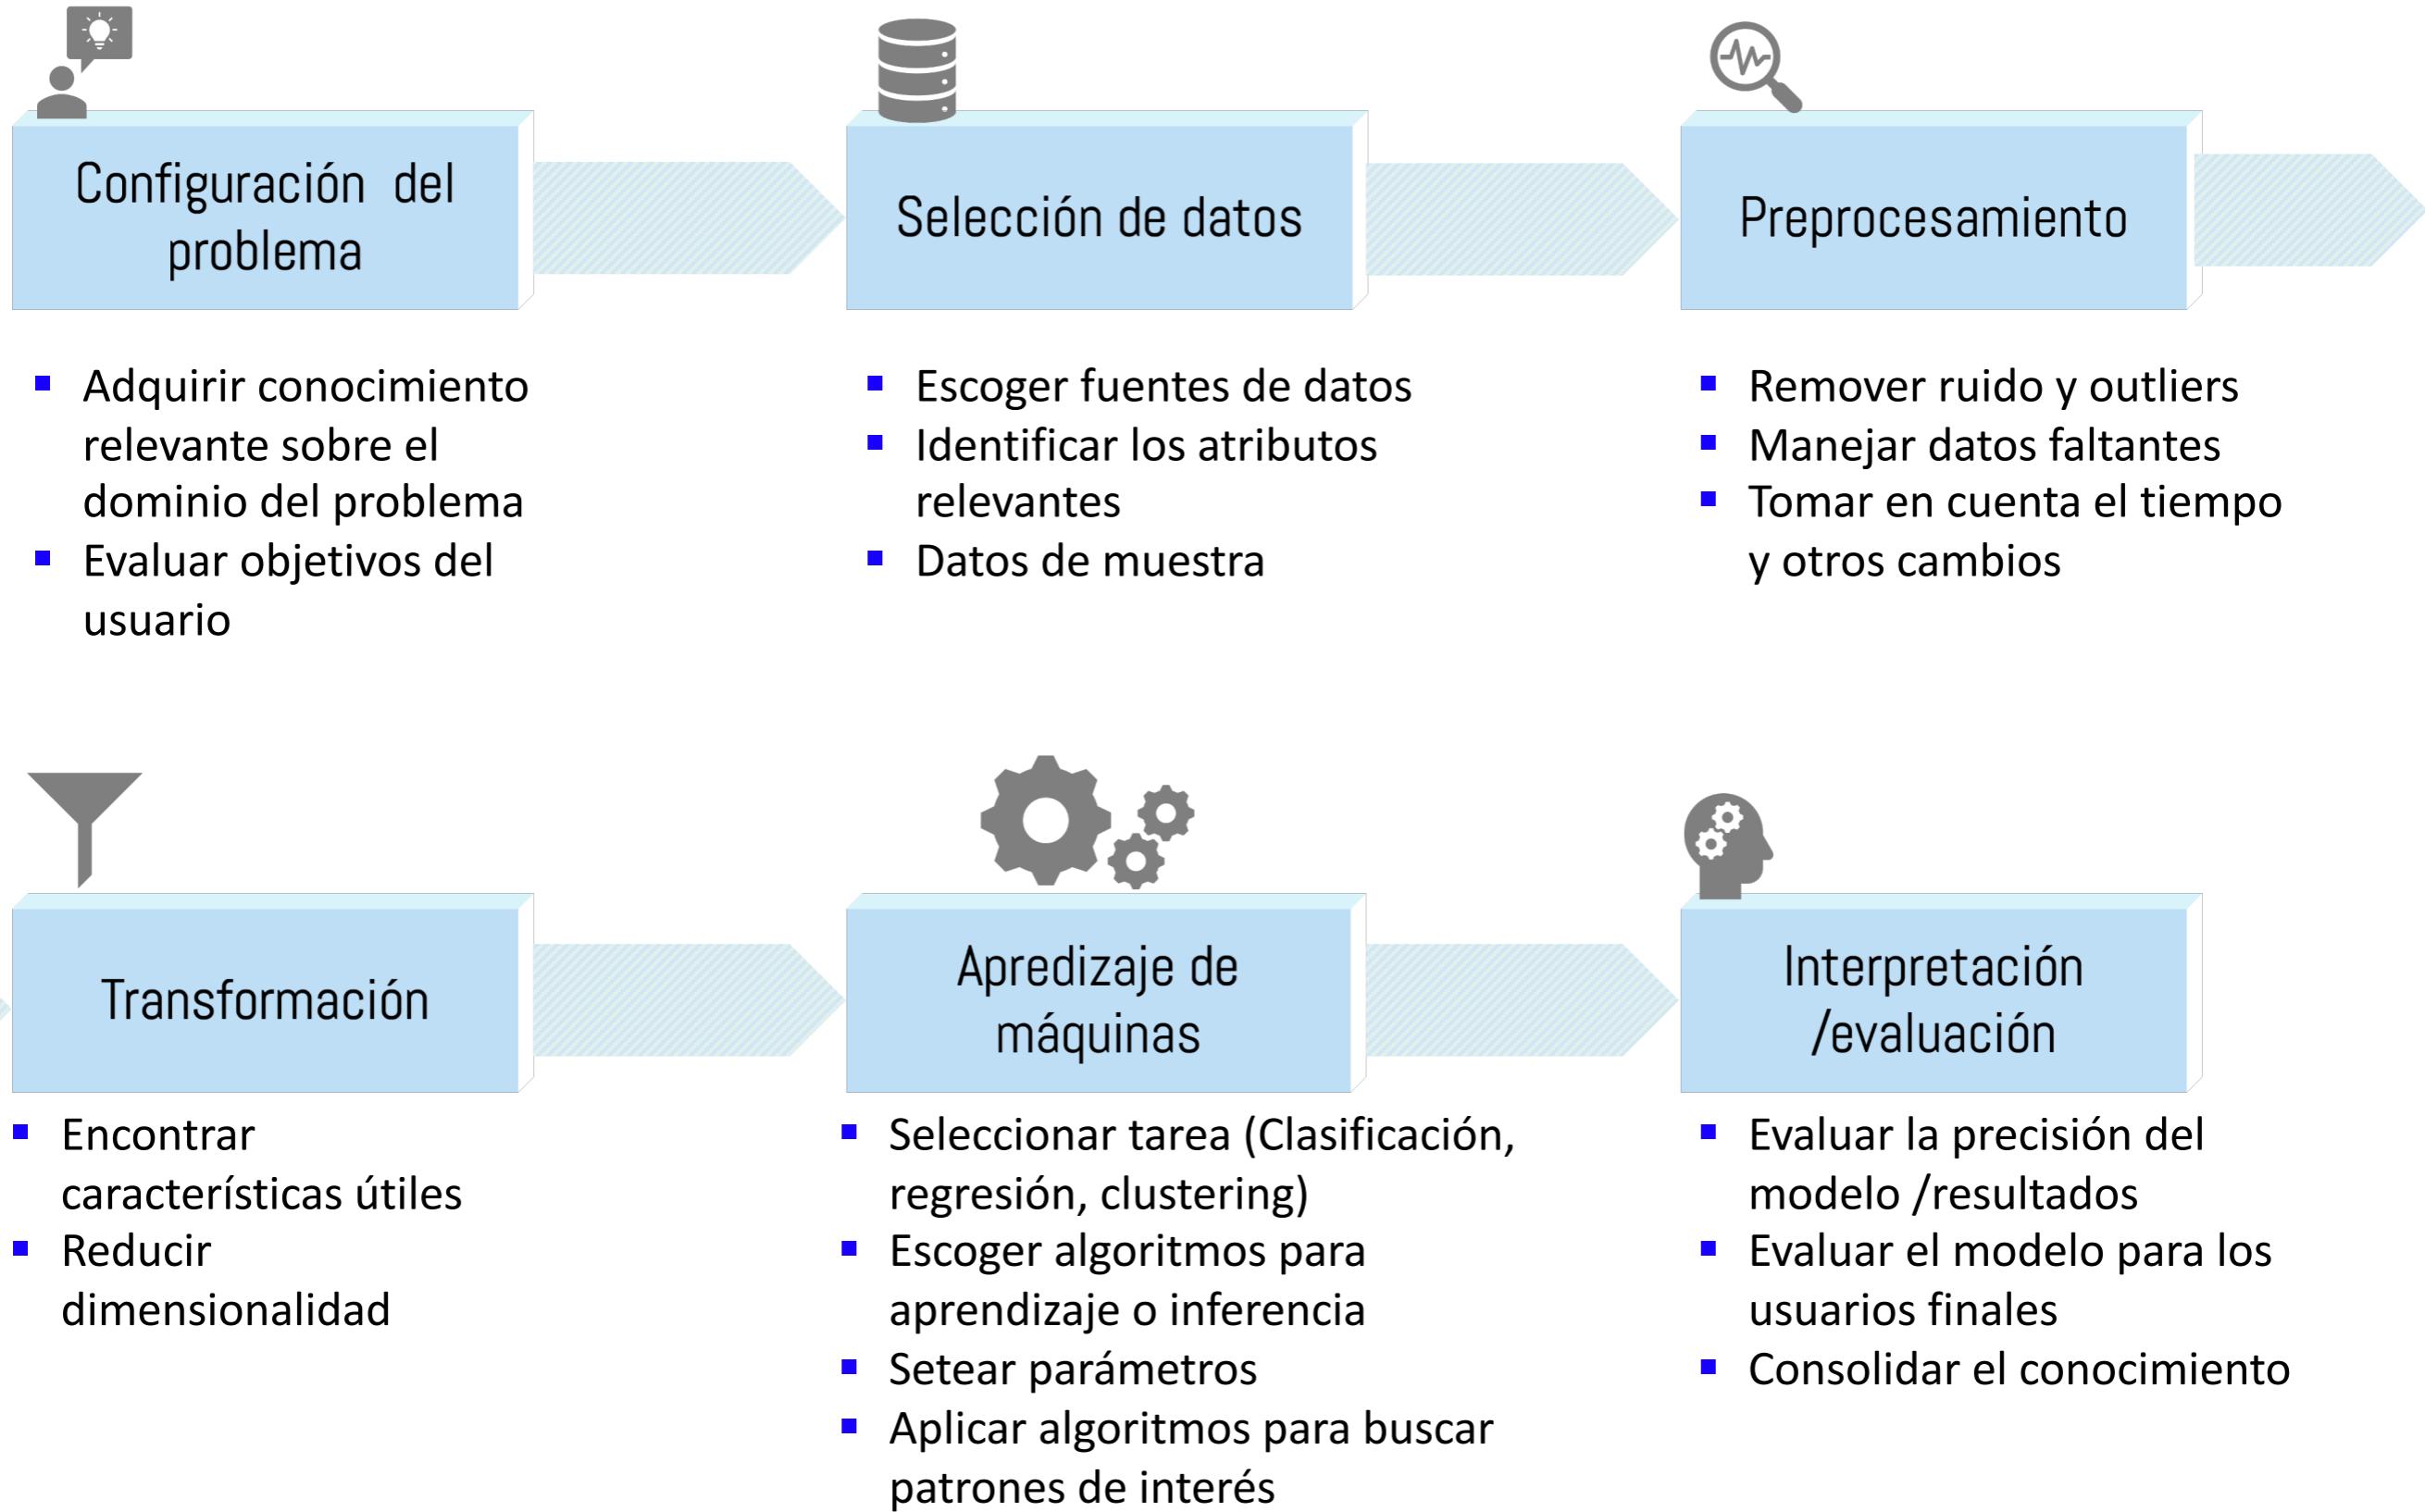
Se enfoca en cómo escalar y procesar grandes cantidades de datos y cómo incorporar una respuesta que mejore la precisión y minimice el esfuerzo



Minería de datos

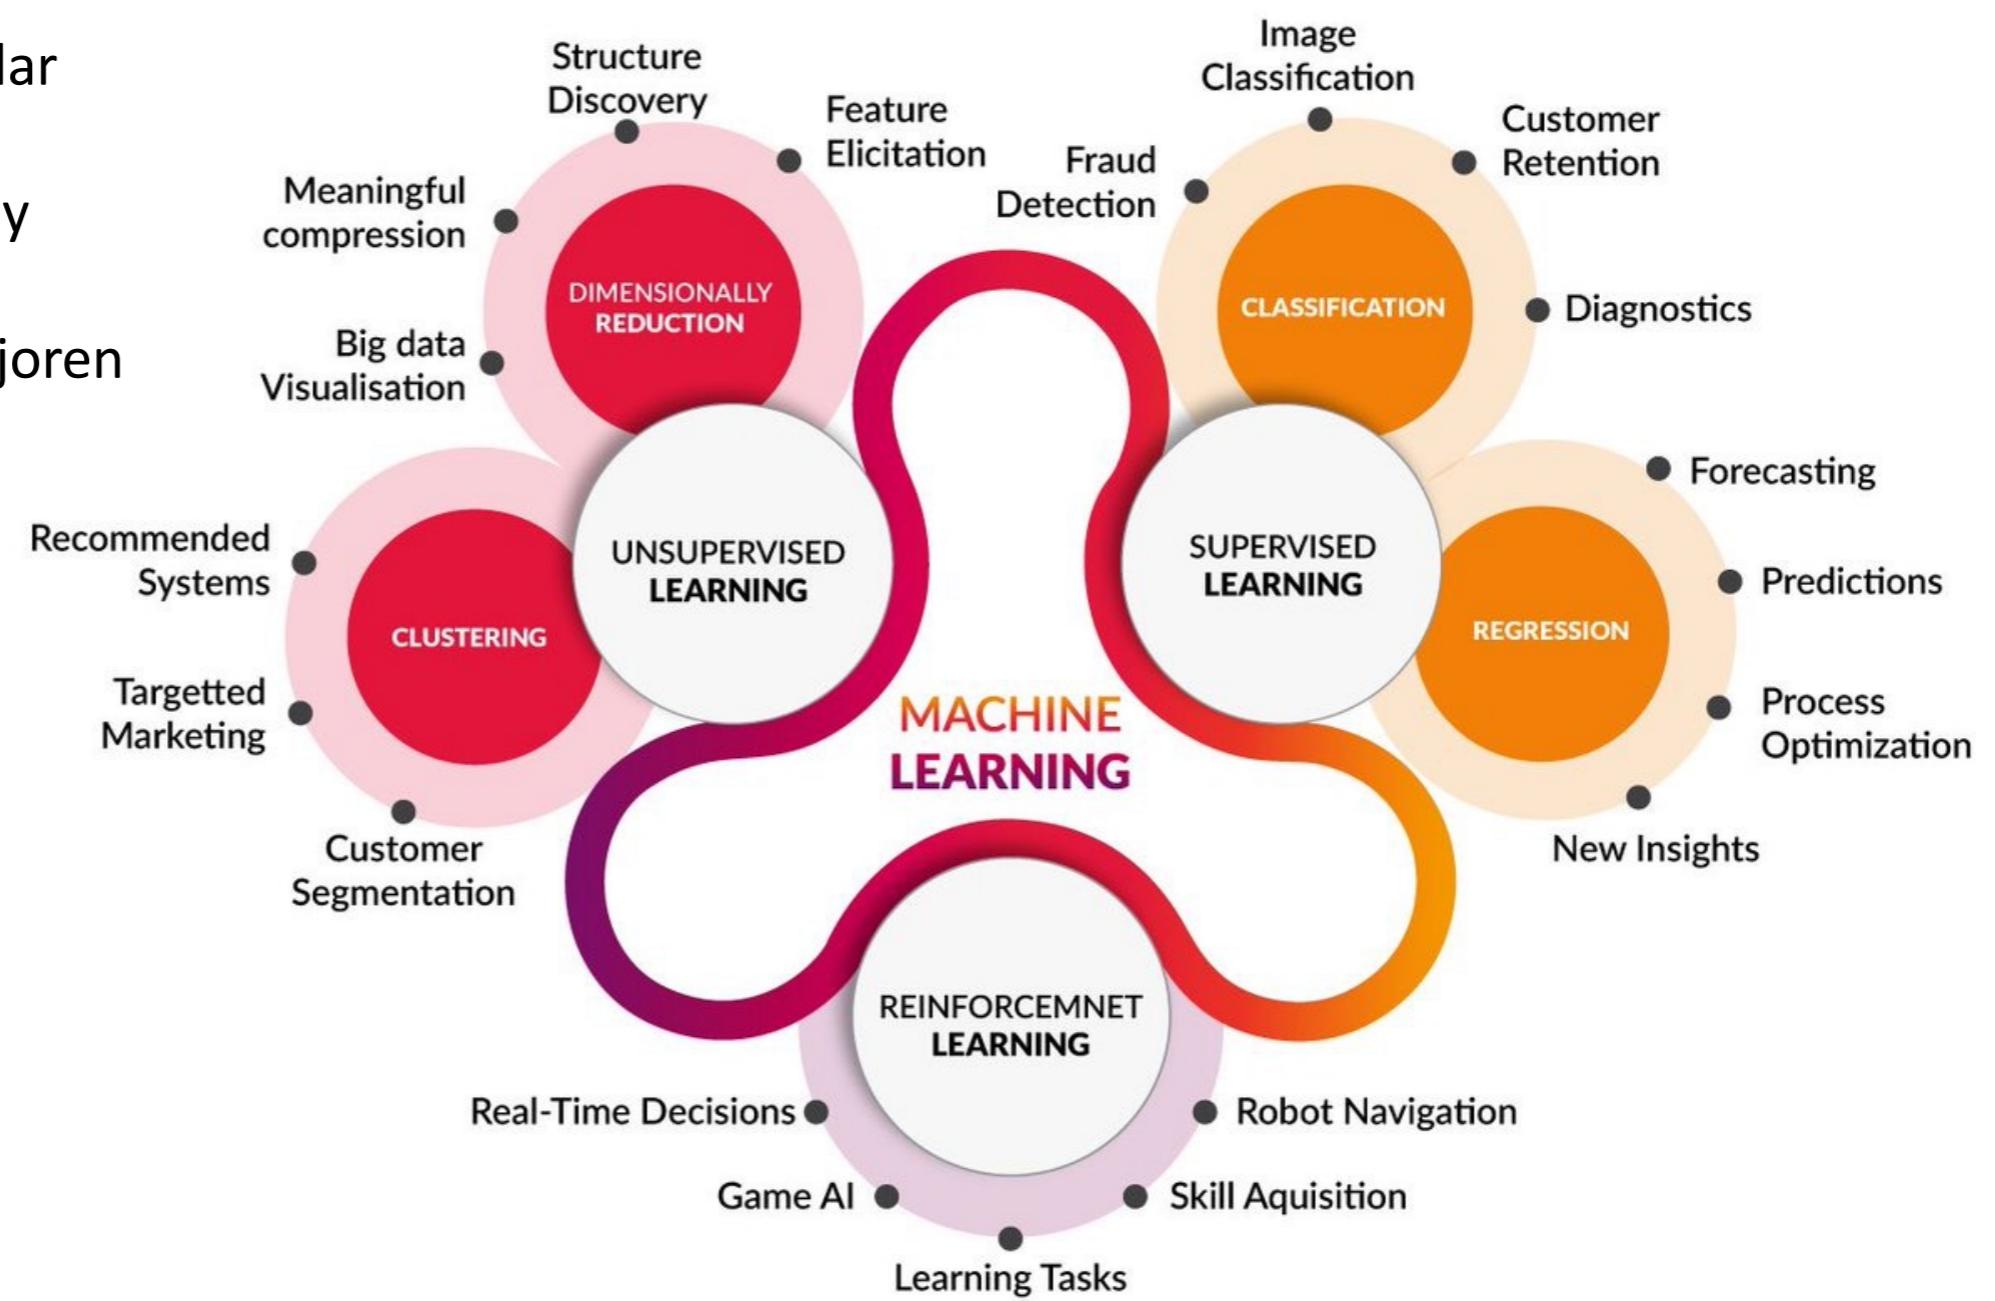
Se enfoca en cómo escalar y procesar grandes cantidades de datos y cómo incorporar una respuesta que mejore la precisión y minimice el esfuerzo





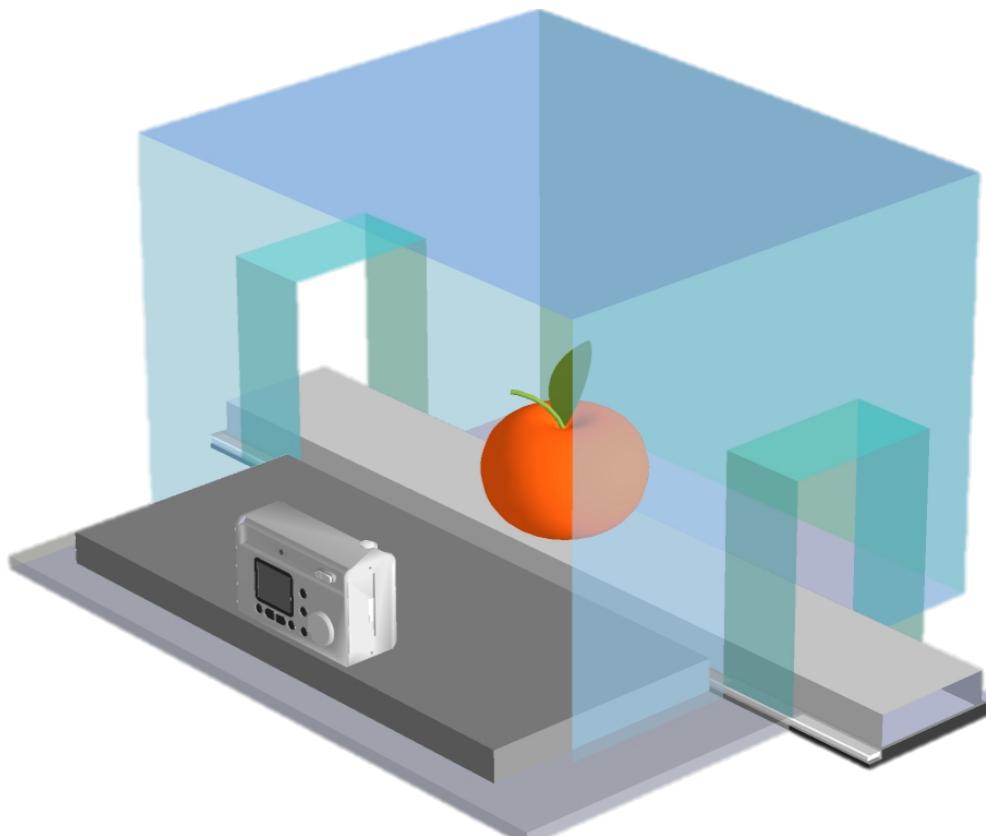
Machine Learning (aprendizaje de máquinas)

Se enfoca en desarrollar nuevas herramientas estadísticas, modelos y algoritmos que automáticamente mejoren con la experiencia



fuente: <http://www.cognub.com/index.php/cognitive-platform/>

- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
 - Panorama general
 - Machine Learning (en acción)
 - Big Data



- ¿Qué es la minería de datos?

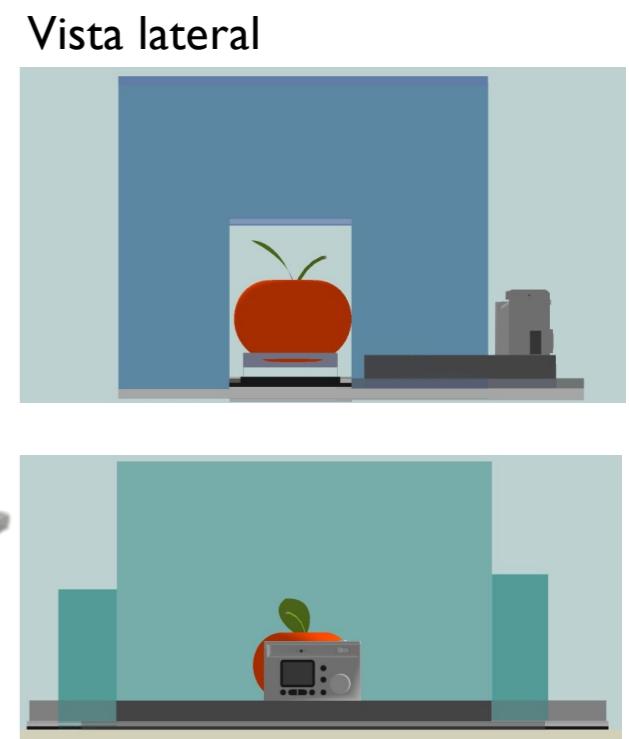
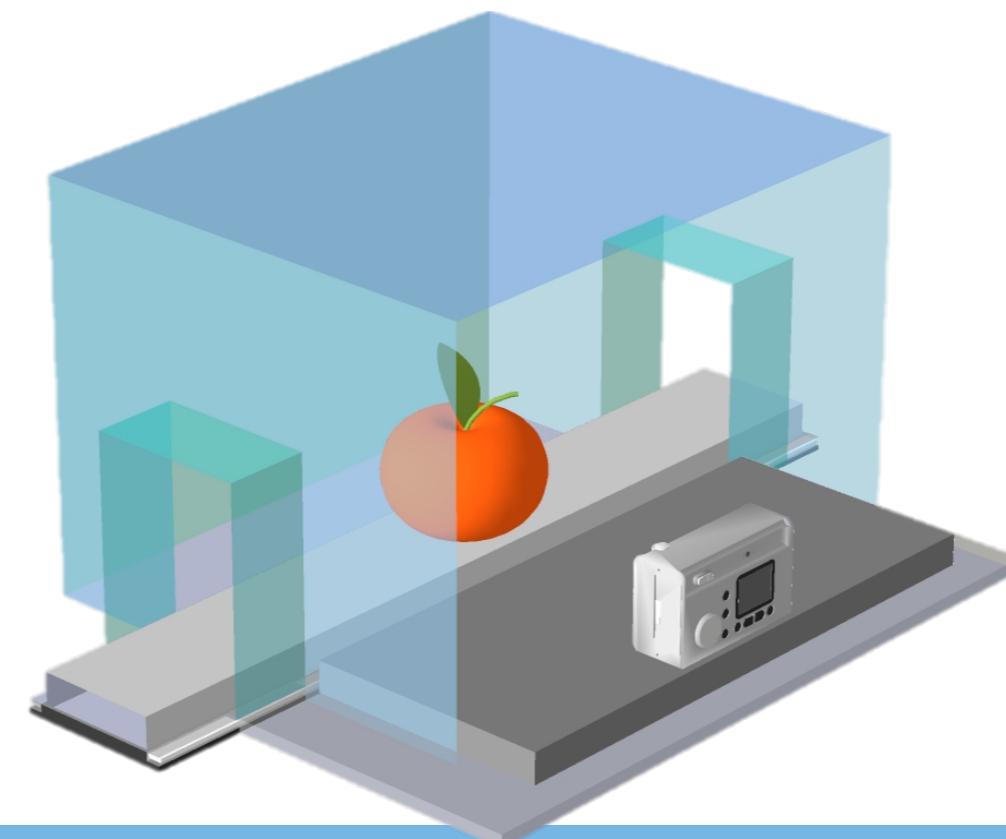
Es el proceso de **identificar un patrón adecuado, novedoso, potencialmente útil** y en último lugar **comprendible** de los datos

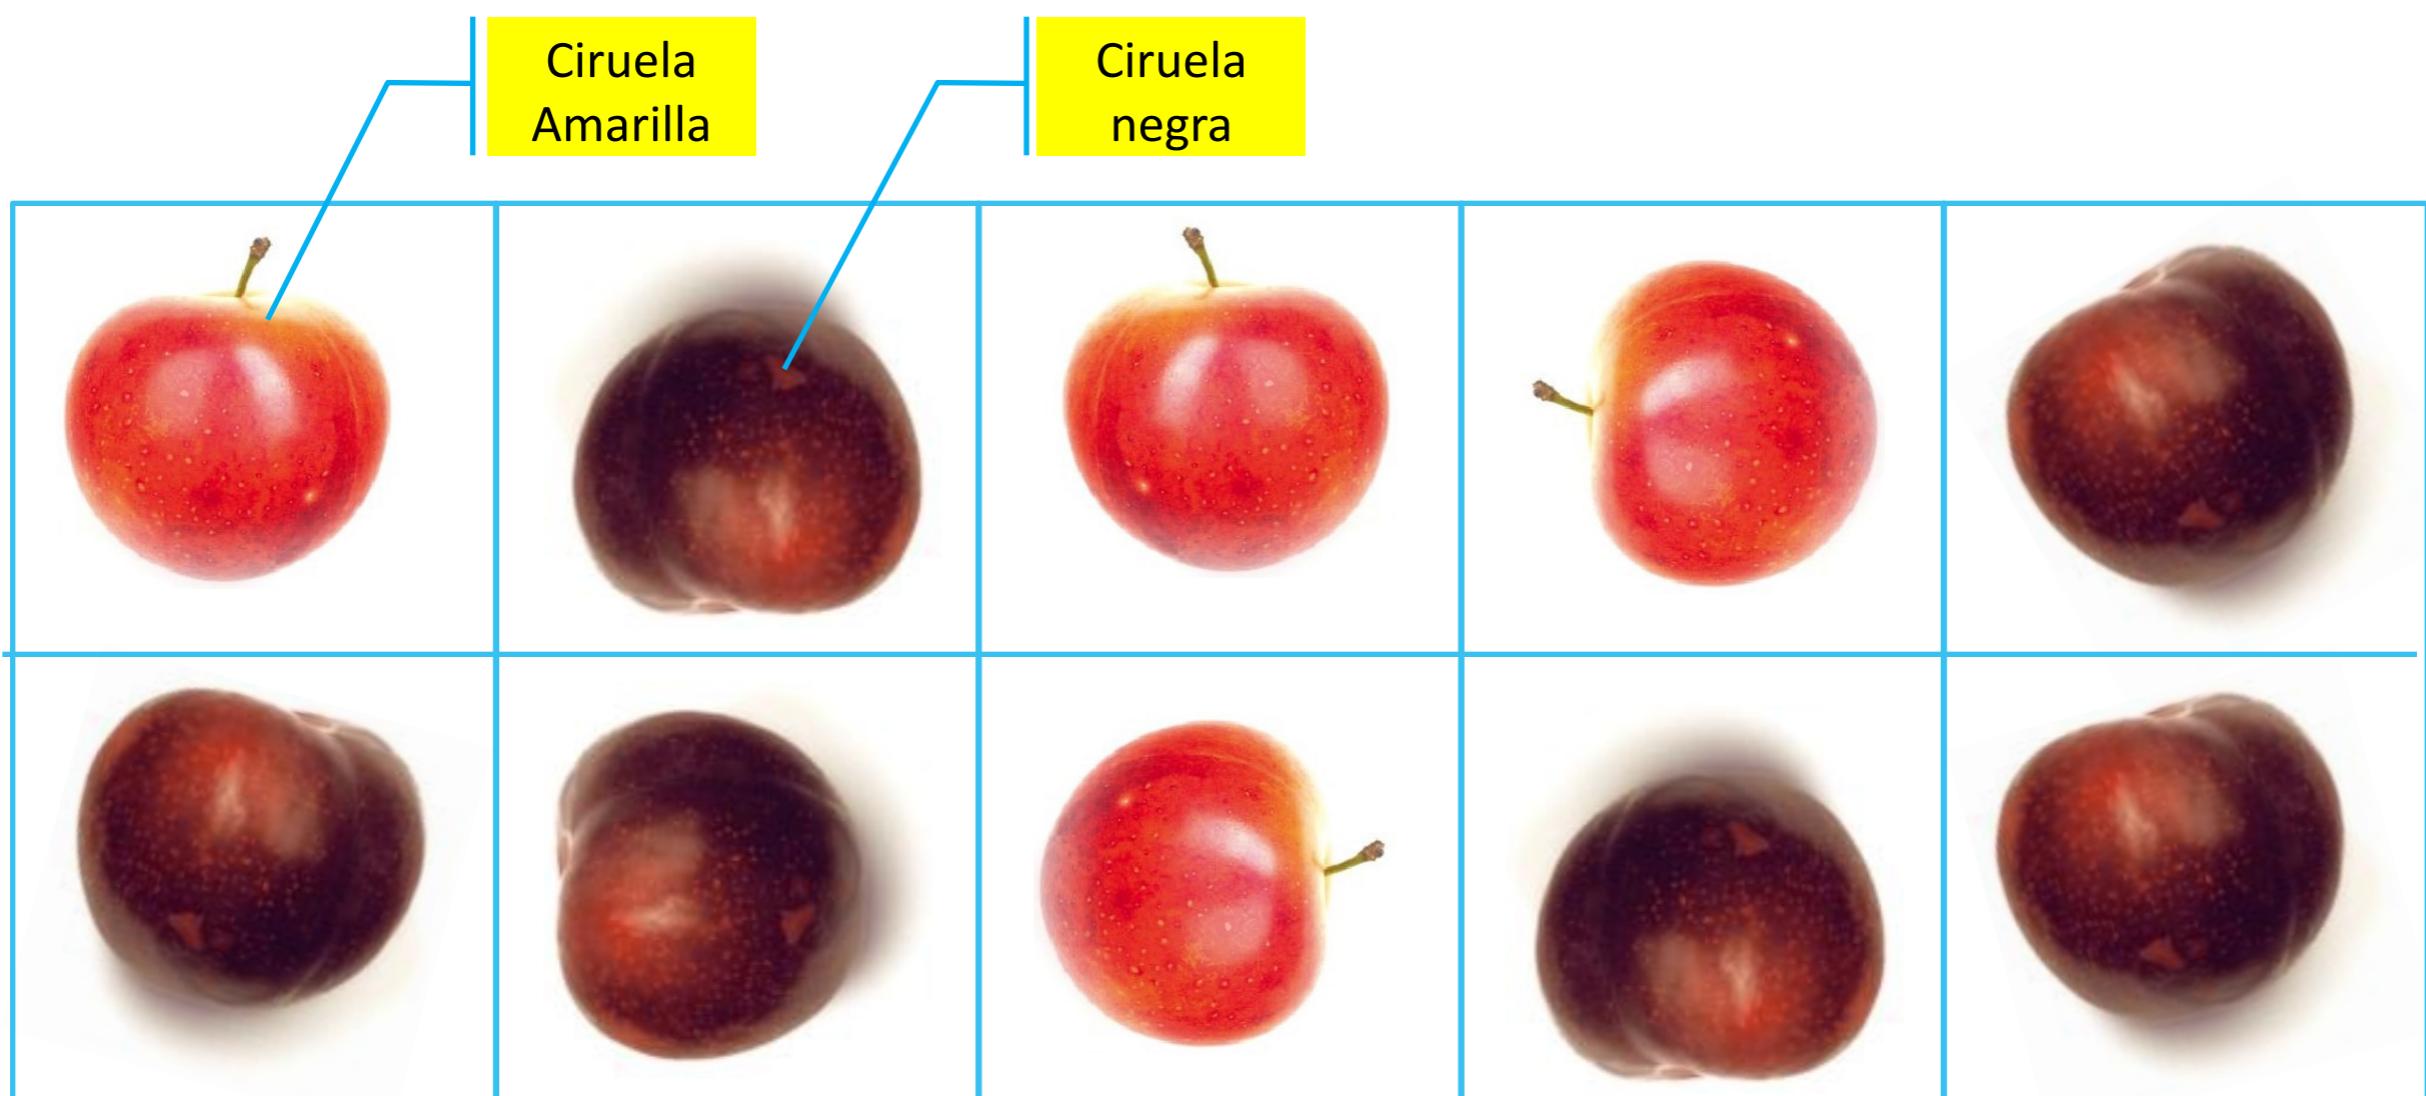
(Fayyad, Piatetsky-Shapiro & Smith 1996)

Ejemplo inventado

Suponga que usted diseña una máquina que toma fotos a ciruelas.

Usted desea diseñar una máquina que separe las ciruelas amarillas de las ciruelas negras automáticamente según sus características intrínsecas (color, forma, tamaño, etc)





¿Cómo separamos las ciruelas amarillas de la ciruelas negras?

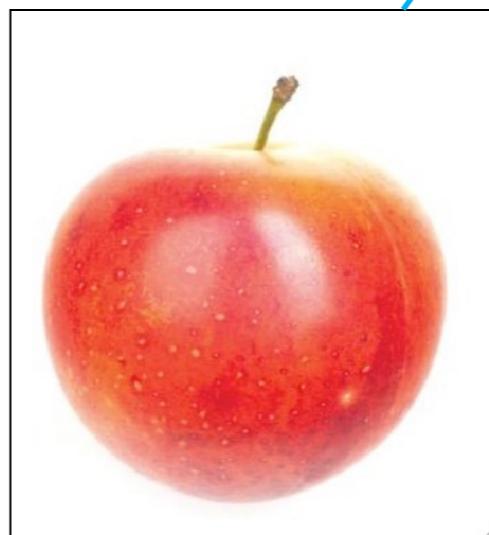


■ Preprocesamiento

En esta etapa la información se encuentra en forma bruta, para ello debe ser extraída y adecuada de tal forma que se pueda procesar.

Ejemplo: Quitar ruido, limpiar la imagen, mejorar el contraste, completar datos incompletos, etc.

Este proceso se denomina segmentación



Ciruela Amarilla

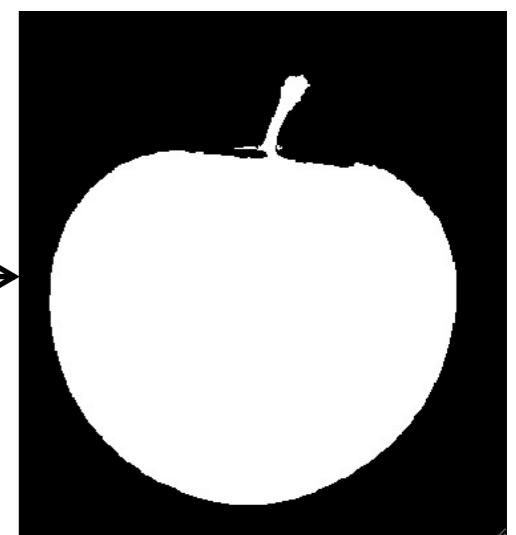
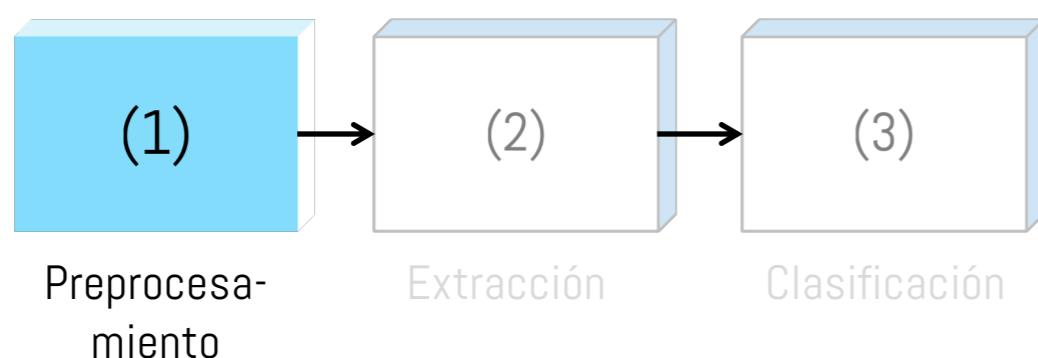


Imagen binaria



Ciruela Negra

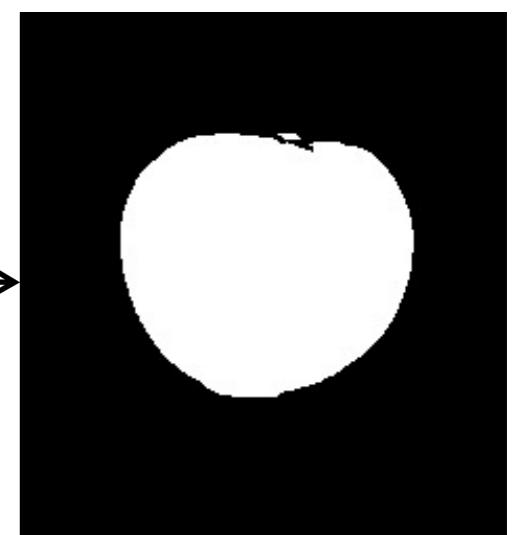


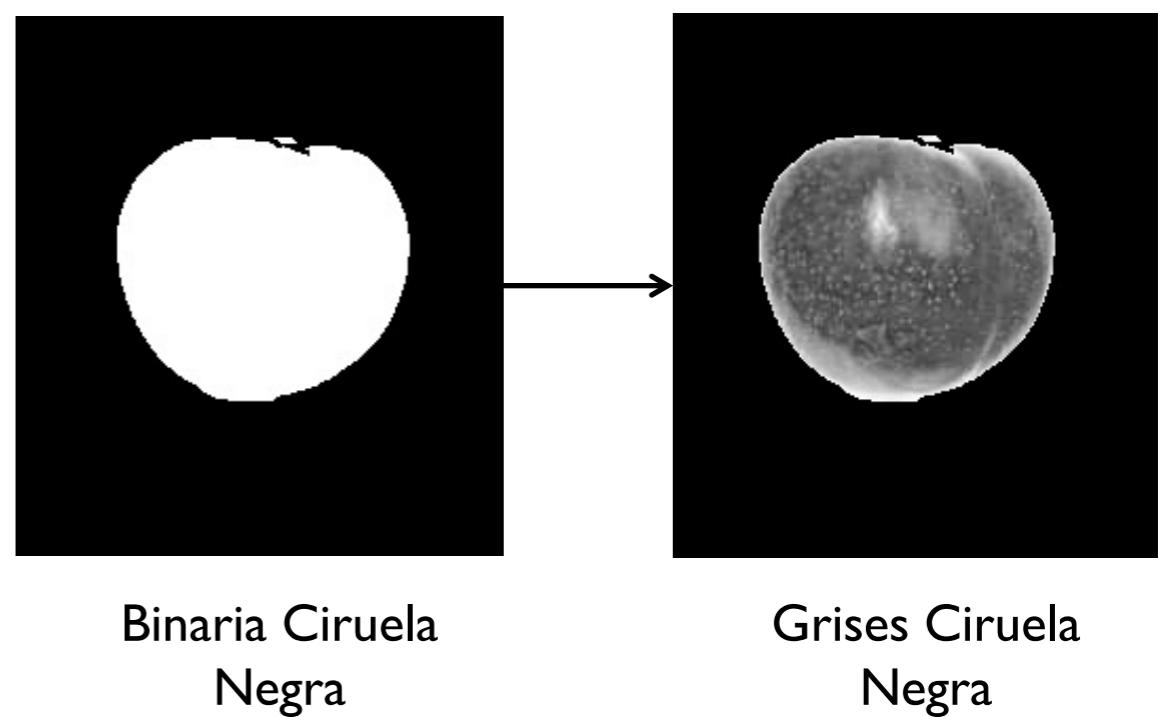
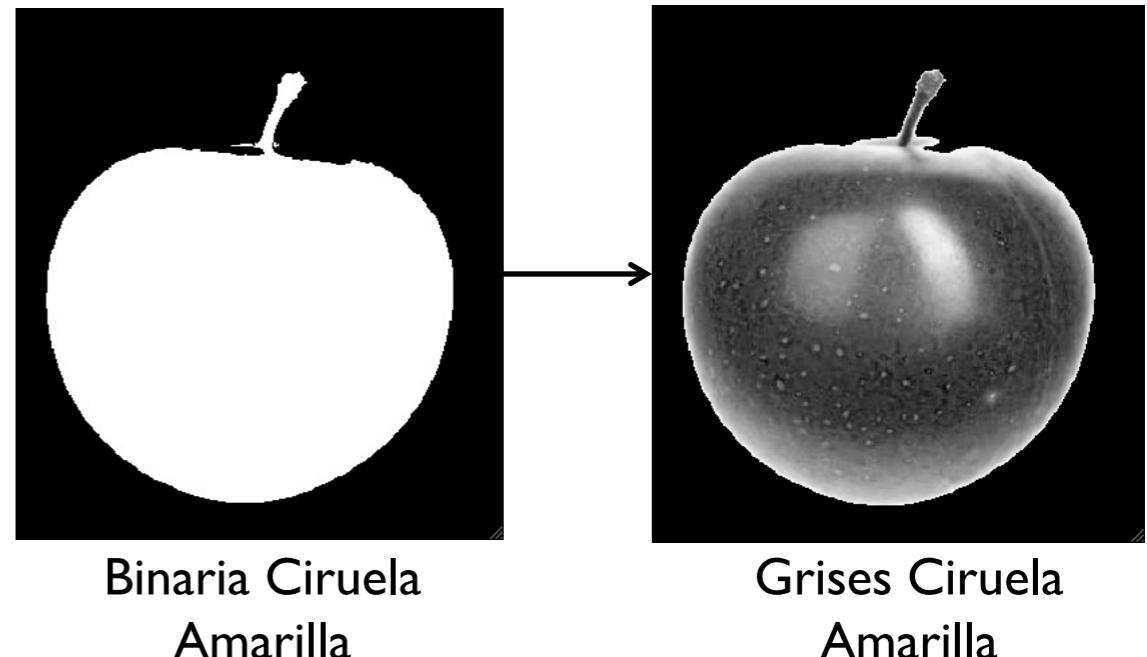
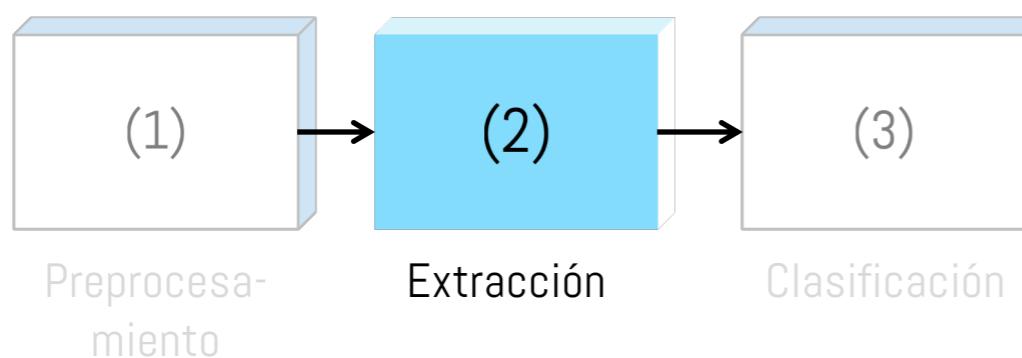
Imagen binaria

■ Extracción de características

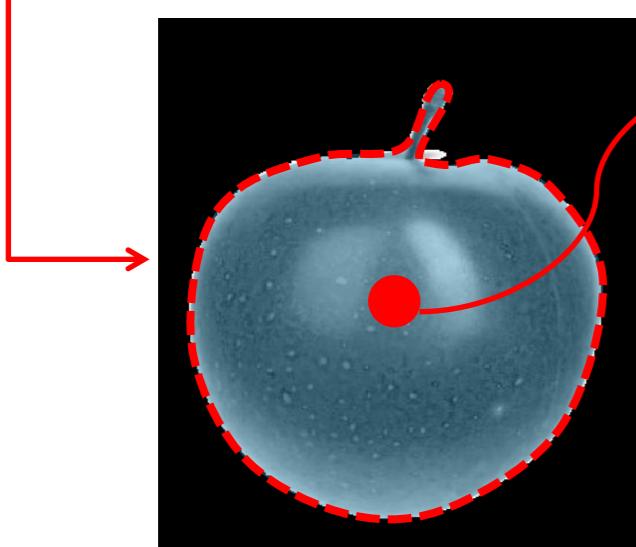
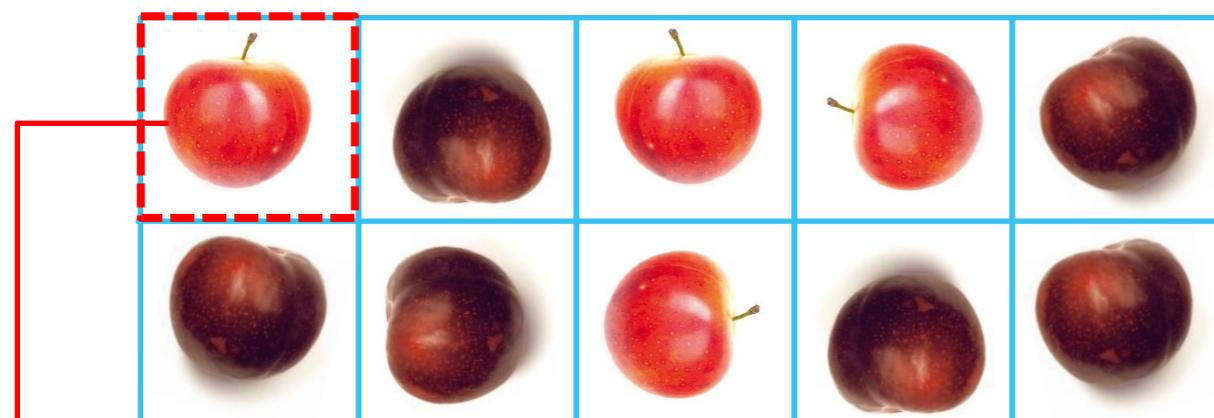
En esta etapa se extraen y miden las características (*features*) de los objetos segmentados.

Podemos extraer cualquier característica, independiente si esta es útil o no. Más adelante estudiaremos algoritmos para definir cuál o cuales de estas características son útiles.

Ejemplo: tamaño, diámetro, peso, color, forma, momentos.



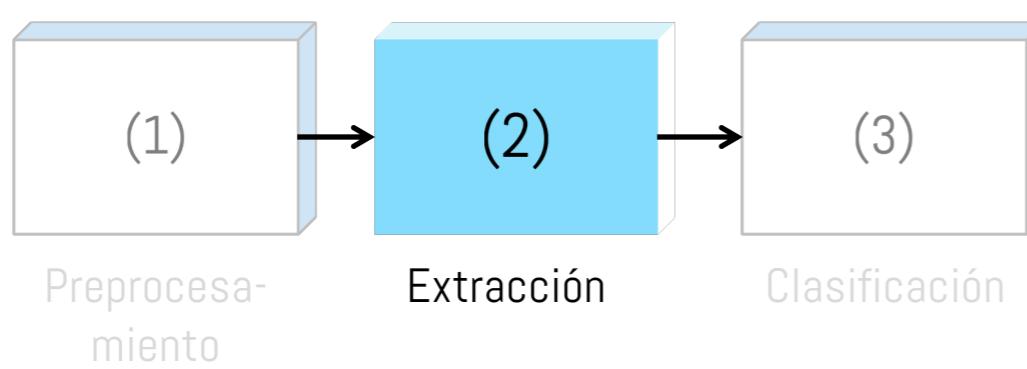
■ Extracción de características



Ciruela-A01
gris: 41.3%

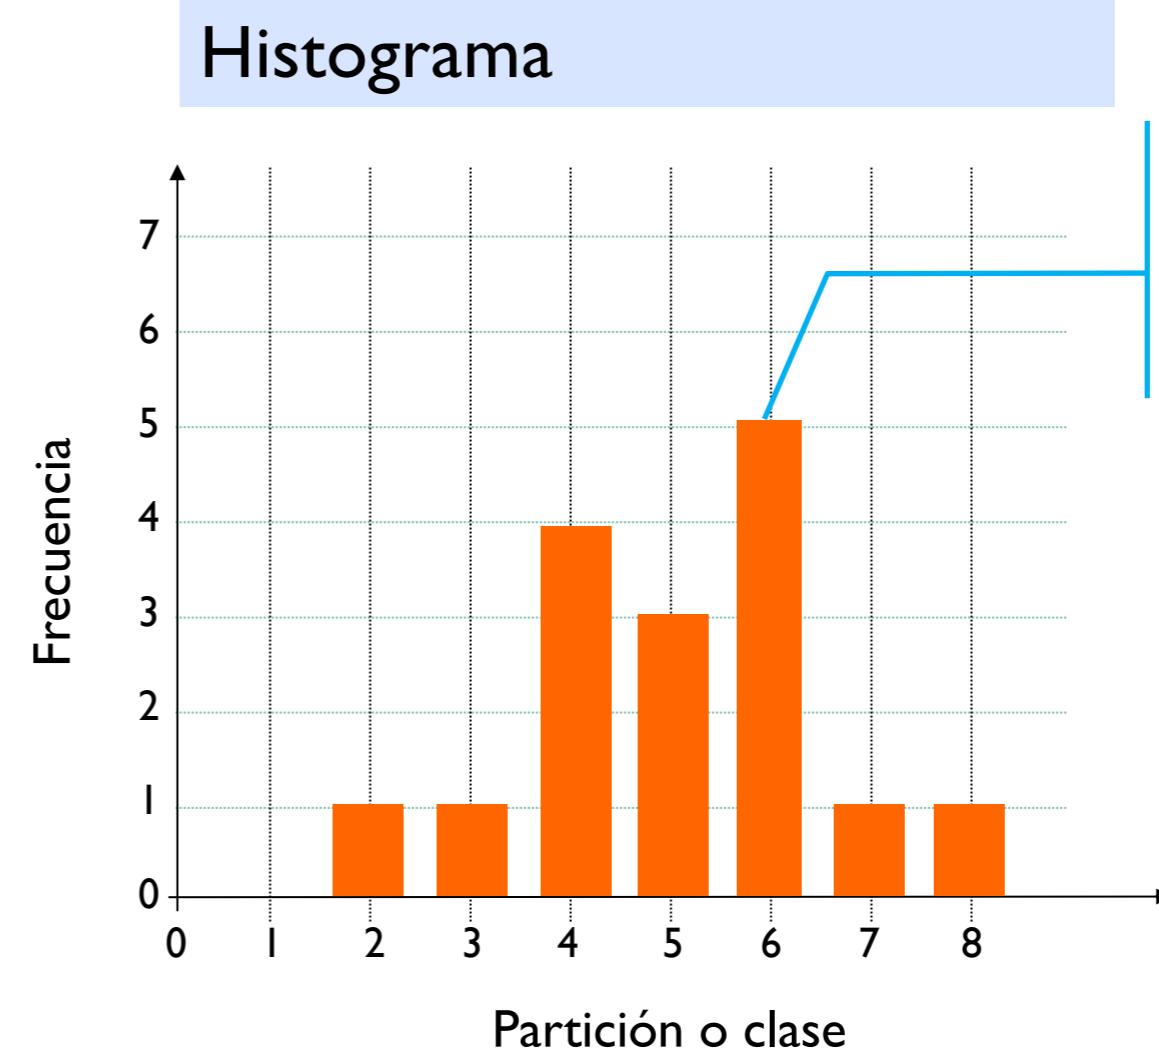
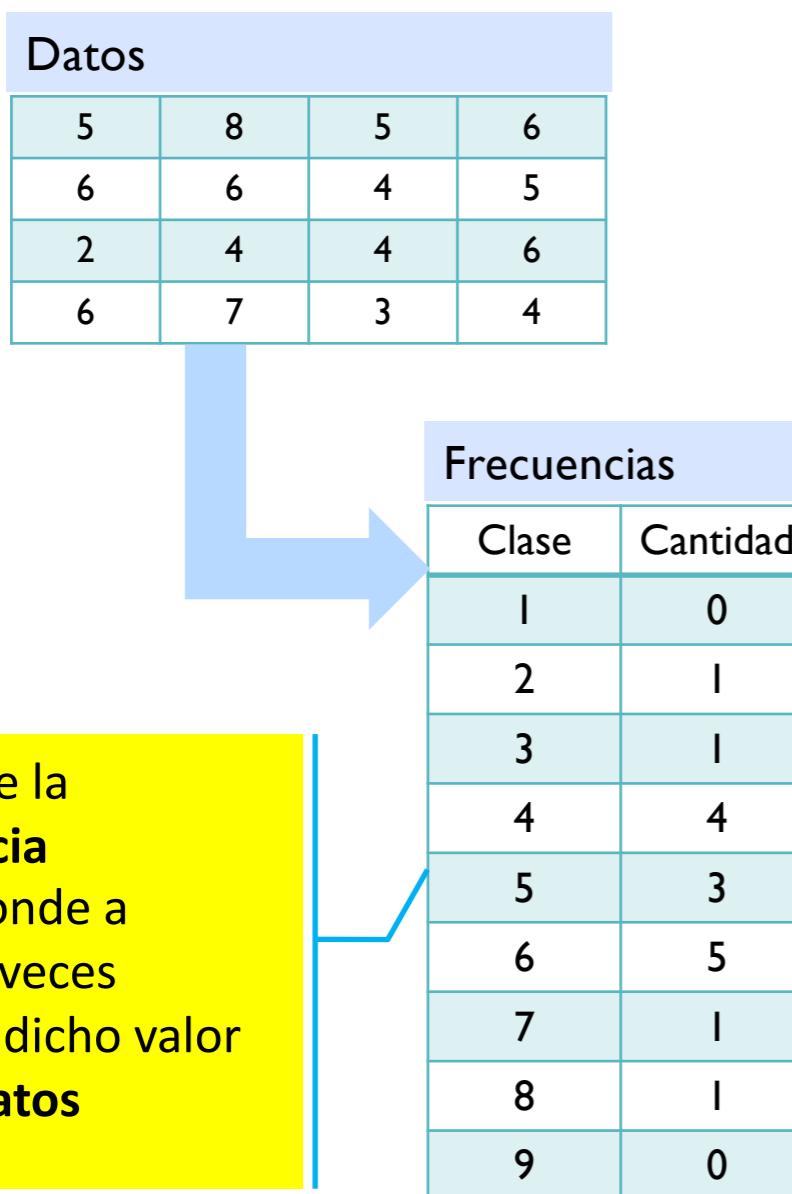
Suponga que luego de extraer solo los niveles de gris rojo de la imagen, determinamos su porcentaje de nivel de rojo

	Ciruelas Amarillas	Ciruelas Negras	
Ciruela-A01	41.3	Ciruela-N01	23.6
Ciruela-A02	39.8	Ciruela-N02	30.1
Ciruela-A03	36.5	Ciruela-N03	37.1
Ciruela-A04	44.6	Ciruela-N04	17.9
Ciruela-A05	41.2	Ciruela-N05	19.7
Ciruela-A06	44.9	Ciruela-N06	30.5
Ciruela-A07	44.4	Ciruela-N07	35.4
:	:	:	
Ciruela-A050	38.7	Ciruela-N050	33.6



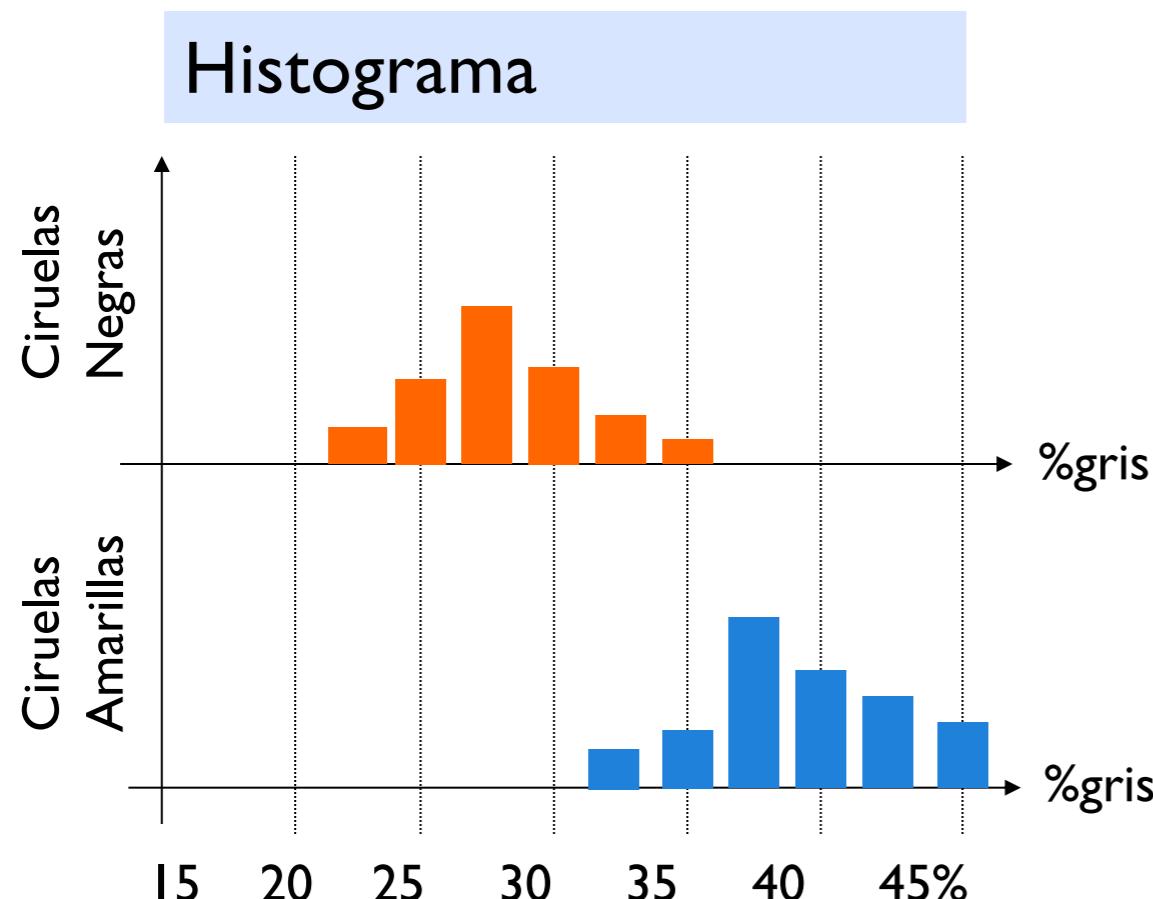
Histograma:

- Es una representación grafica de las observaciones que pertenecen a cada subintervalo de una partición.

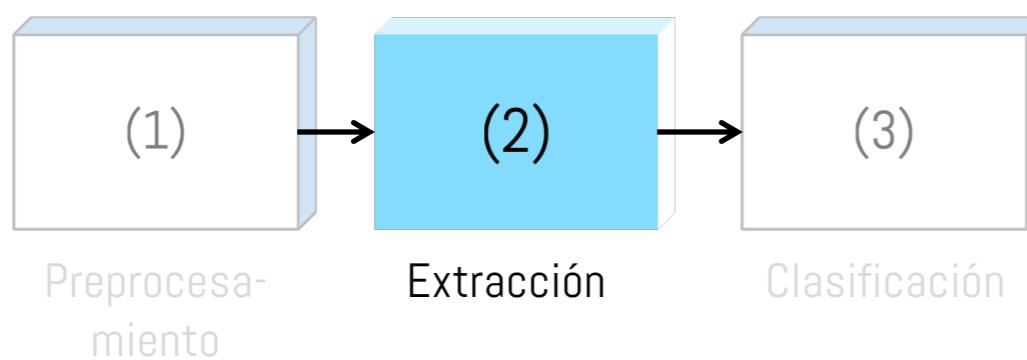


Esto es una representación de la tabla de frecuencia

- Extracción de características



Ciruelas Amarillas		Ciruelas Negras	
Ciruela-A01	41.3	Ciruela-N01	23.6
Ciruela-A02	39.8	Ciruela-N02	30.1
Ciruela-A03	36.5	Ciruela-N03	37.1
Ciruela-A04	44.6	Ciruela-N04	17.9
Ciruela-A05	41.2	Ciruela-N05	19.7
Ciruela-A06	44.9	Ciruela-N06	30.5
Ciruela-A07	44.4	Ciruela-N07	35.4
:		:	
Ciruela-A050	38.7	Ciruela-N050	33.6



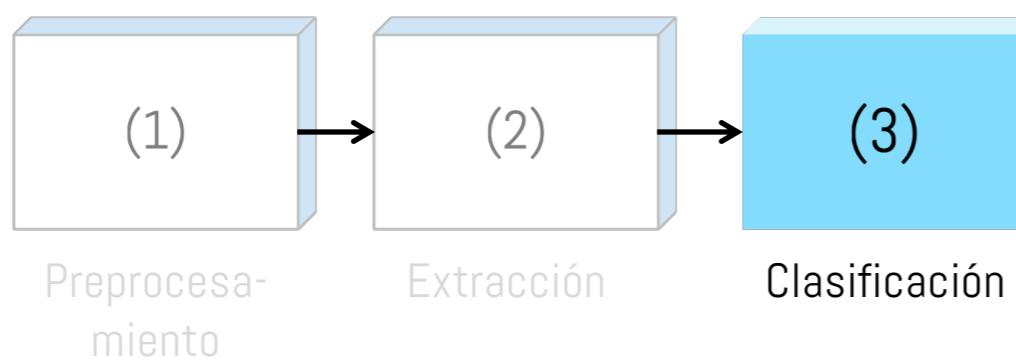
A partir de la tabla, generamos un histograma.
El histograma es simplemente una distribución acumulada.

Clasificación

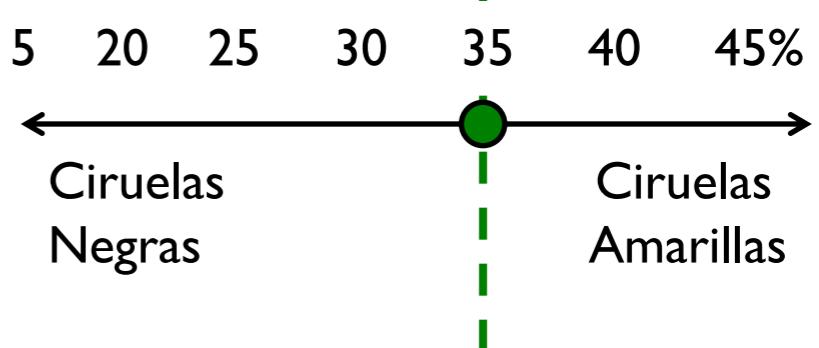
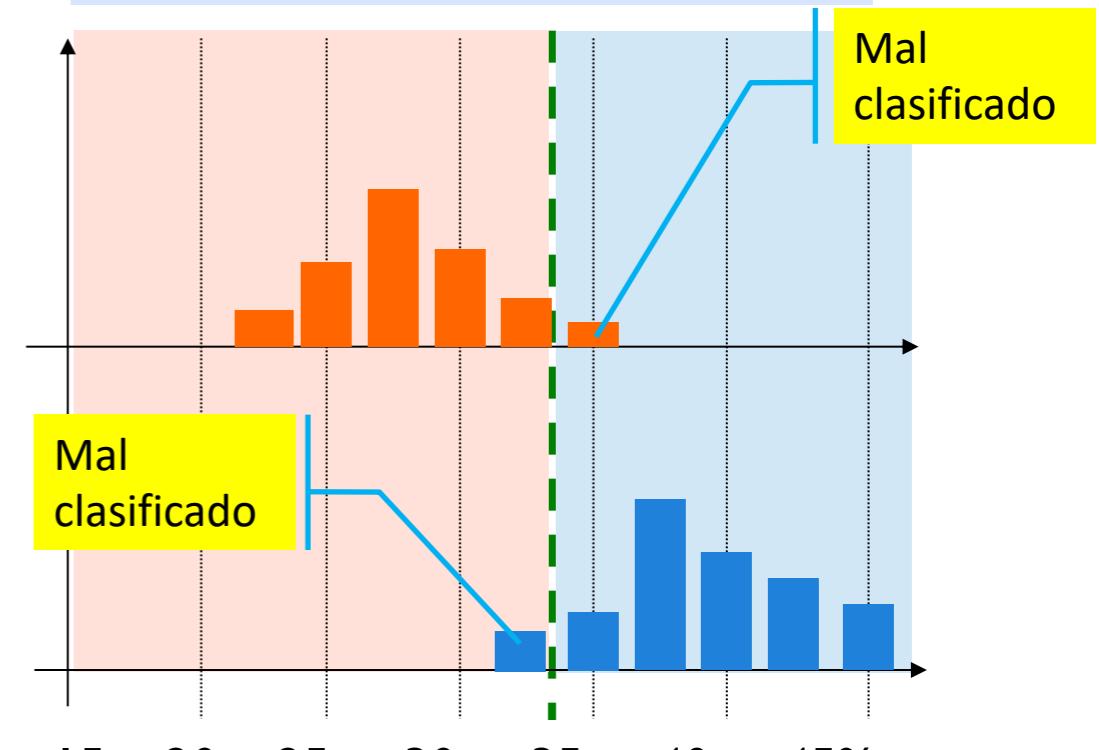
El objetivo del clasificador consiste en asignar clases a los objetos según sus características anteriormente extraídas.

Para diseñar el clasificador es necesario realizar un entrenamiento “off-line”. El entrenamiento permite que el sistema **funcione para datos no conocidos por el sistema**, de esta forma podemos emplear el clasificador para nuevos datos.

Sin embargo, no siempre obtendremos una buena separación entre las clases, y quedarán mal clasificados algunos objetos.



Histograma

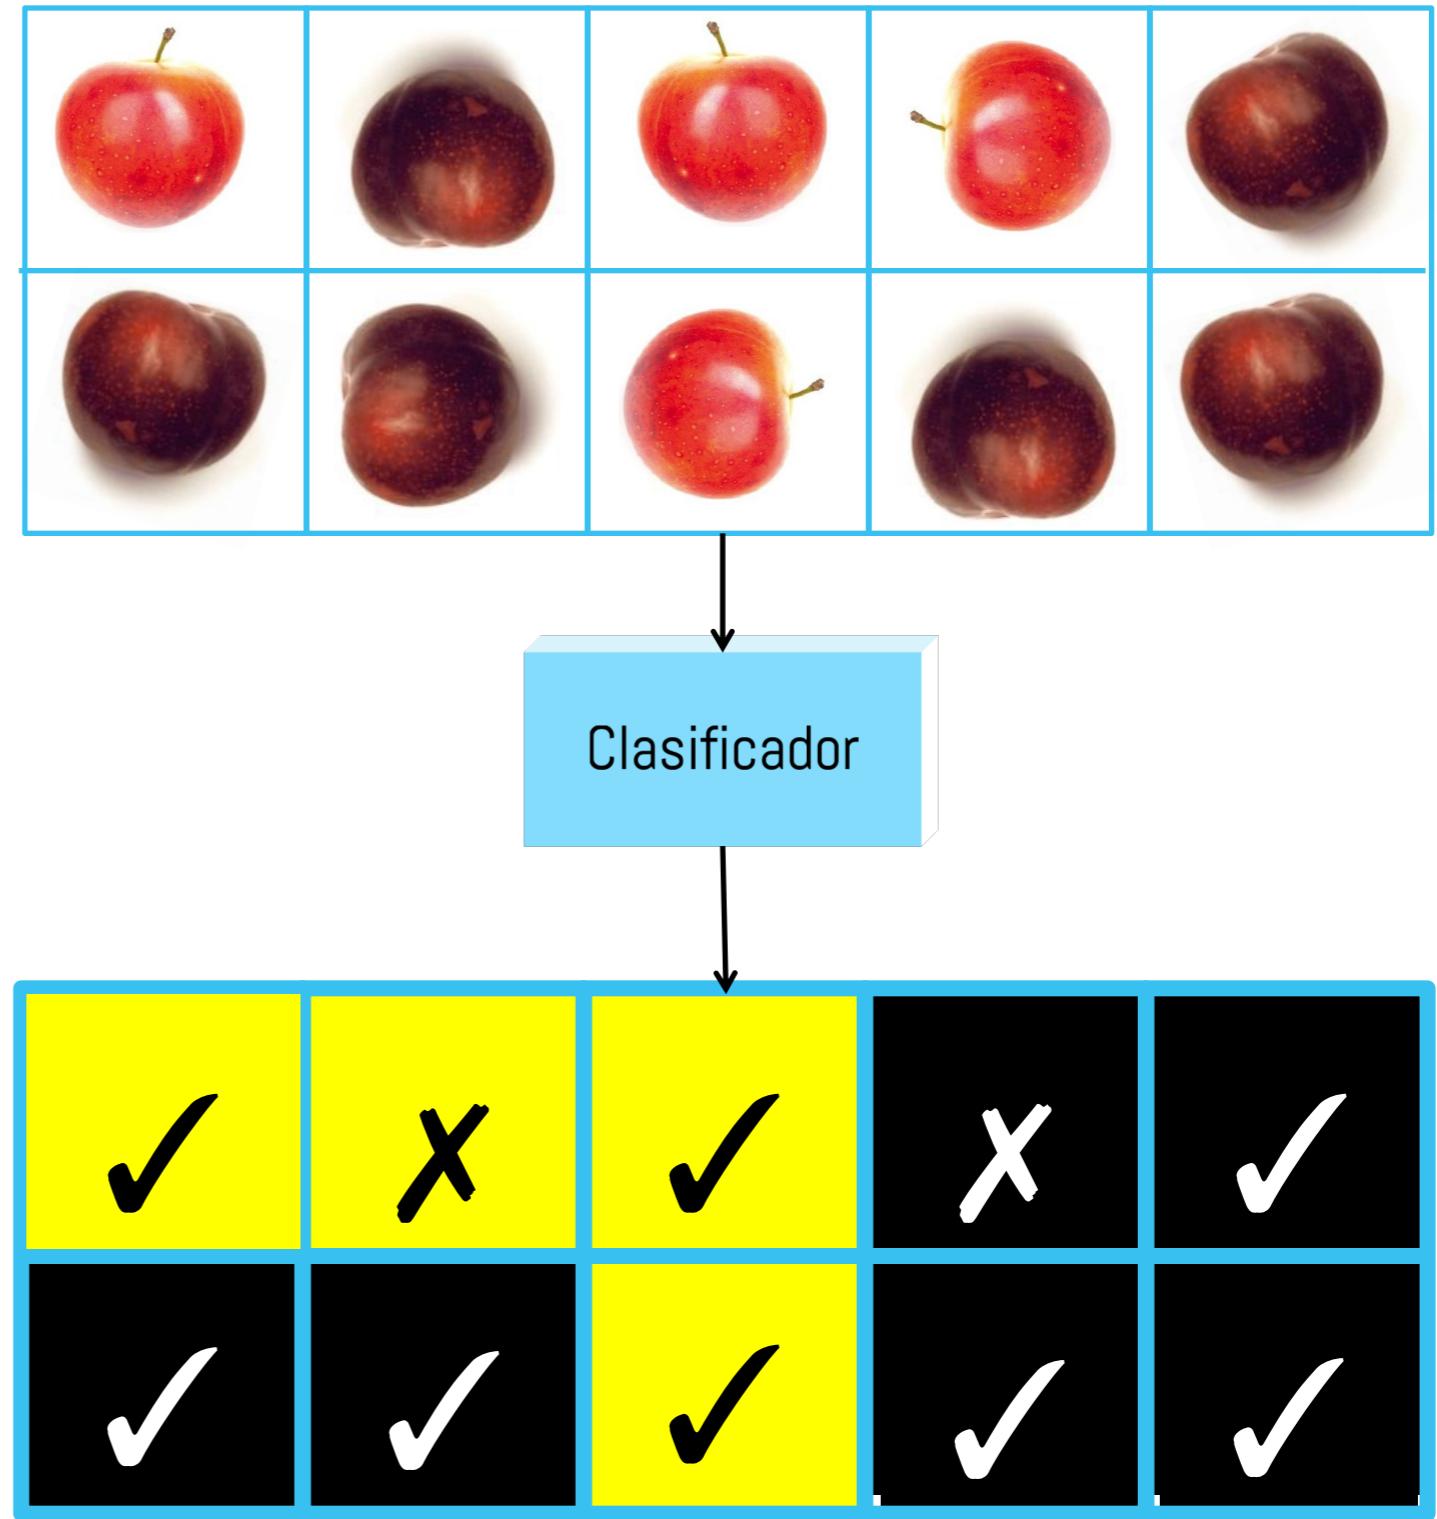
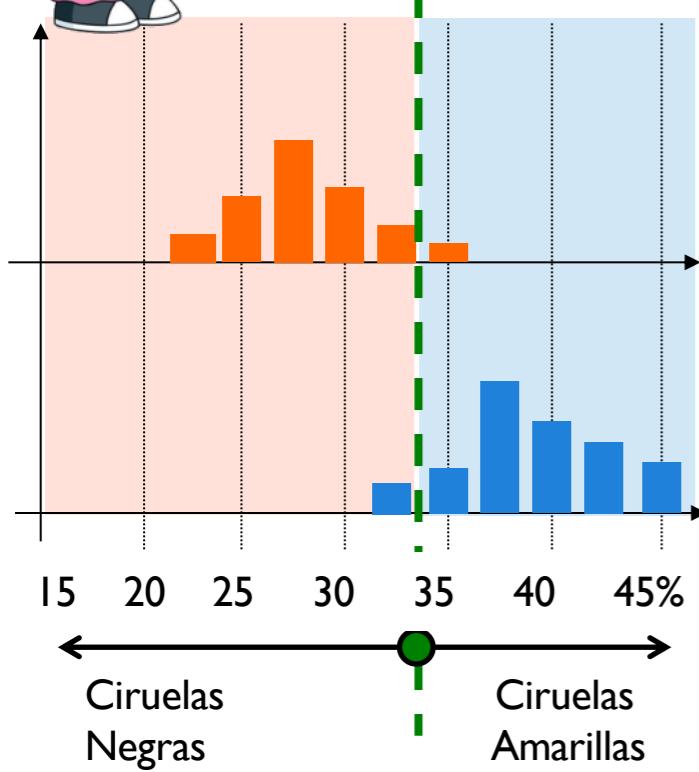


Línea de decisión

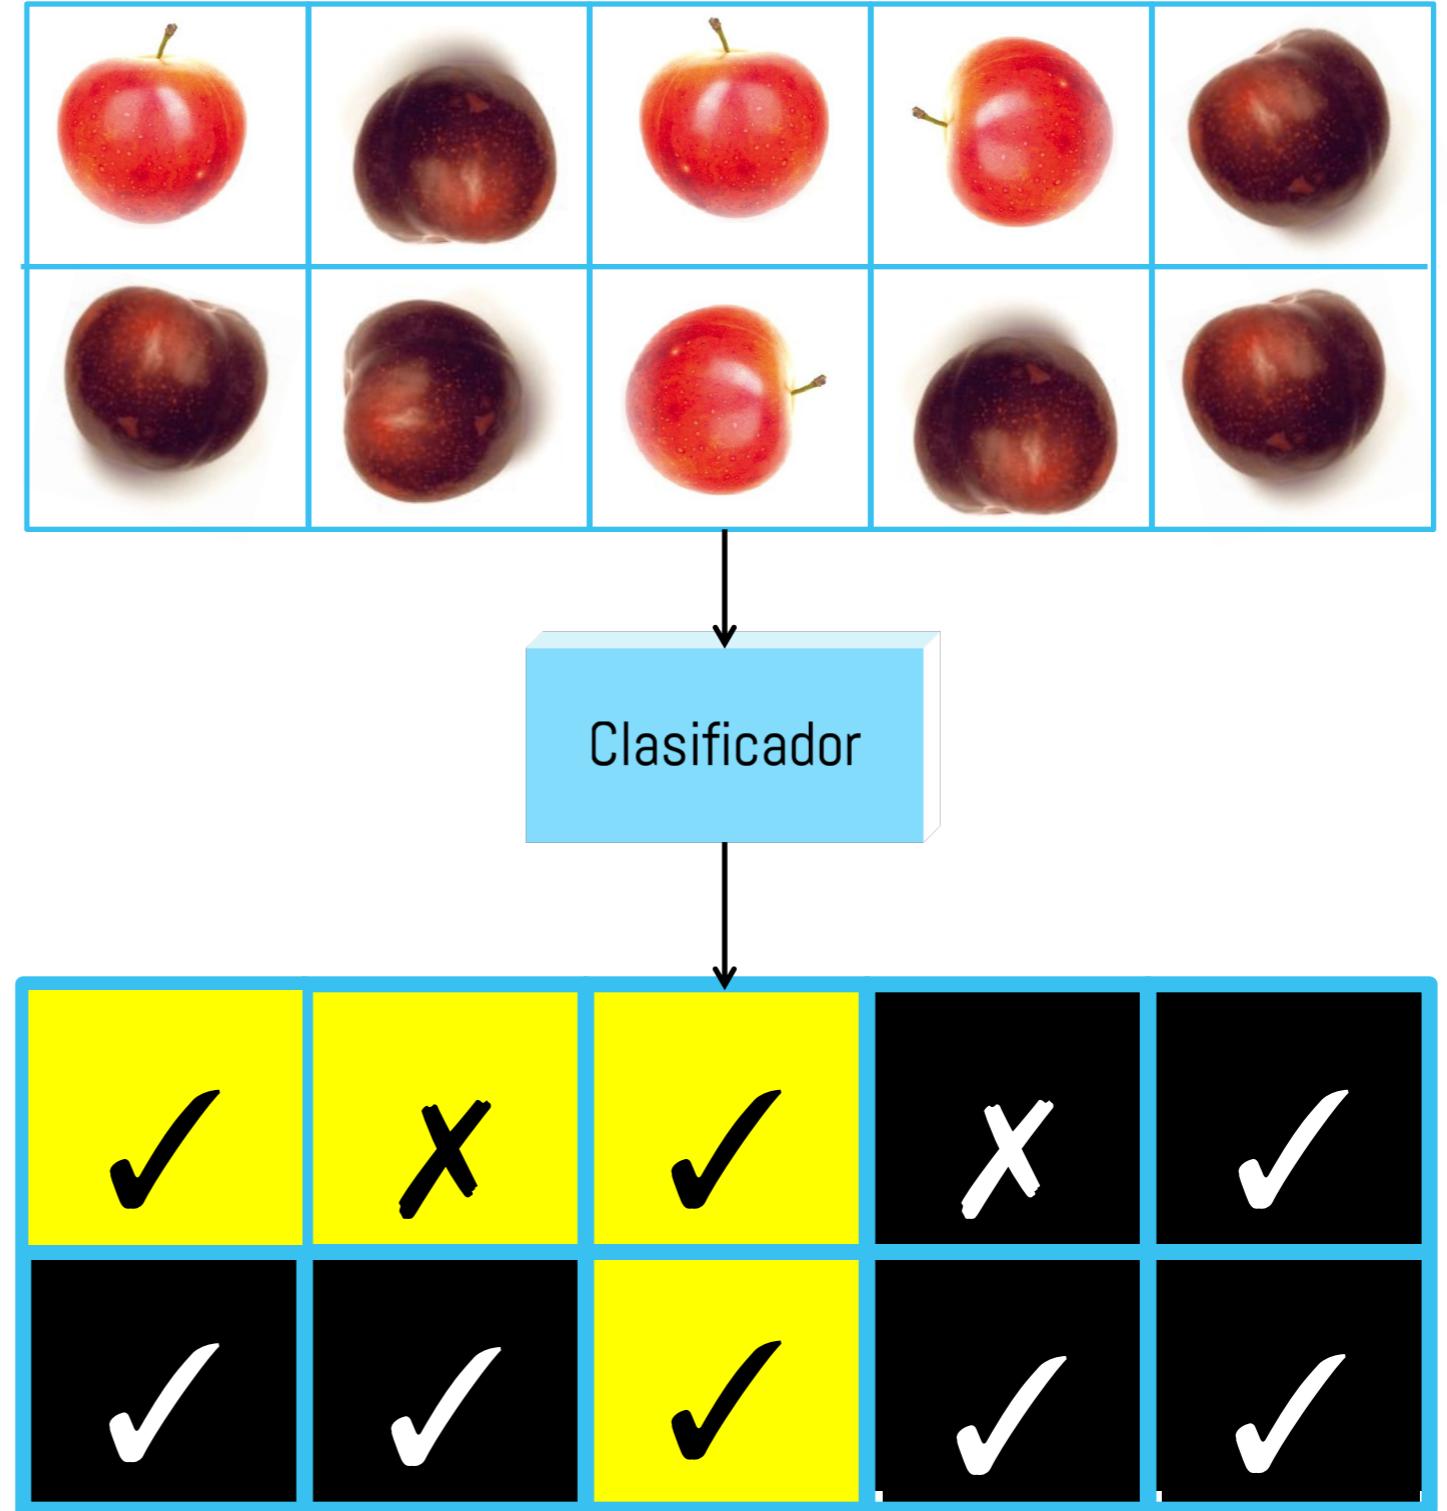
- Clasificación



Esta línea decisión implica que algunas ciruelas serán mal clasificadas

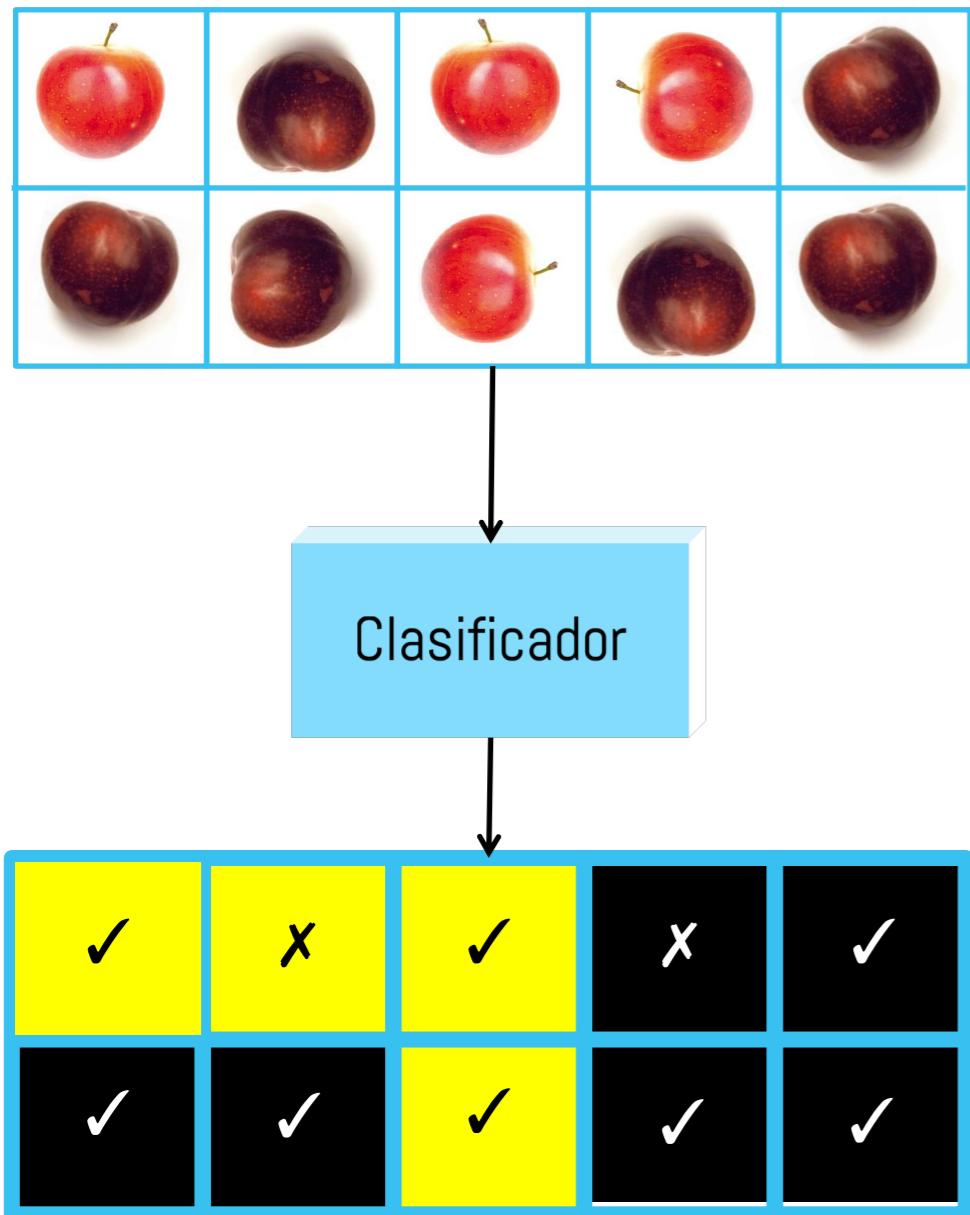


■ Clasificación



Clasificación

En esta etapa medimos el desempeño de la clasificación.

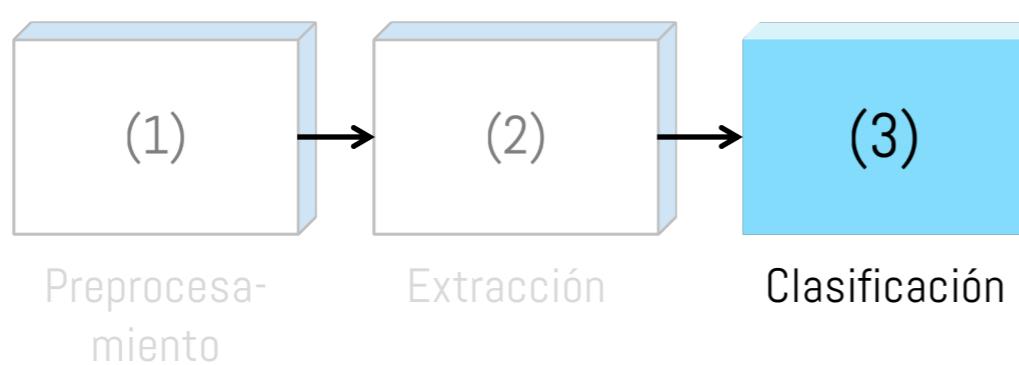
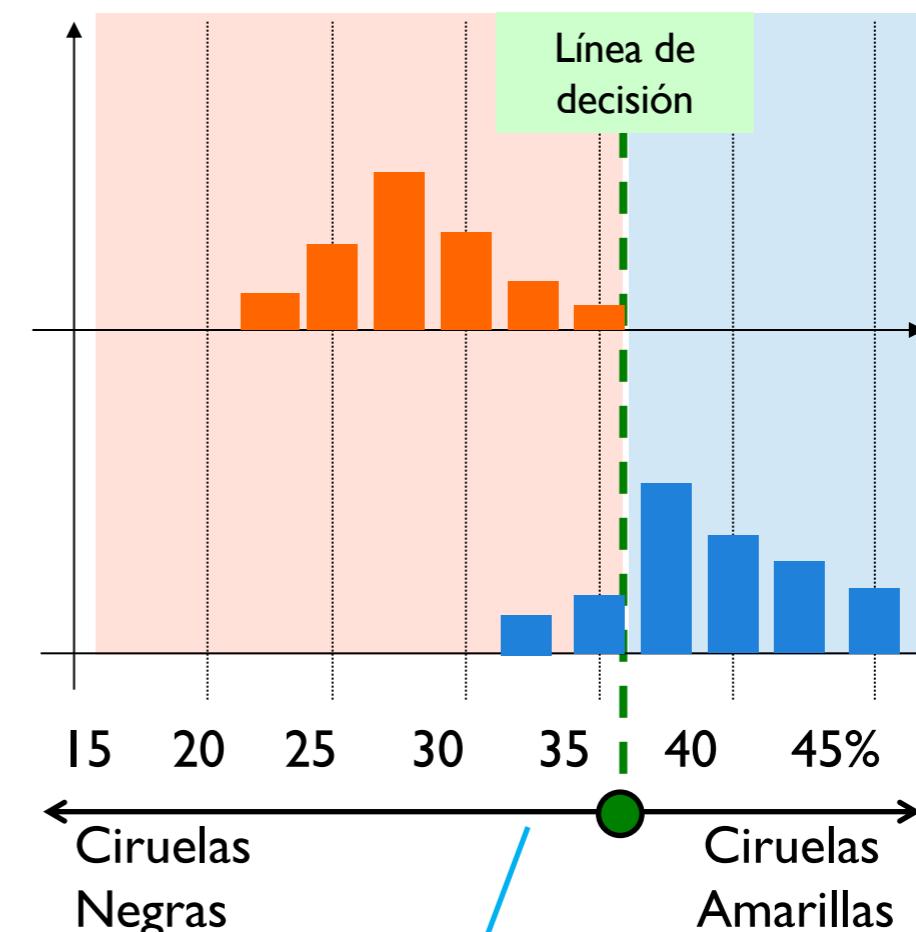
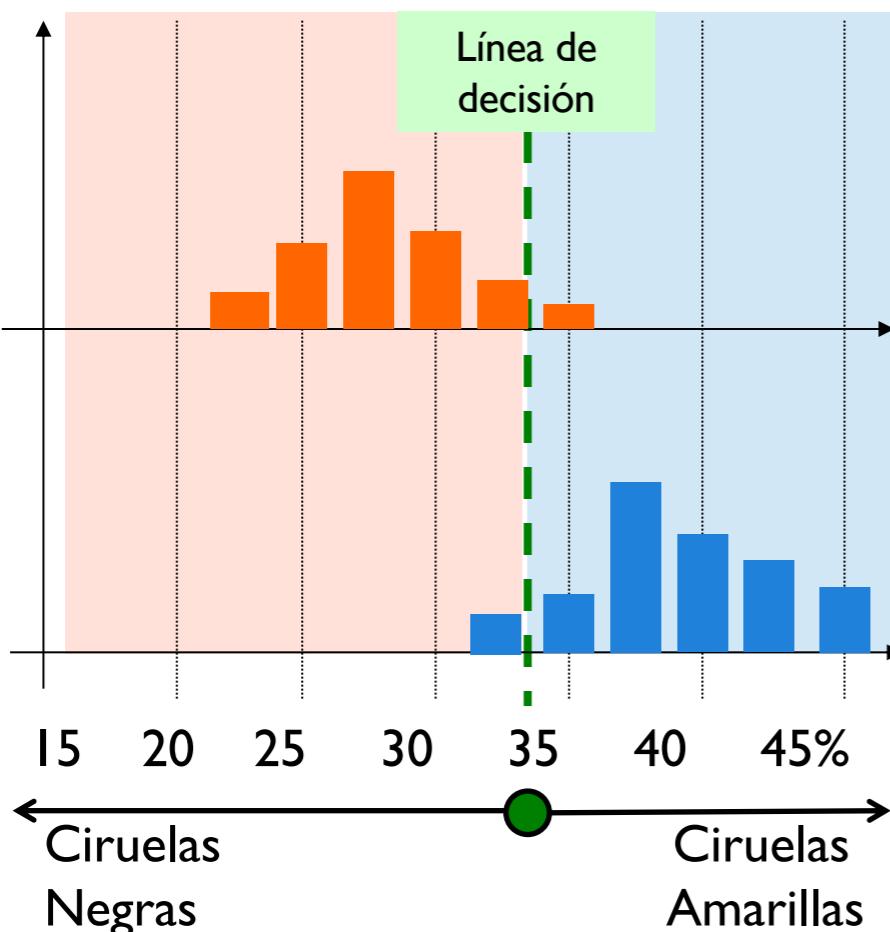


Clase	BIEN clasificadas	MAL clasificadas	Σ
Ciruela Amarilla	$T_1 = 3$	$F_1 = 1$	4
Ciruela Negra	$T_2 = 5$	$F_2 = 1$	6
Σ	8	2	10

$$N = \sum_{i=1}^m (T_i + F_i) \longrightarrow N = 10$$

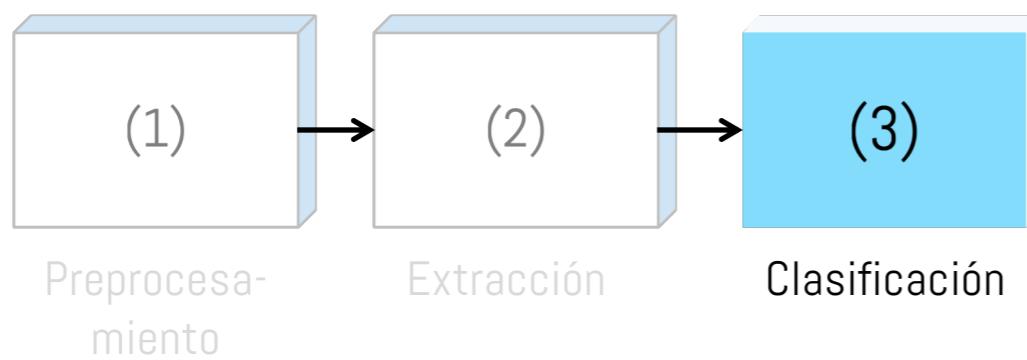
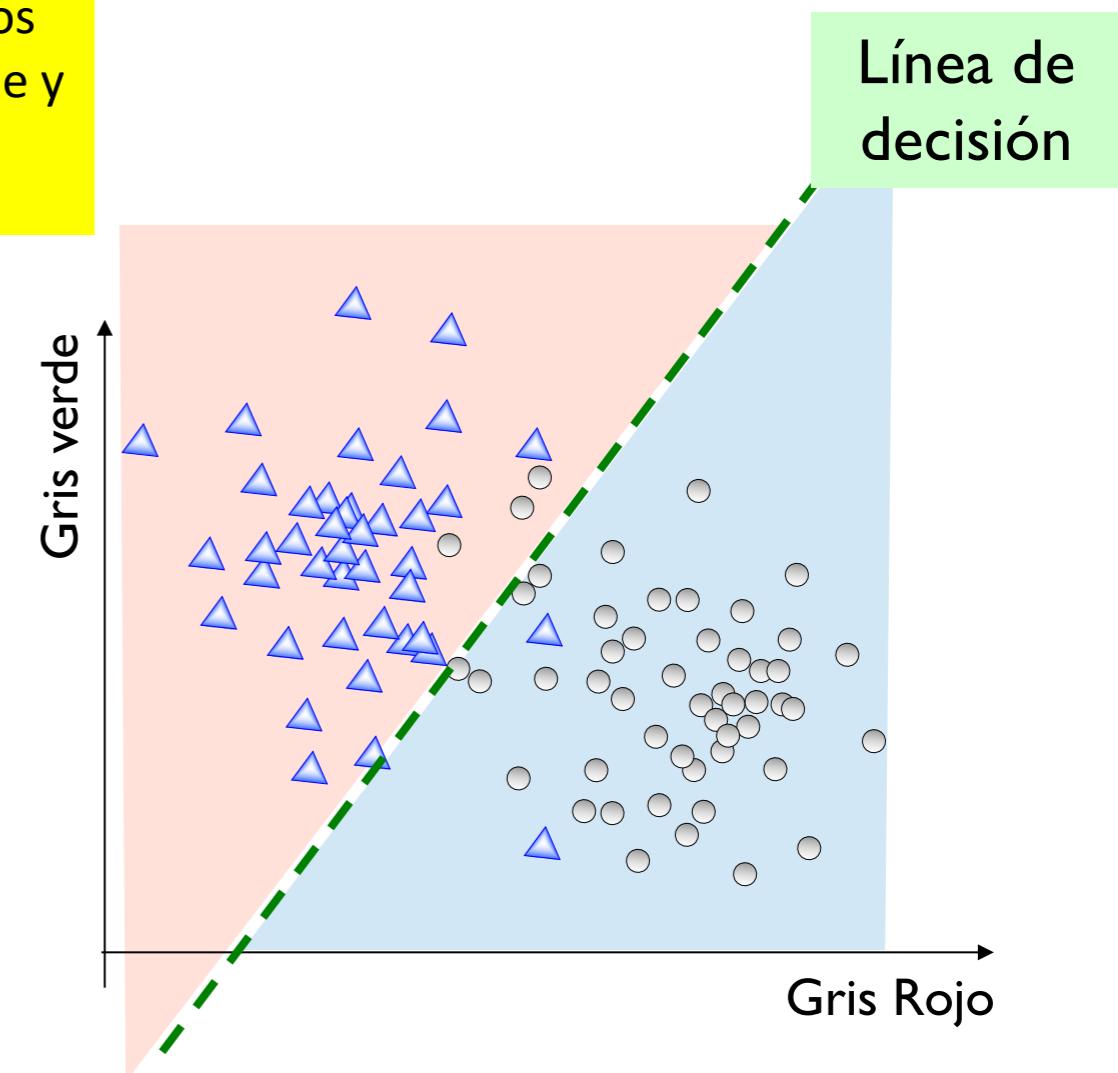
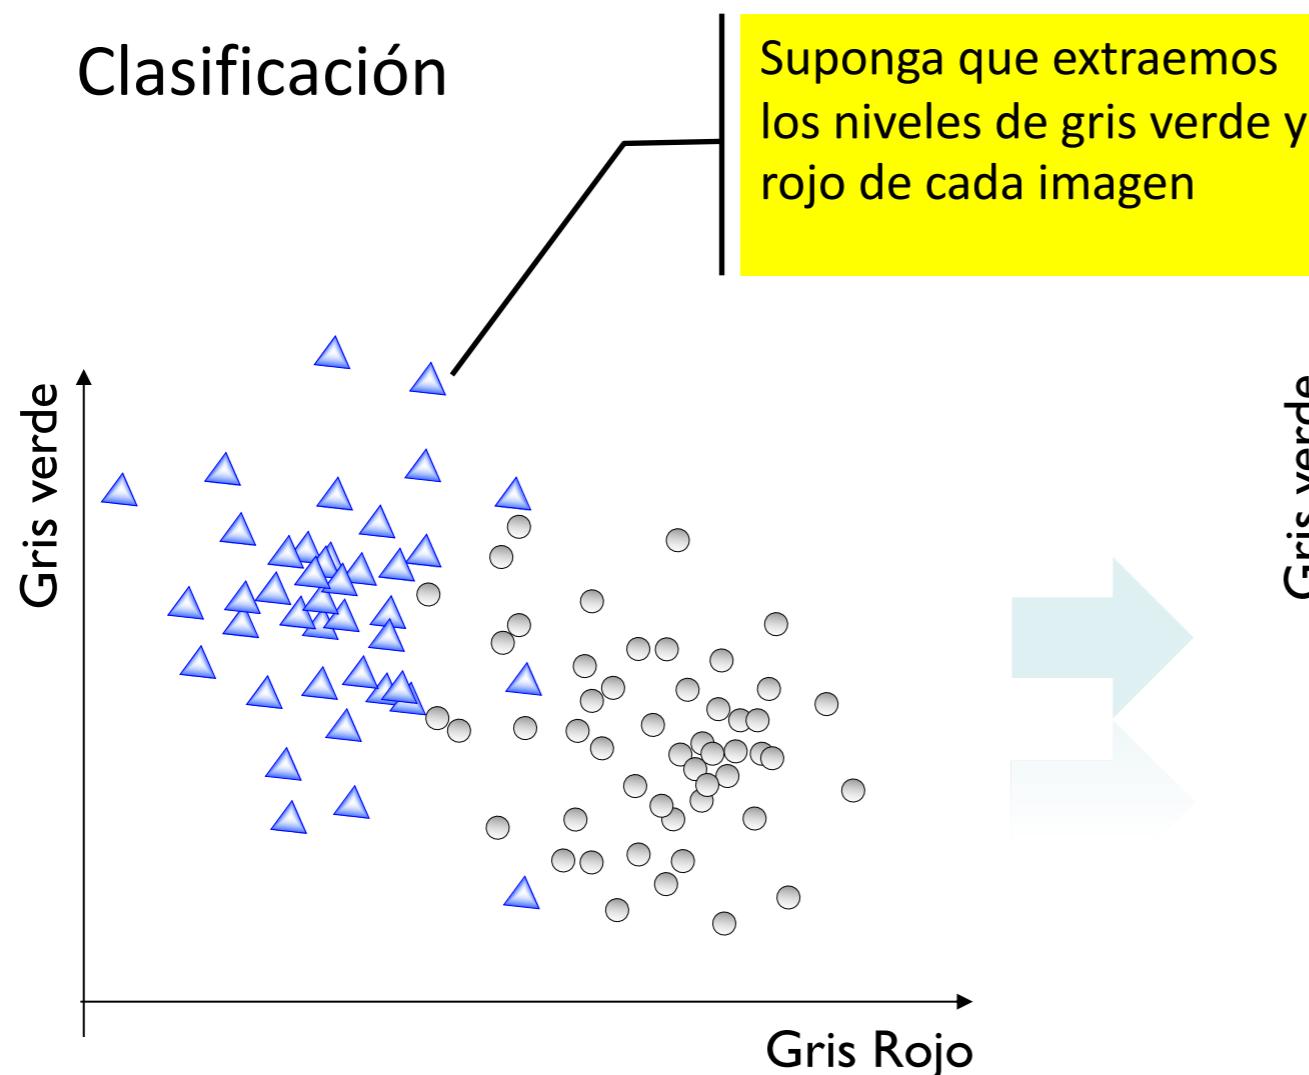
$$J = \frac{1}{N} \sum_{i=1}^m T_i \longrightarrow J = \frac{1}{10} (3 + 5) = 0.8$$

Clasificación



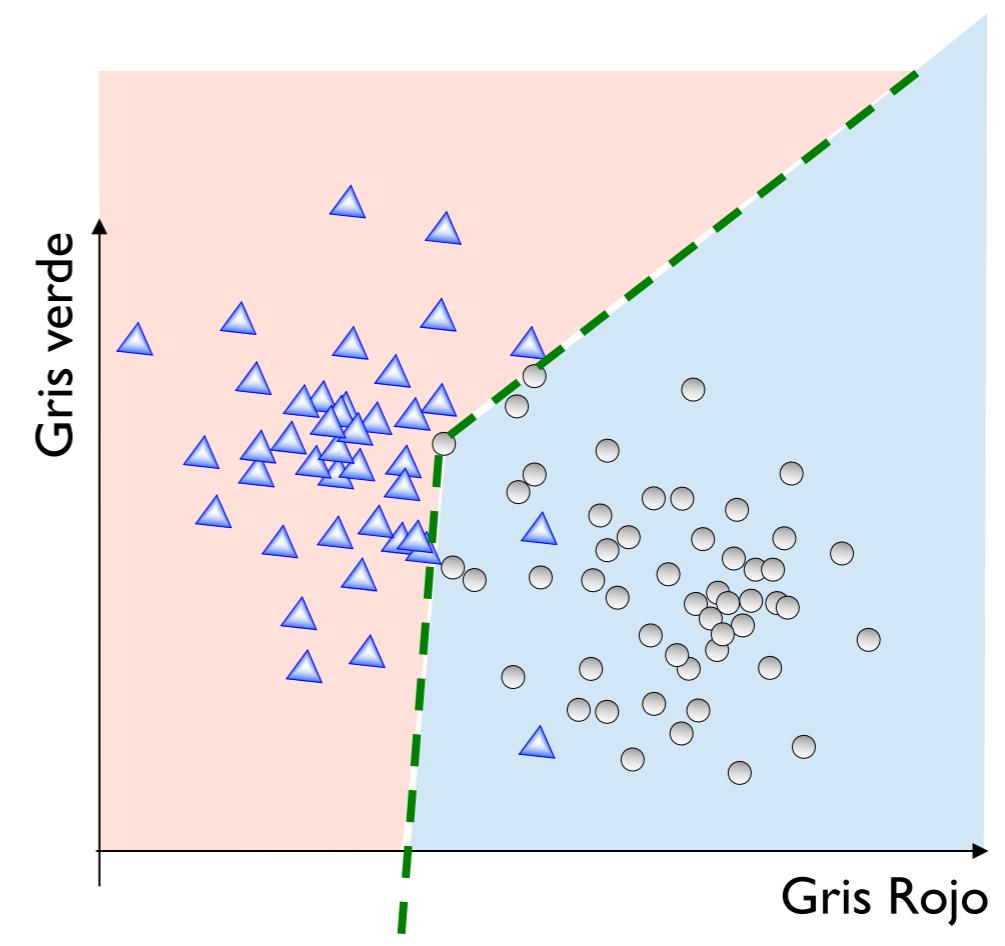
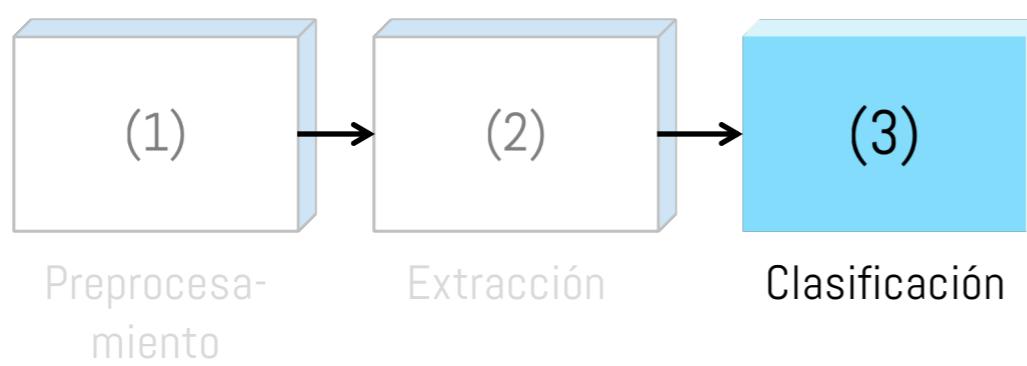
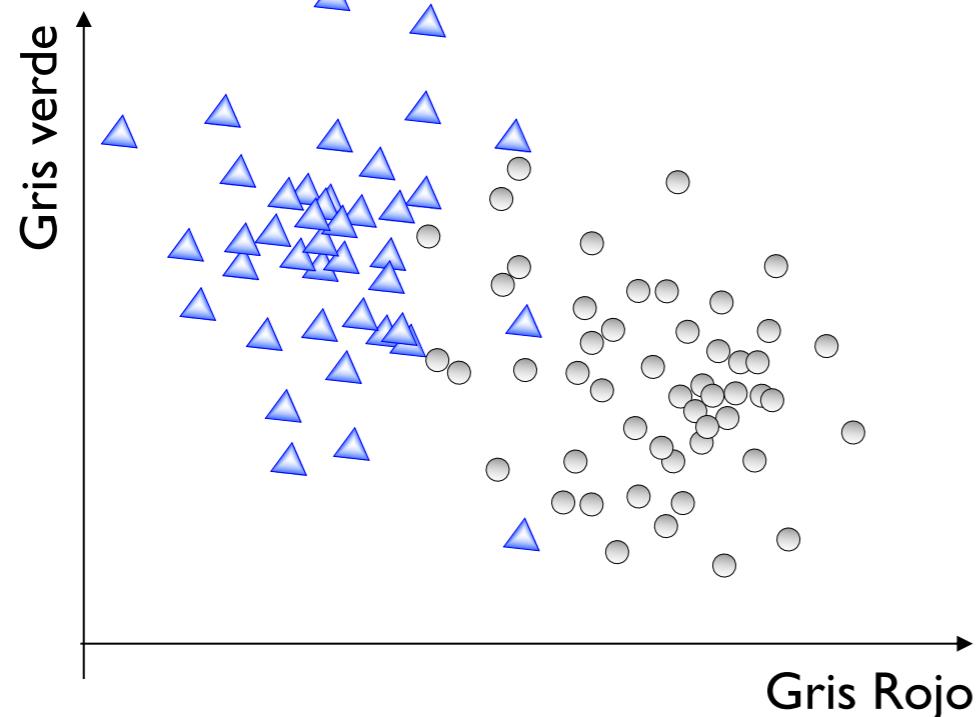
Si las **Ciruelas Negras** son más caras, es mejor seleccionarlas todas, a pesar que mal clasifiquemos **Ciruelas Amarillas**

Clasificación



Supongamos que tenemos dos clases en vez de una

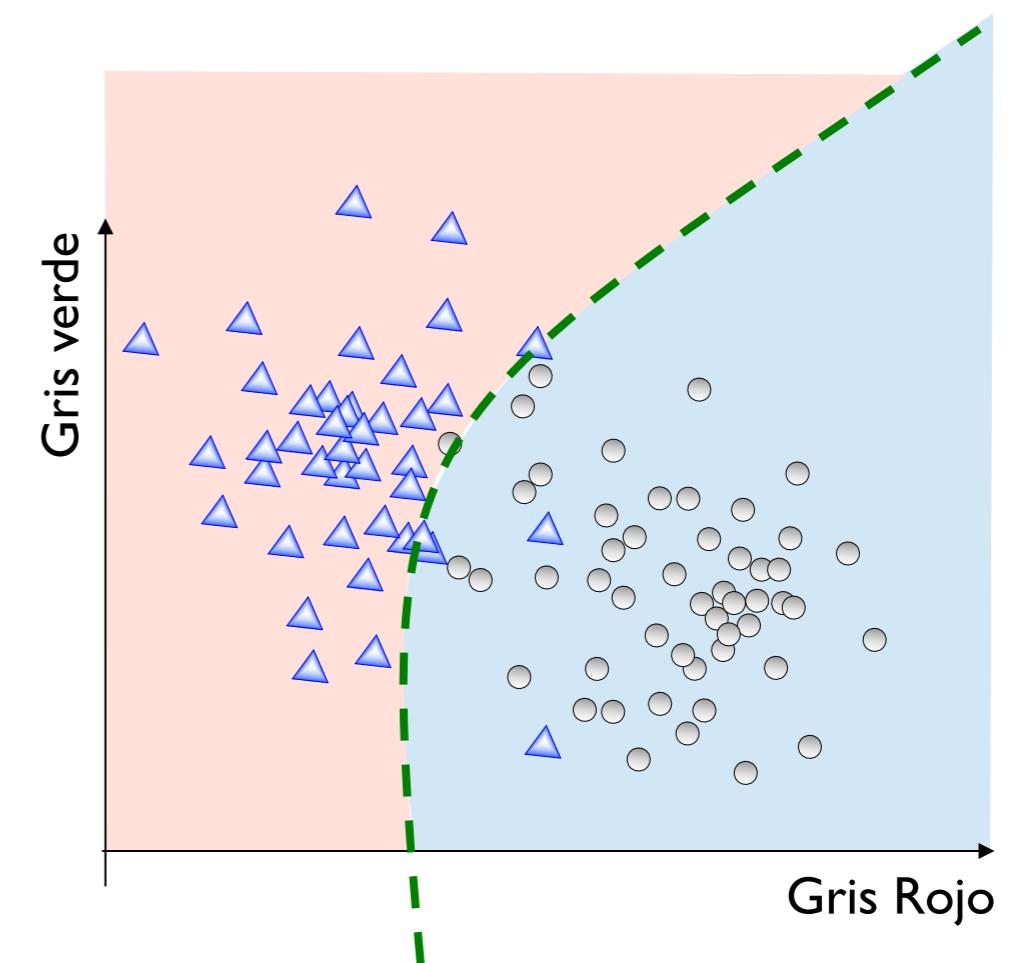
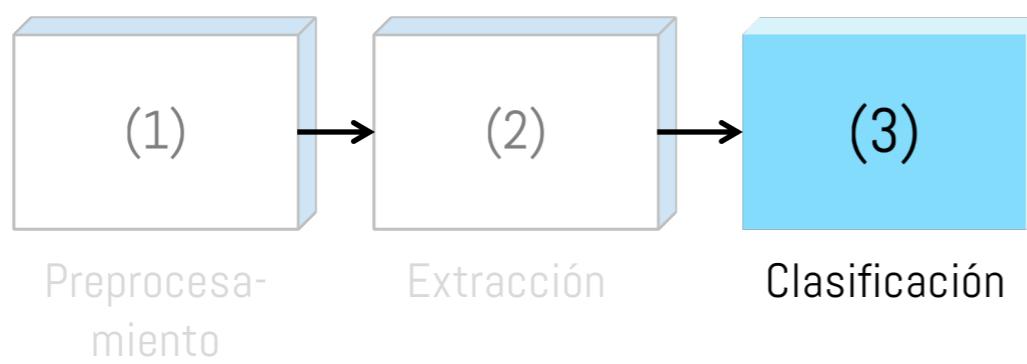
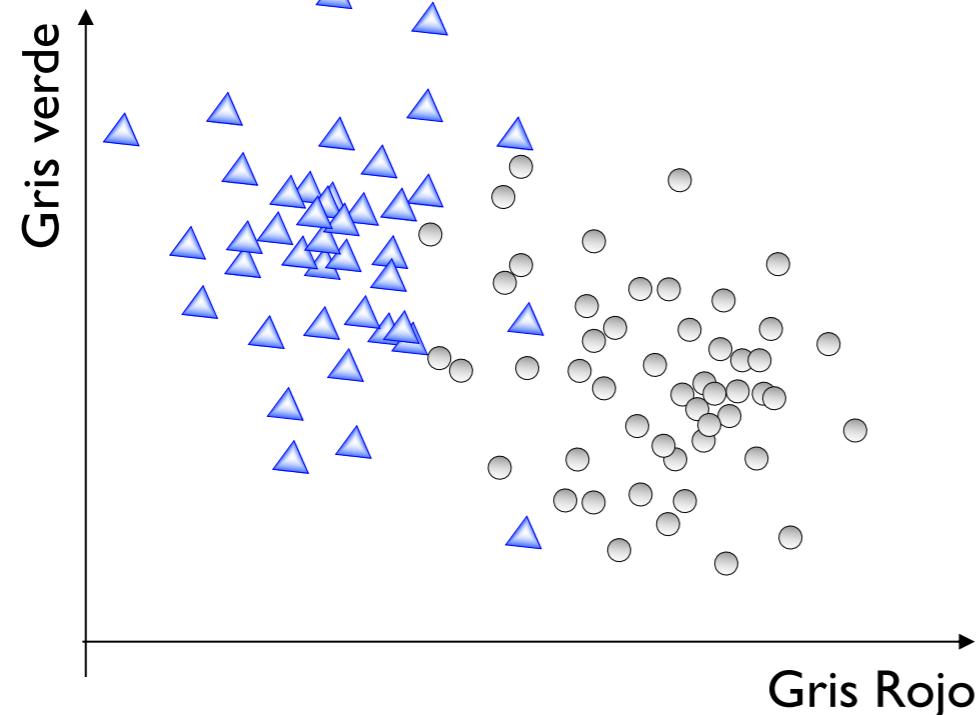
Clasificación



Línea de
decisión

Esta línea es menos
general que la anterior

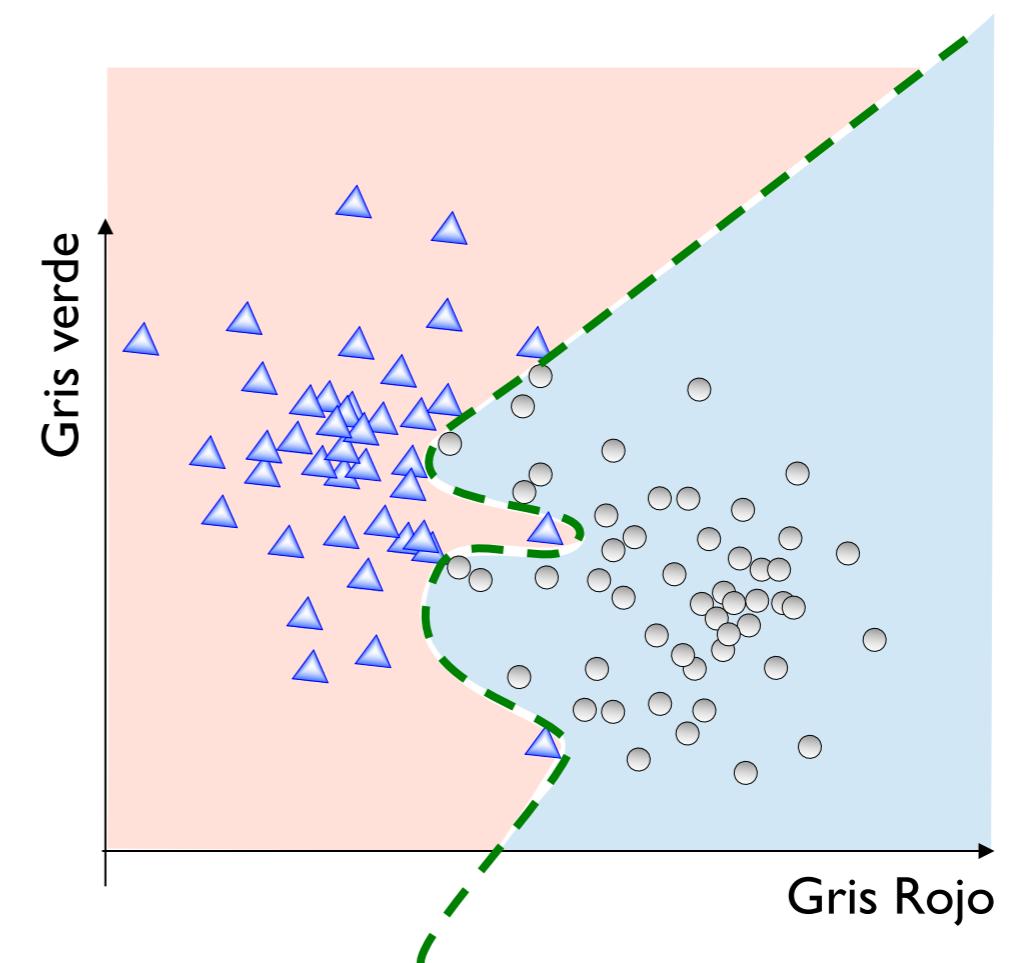
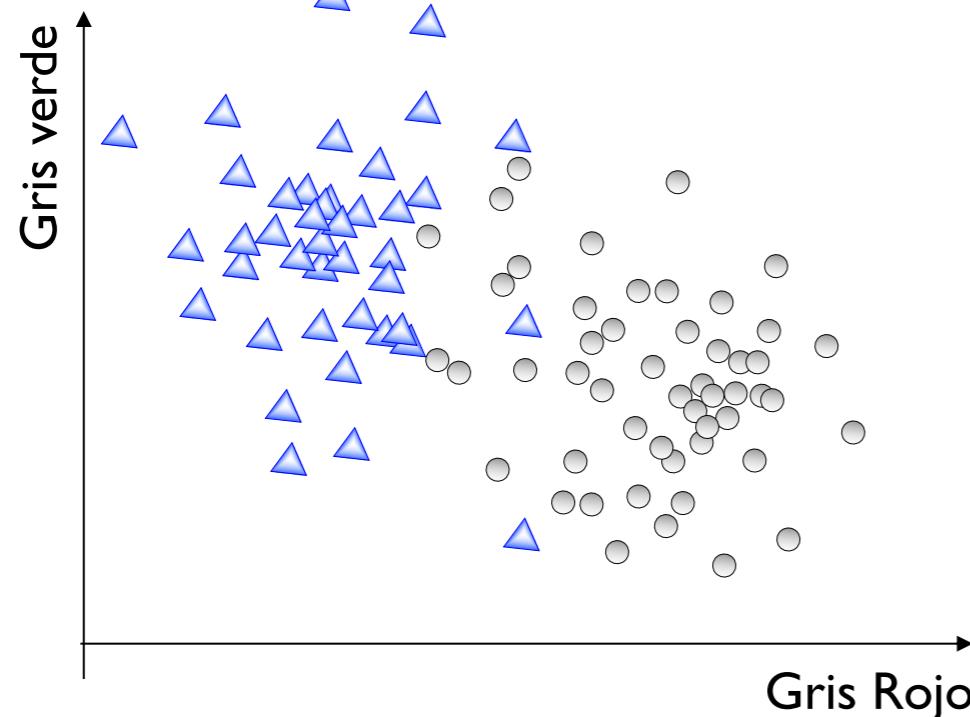
Clasificación



Línea de
decisión

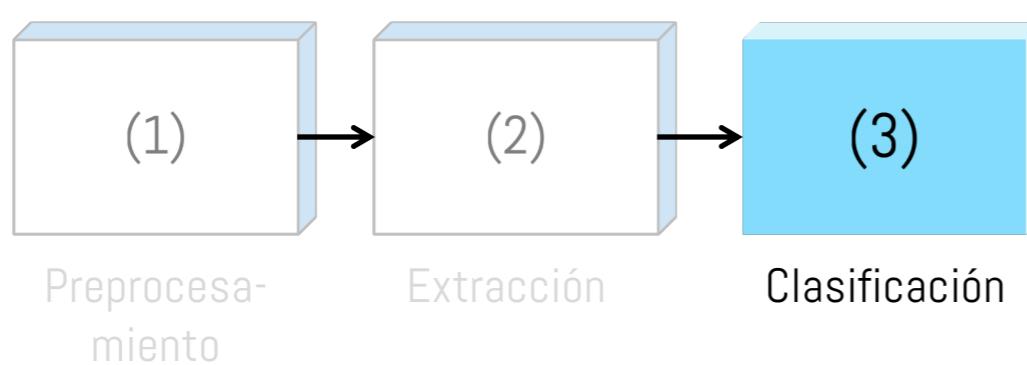
Esta línea responde
a una función

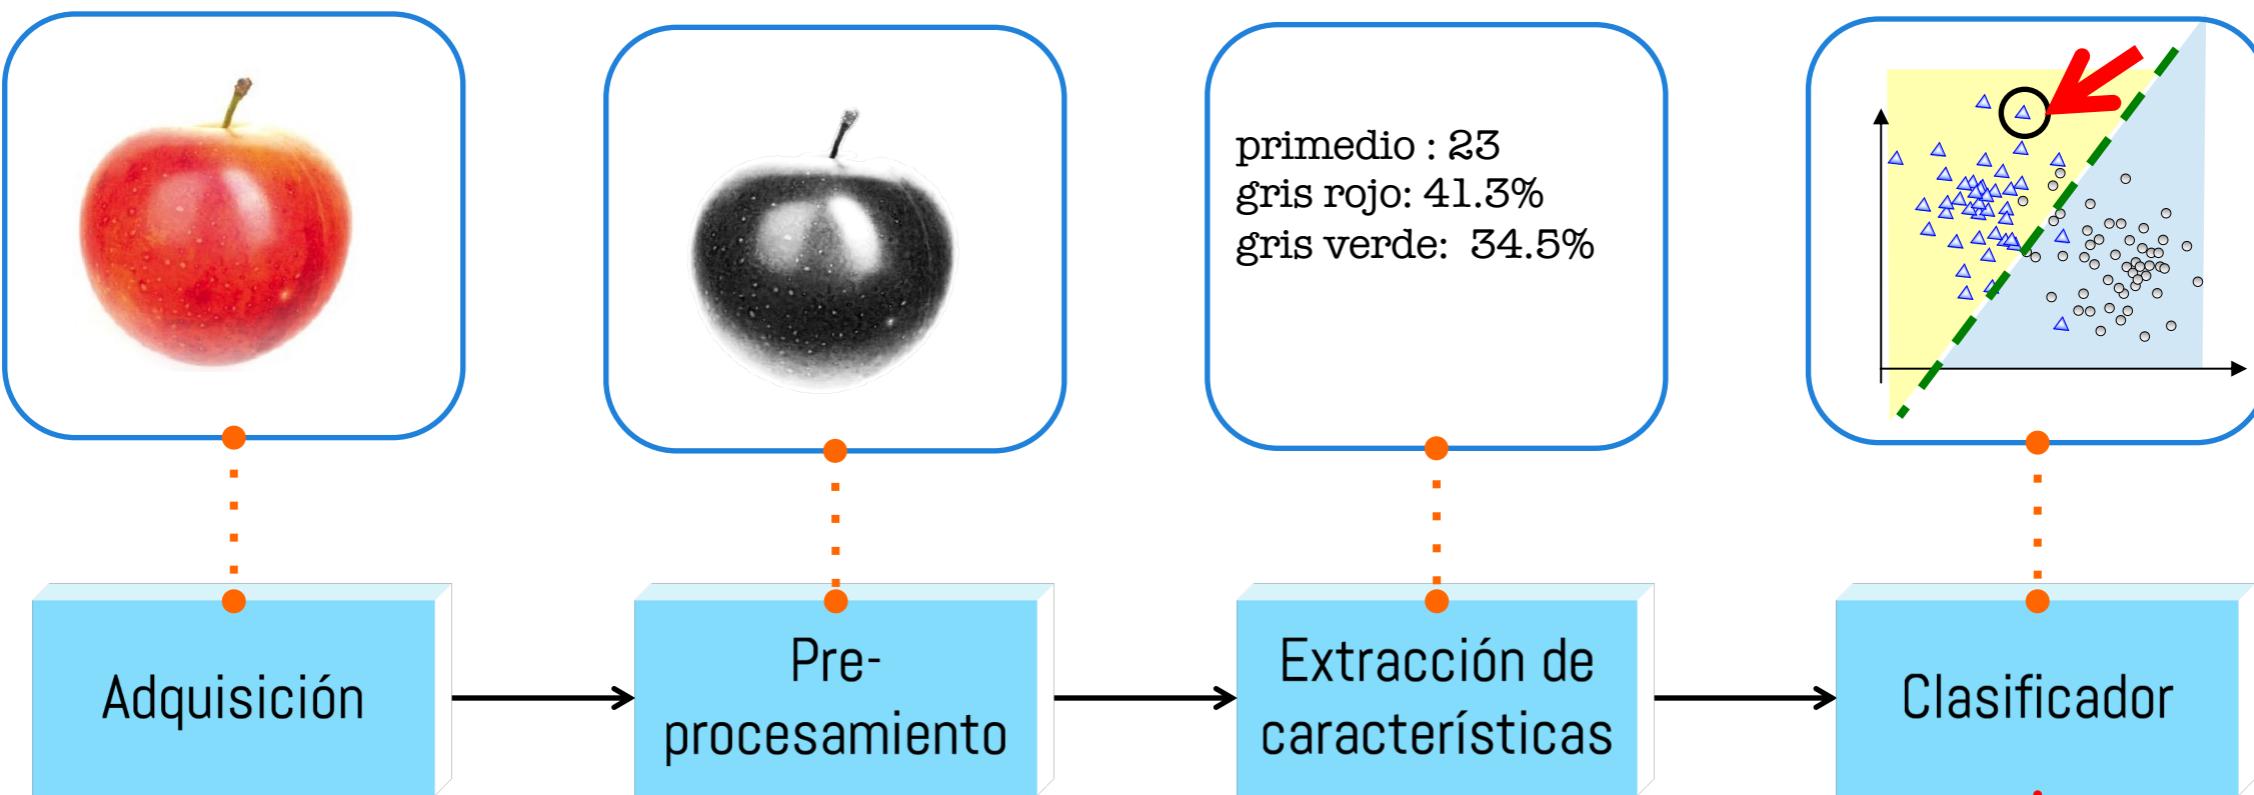
Clasificación



Línea de
decisión

SOBRE
ENTRENAMIENTO!!
muy muy malo





RESULTADO:

*Es ciruela
amarilla*



Voilà. Este es el proceso general del reconocimiento de patrones (machine learning), que simple, no?



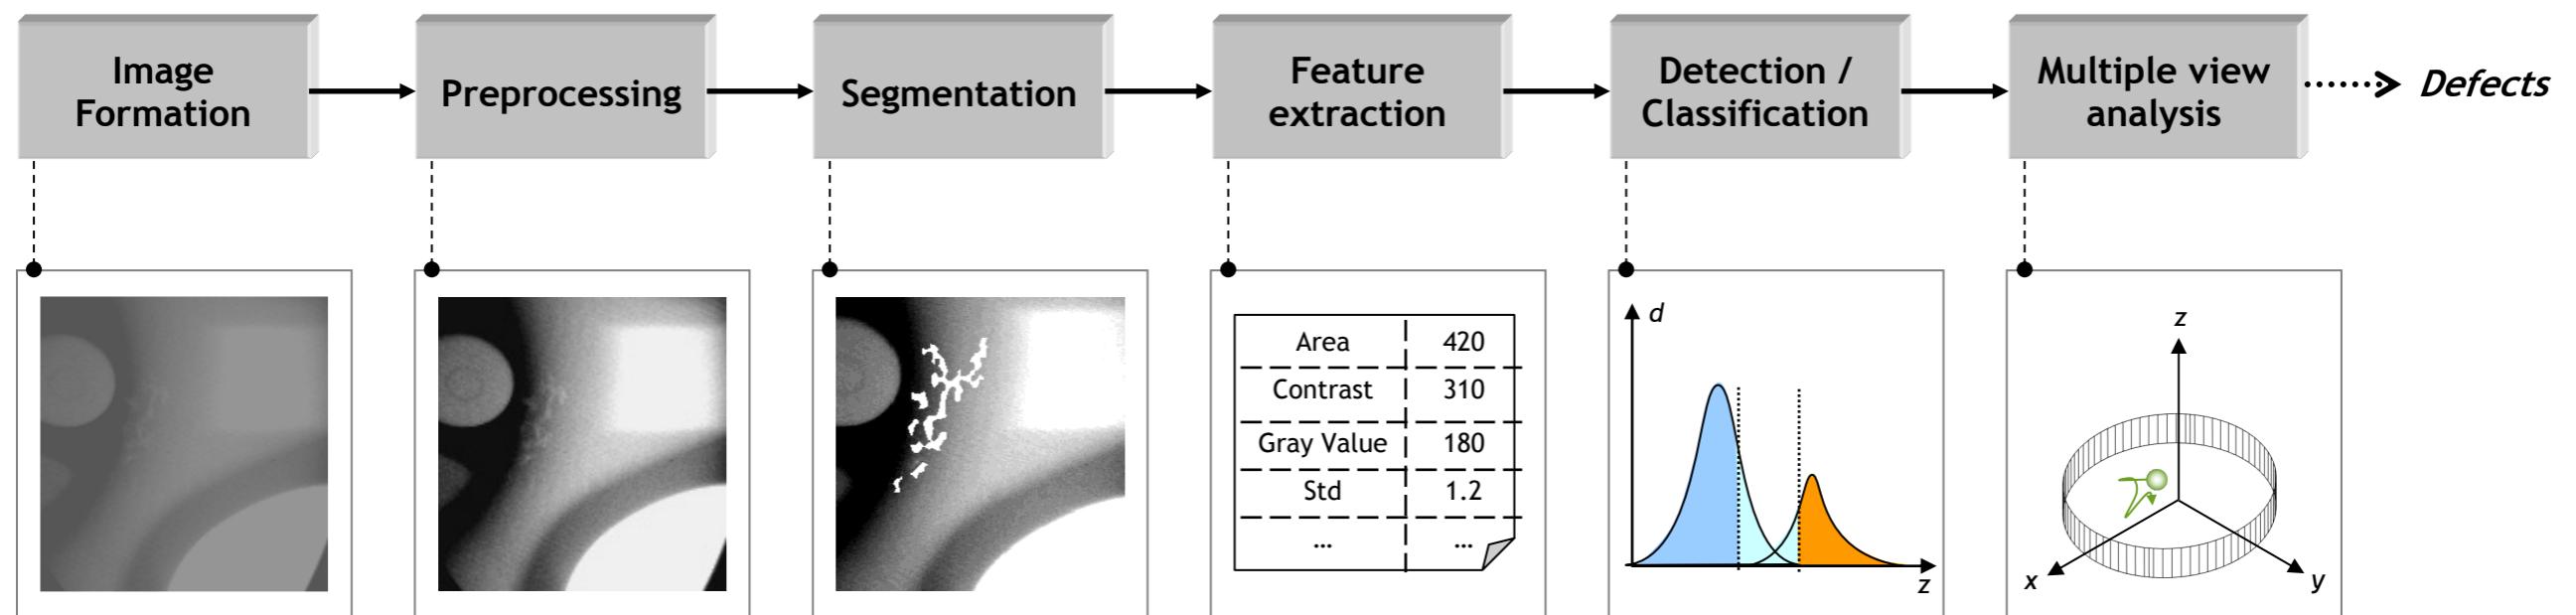
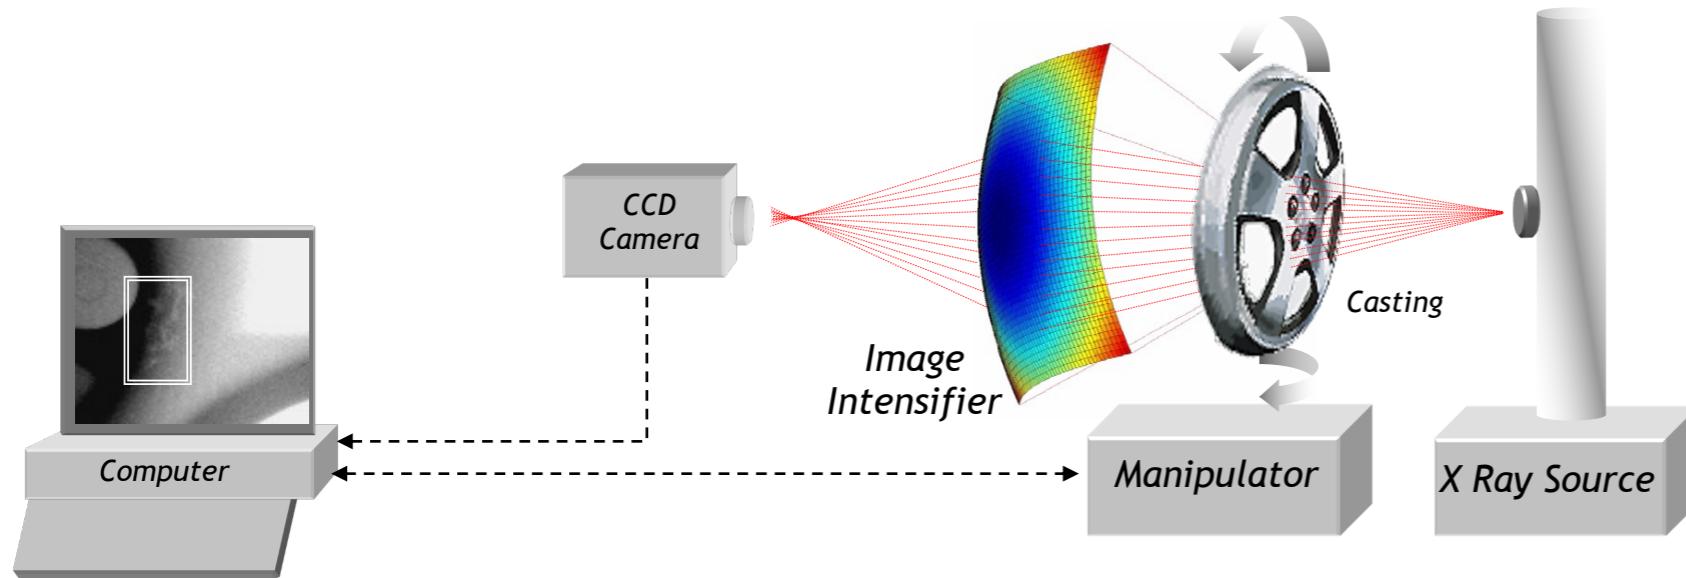


DARPA Visual Media Reasoning VMR

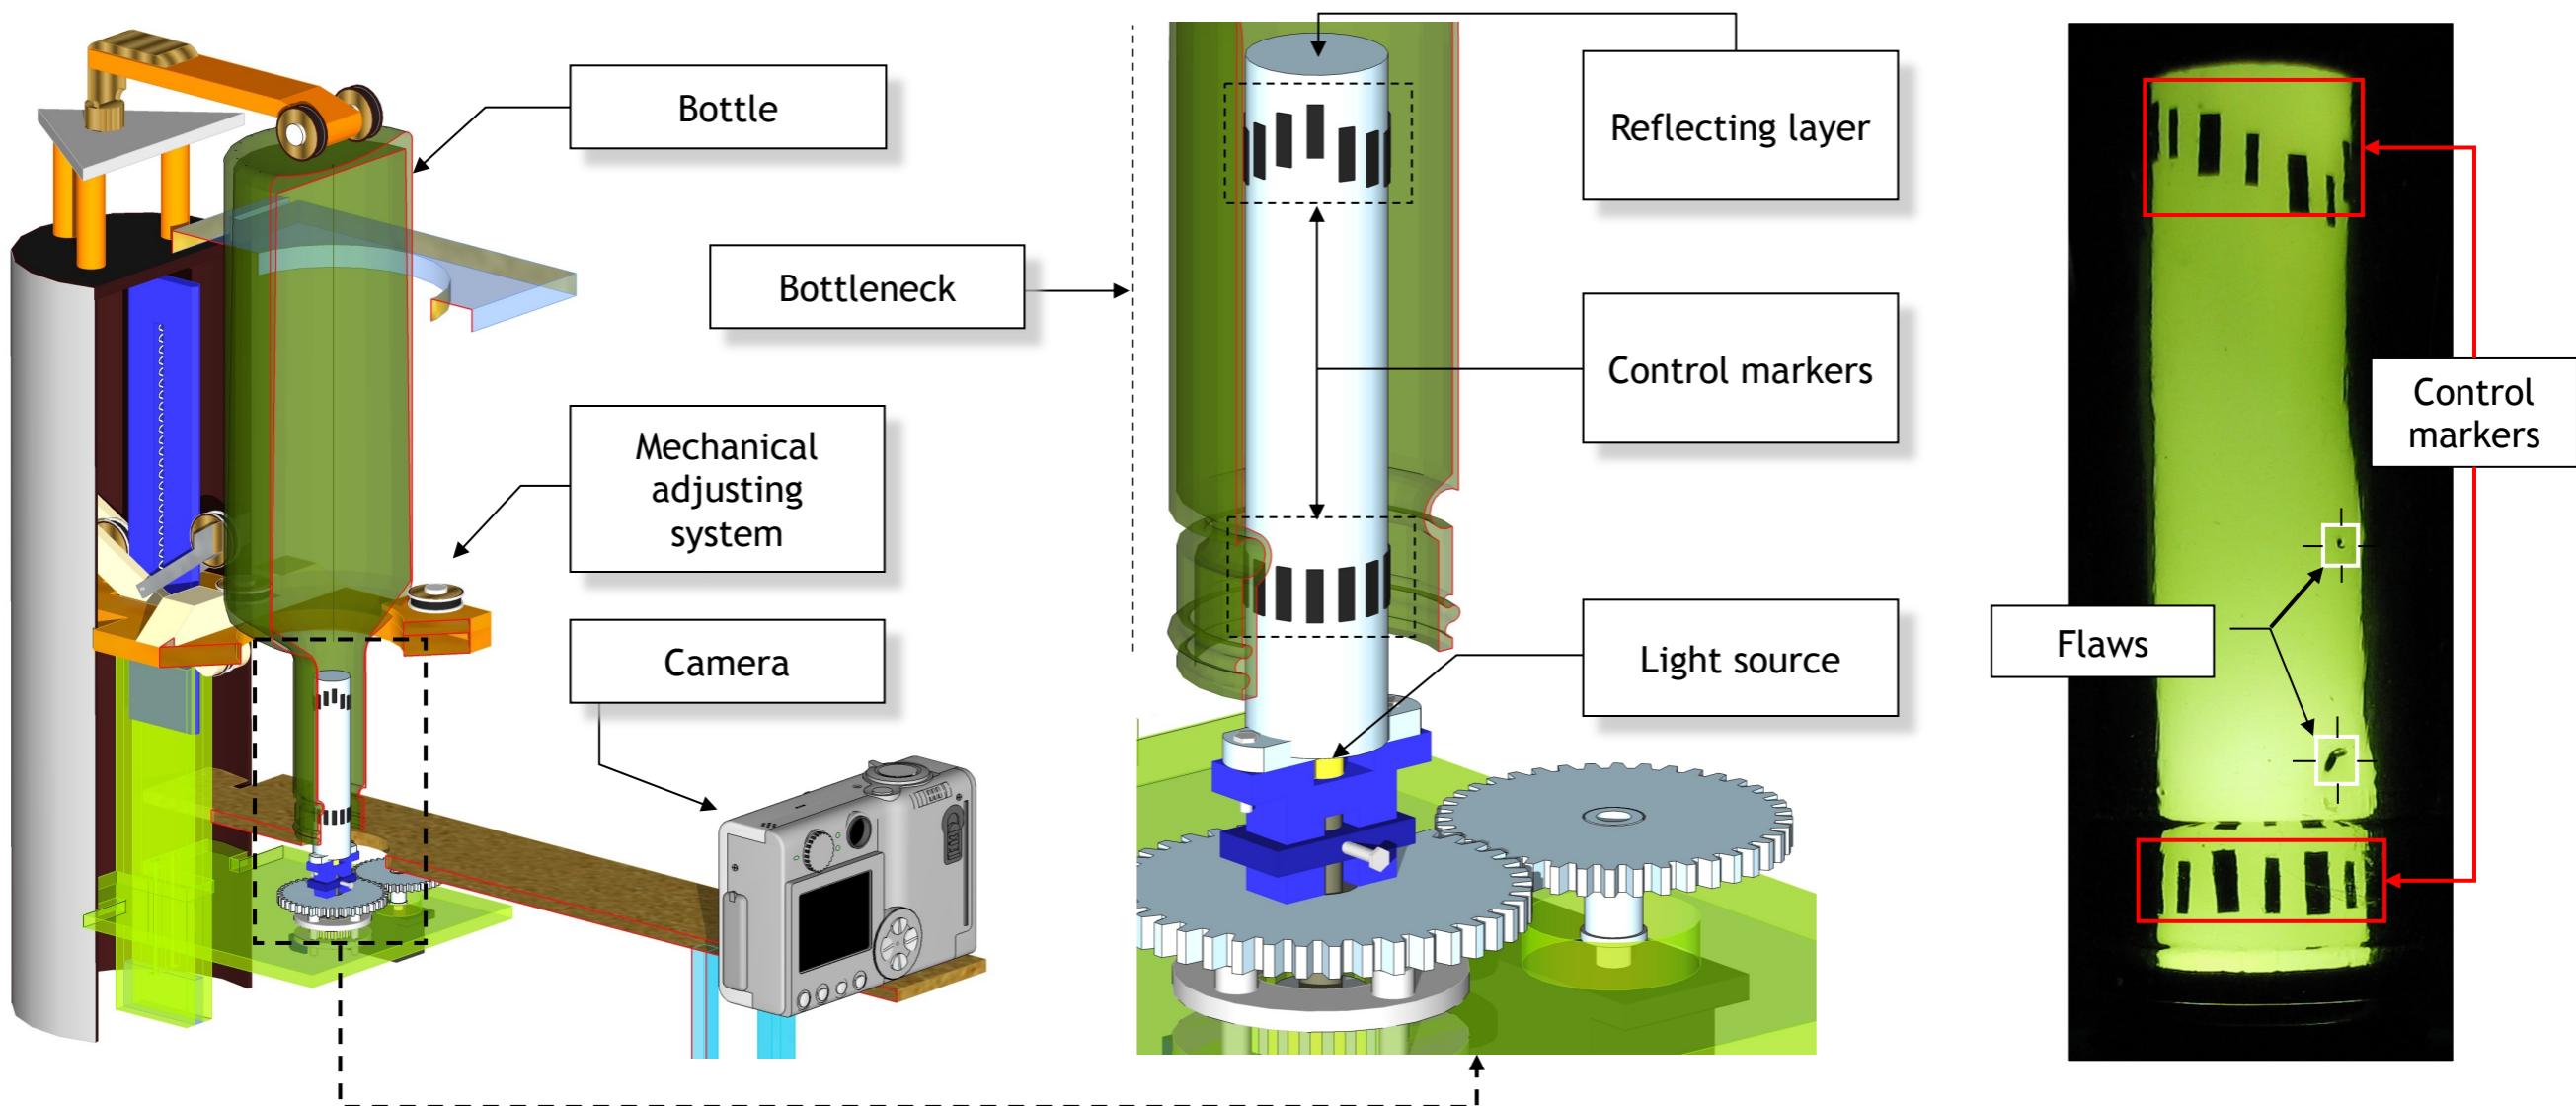
- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
 - Panorama general
 - Machine Learning (en acción)
 - Big Data
 - Ejemplos



Sistema de visión por computador

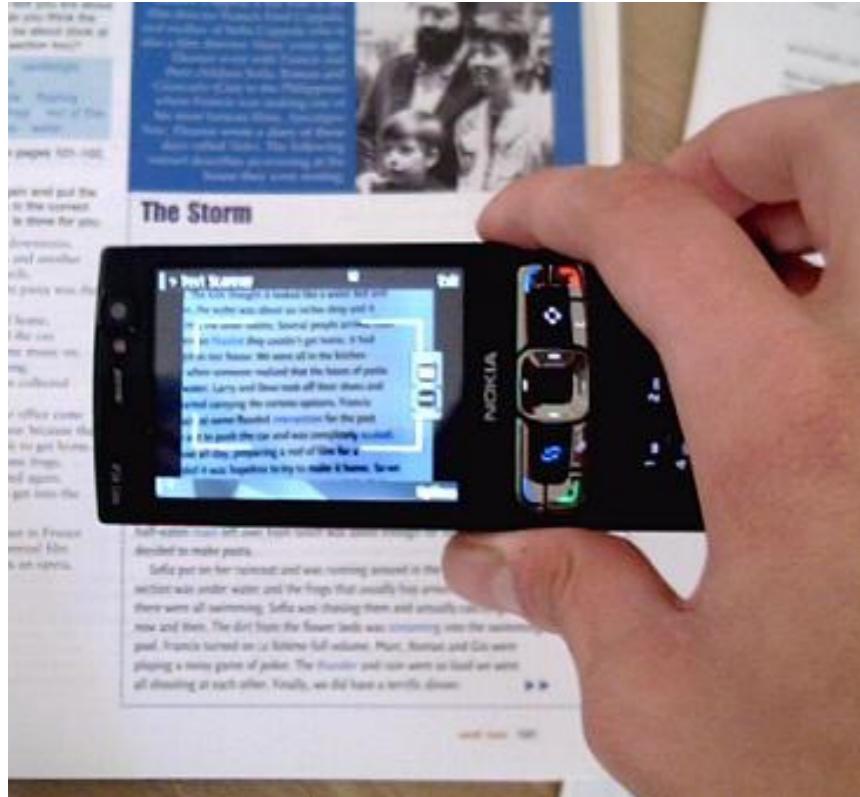


Sistema de visión por computador



Prototipo de inspección de botellas.
(Desarrollado por M.Carrasco, 2008)

Aplicaciones con imágenes



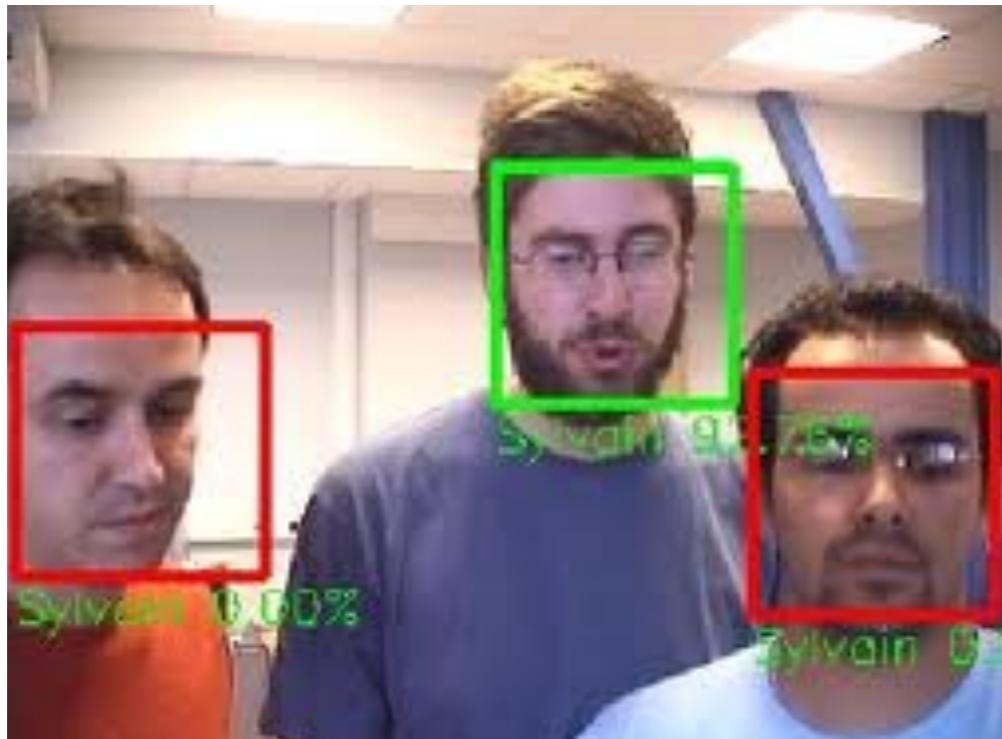
Reconocimiento óptico de caracteres (OCR)



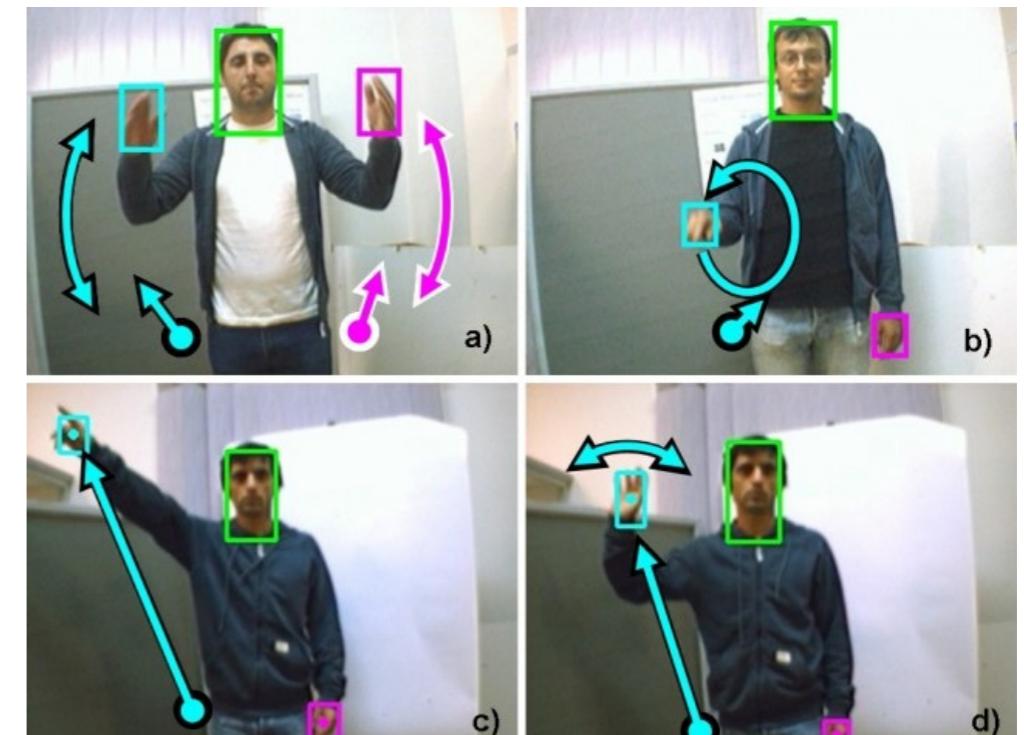
Reconocimiento de huellas digitales



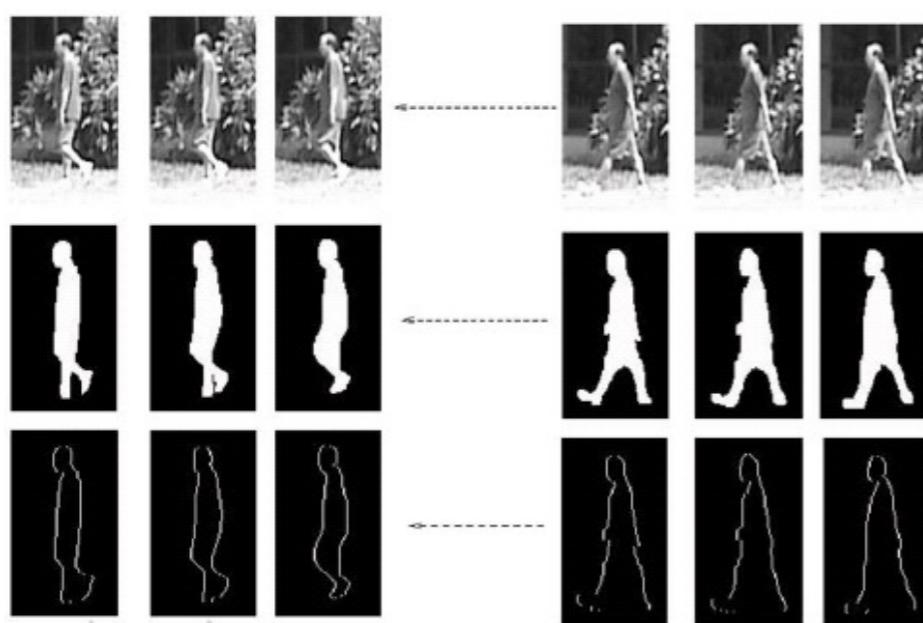
Reconocimiento de del iris



Reconocimiento de caras



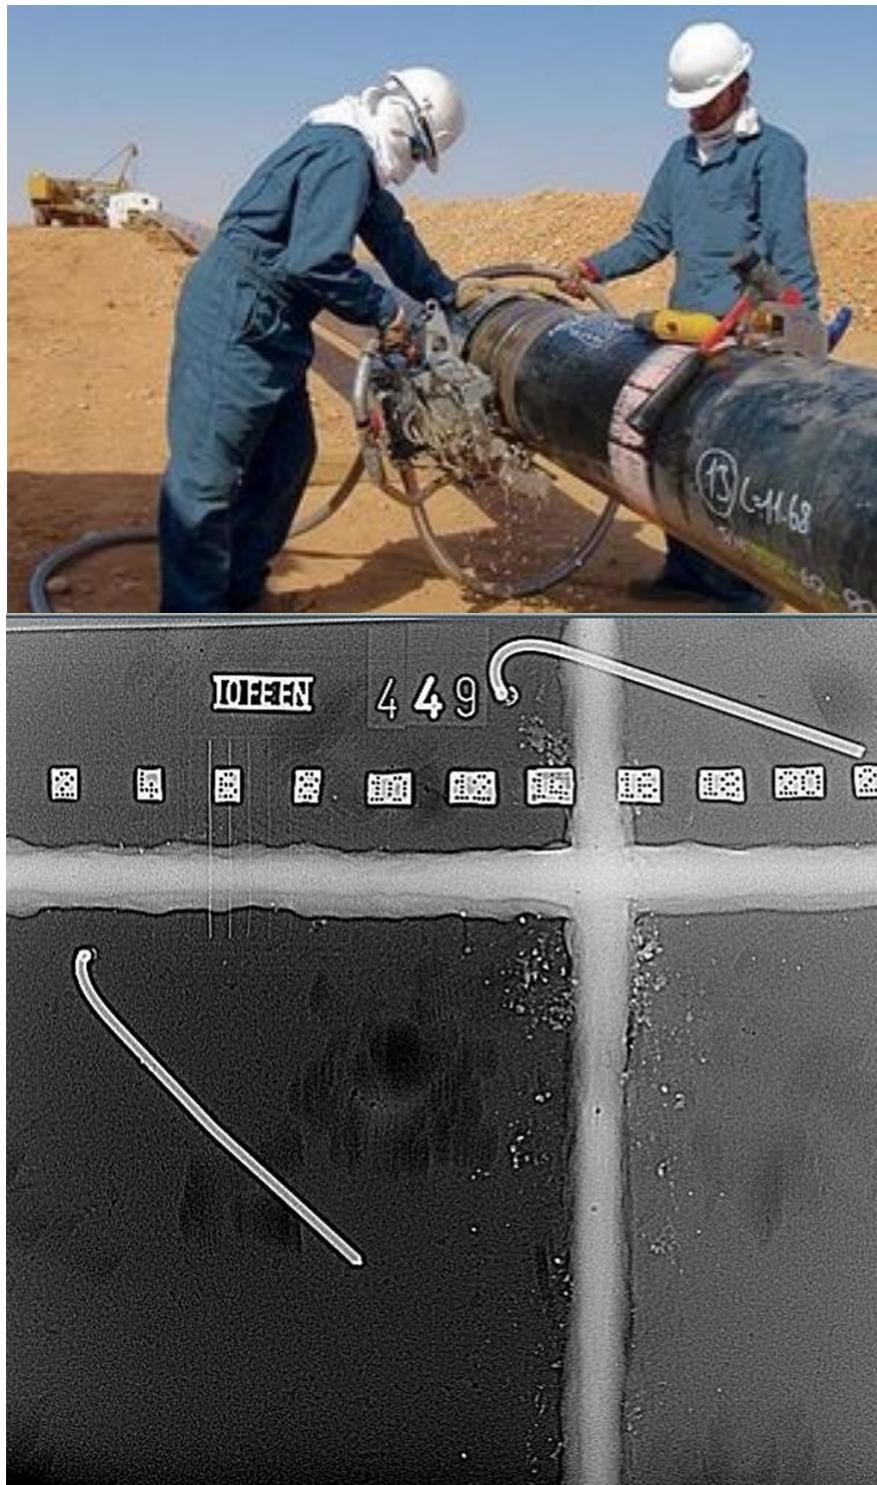
Reconocimiento de gestos



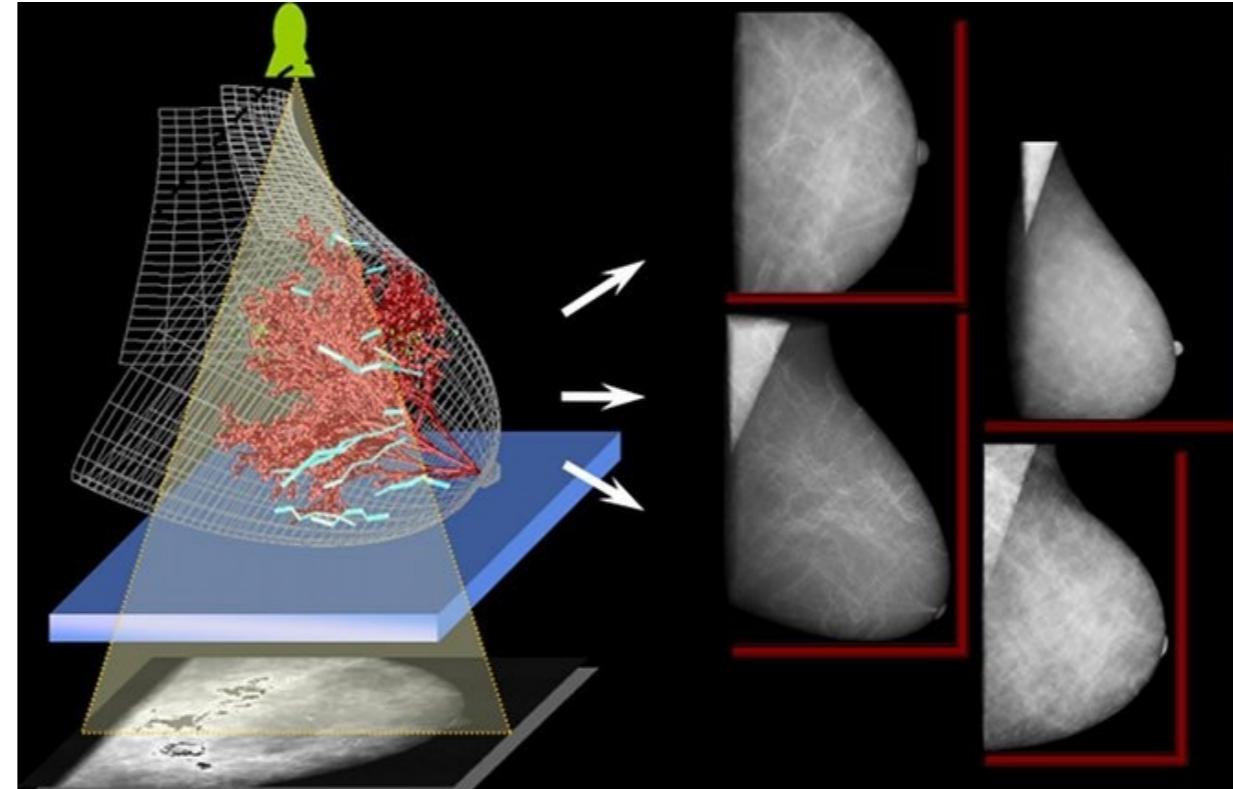
Reconocimiento de la marcha



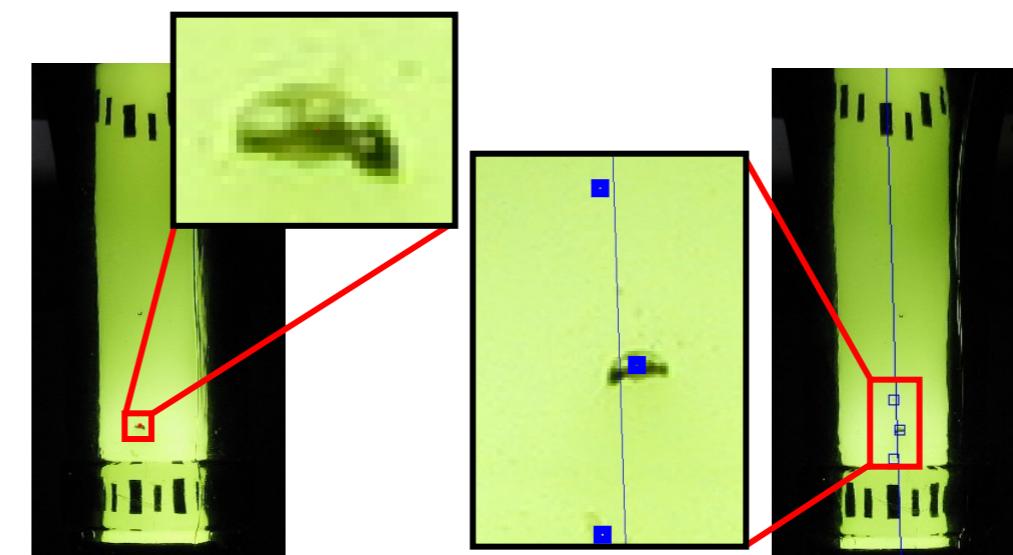
Reconocimiento de patentes



Reconocimiento de fallas en soldaduras (NDT)



Reconocimiento de tumores en rayos-X

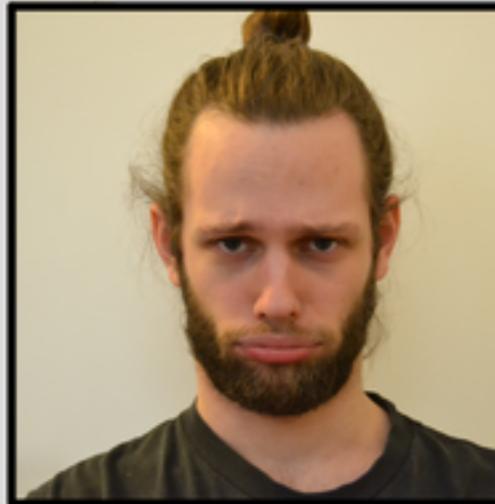


Reconocimiento de fallas en botellas (y objetos manufacturados)

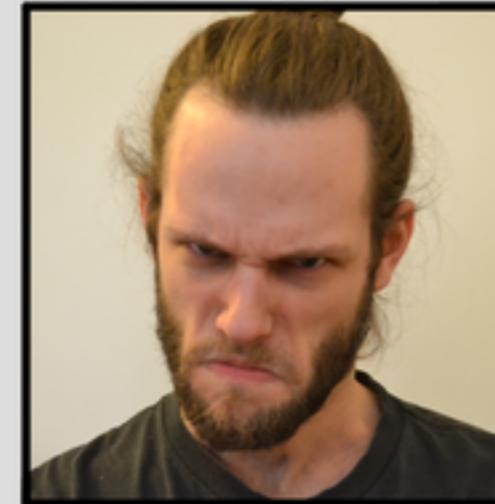
Happy



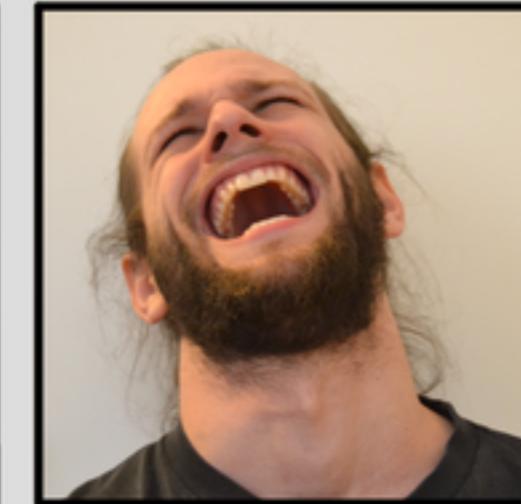
Sad



Angry



Laugh



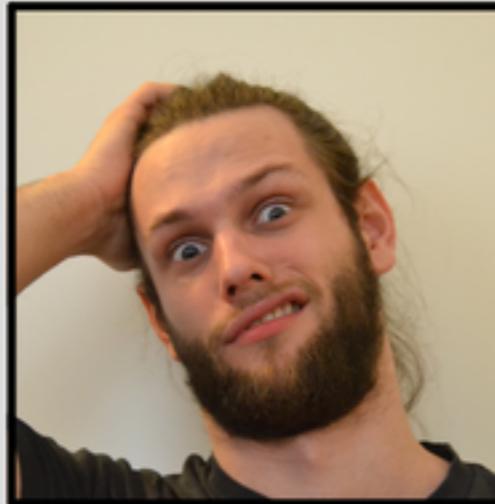
Curious



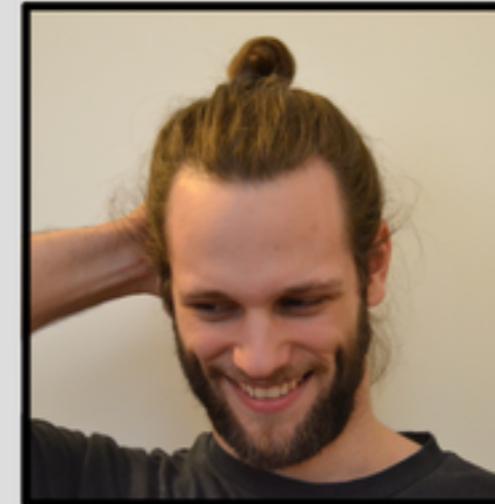
Scared



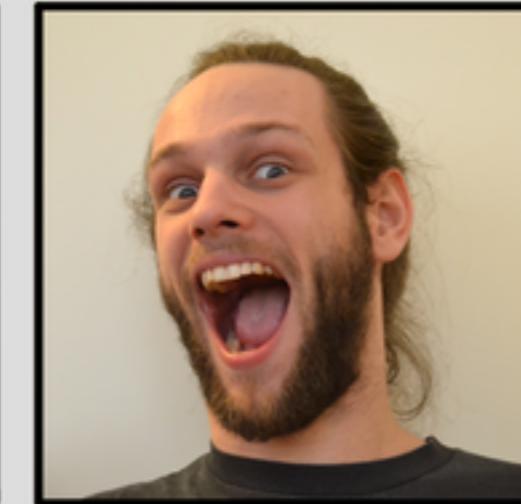
Confused



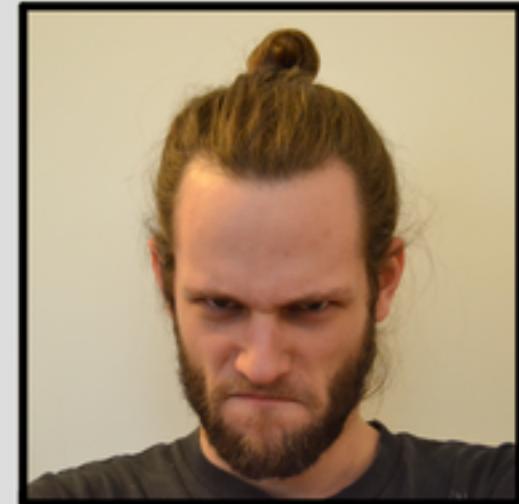
Embarrassed



Excited



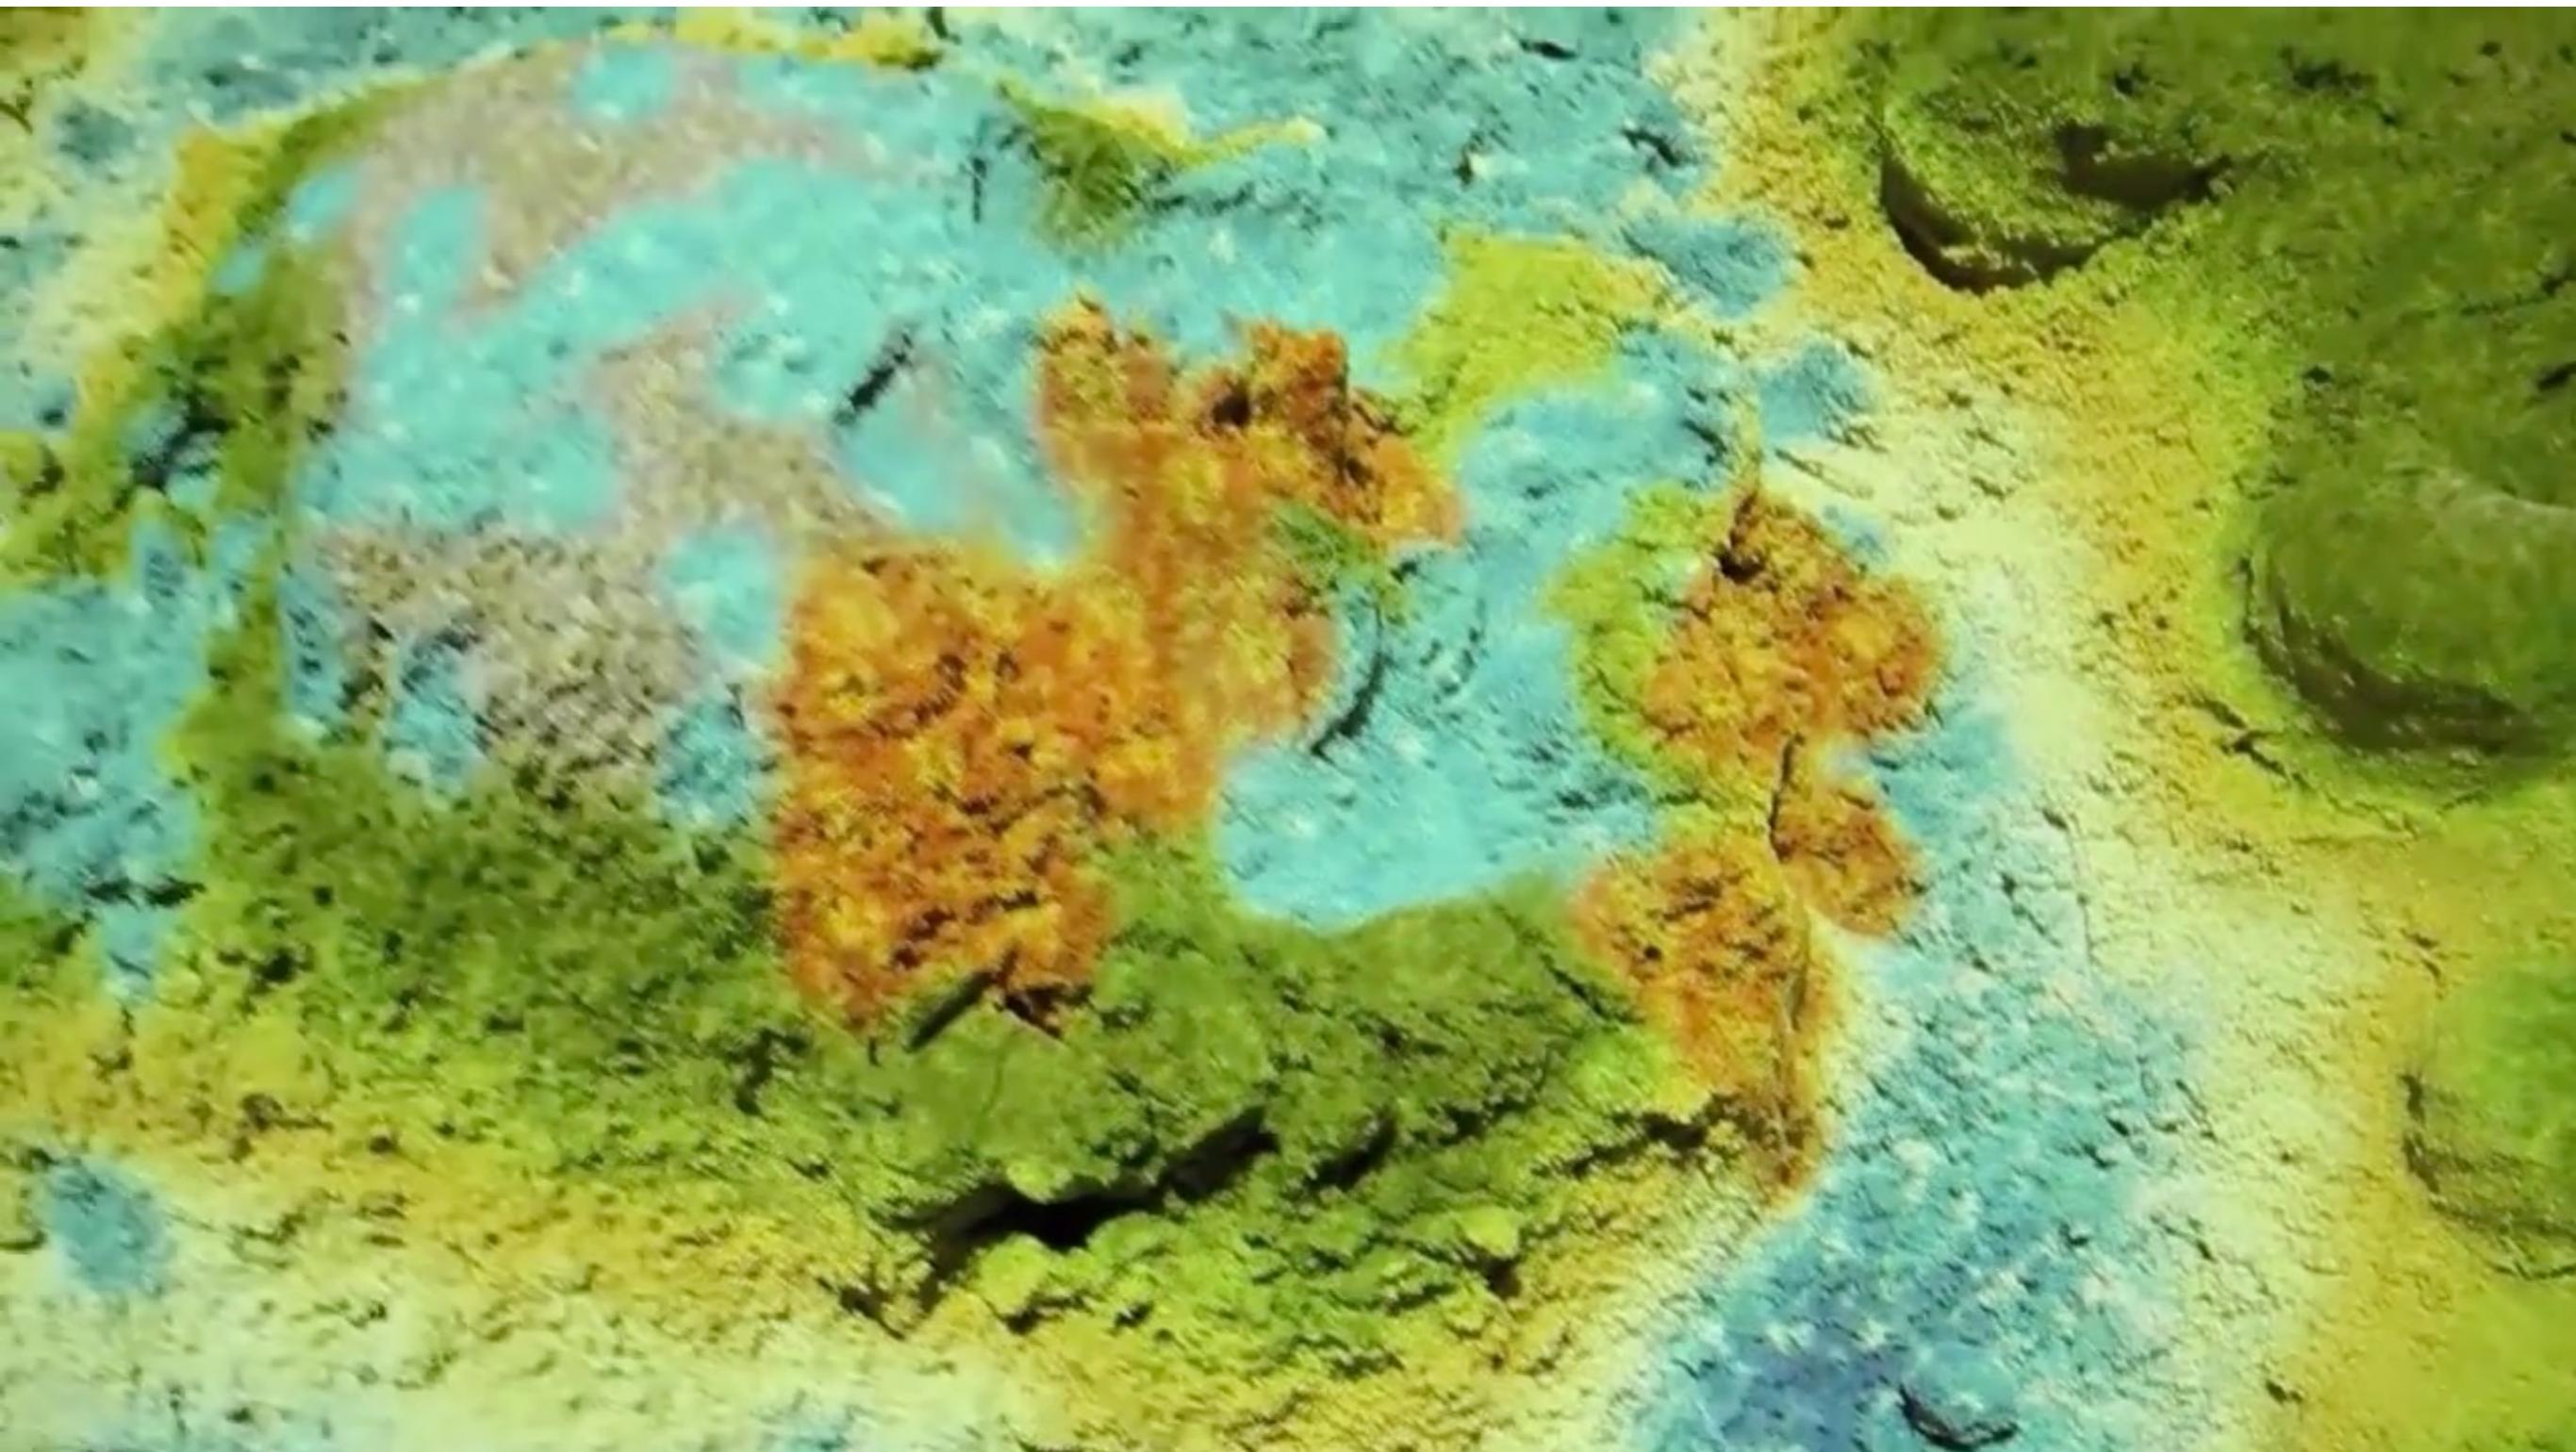
Stubborn



Reconocimiento de Emociones y
gestos

Object Detection and Tracking in PyTorch

fuente: <https://www.youtube.com/watch?v=1BY2CxMYvQ&t=35s>



fuente: <https://www.youtube.com/watch?v=orkTgPt3M4k>



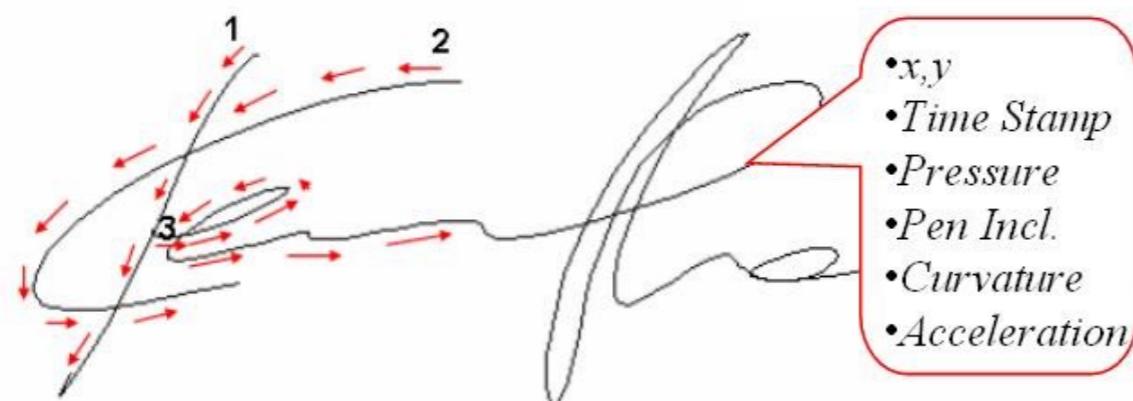
Reconocimiento de enfermedades



Reconocimiento de música (Ej. Shazam)



Reconocimiento de la voz



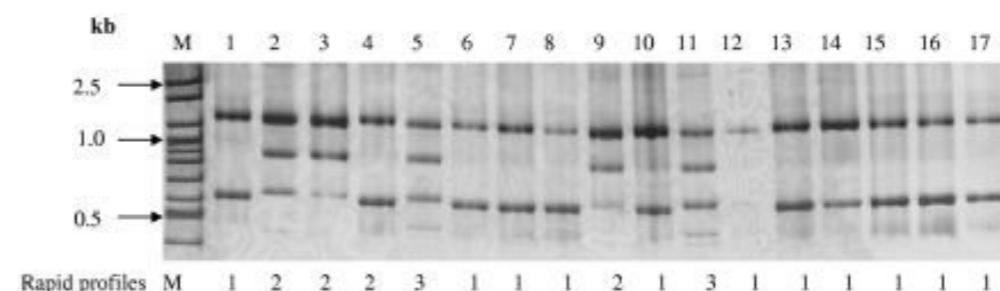
Reconocimiento de firmas



Reconocimiento del movimiento corporal (video juegos)



Reconocimiento de correo
no deseado (SPAM)



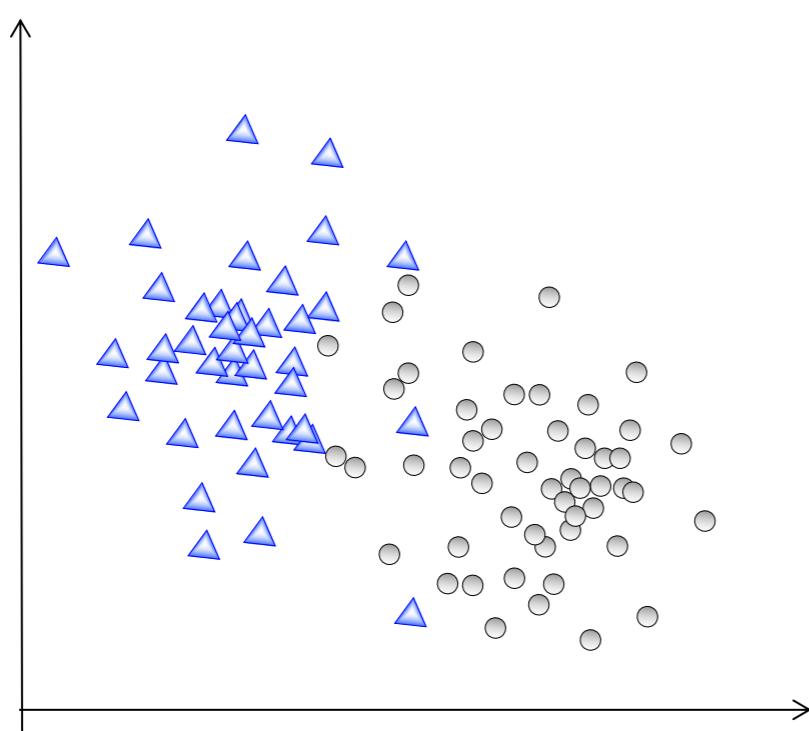
Reconocimiento de Patrones ADN
(identificación, parentesco)

- Aspectos administrativos
- Objetivos y tópicos del curso
- Minería de datos
- Visión general



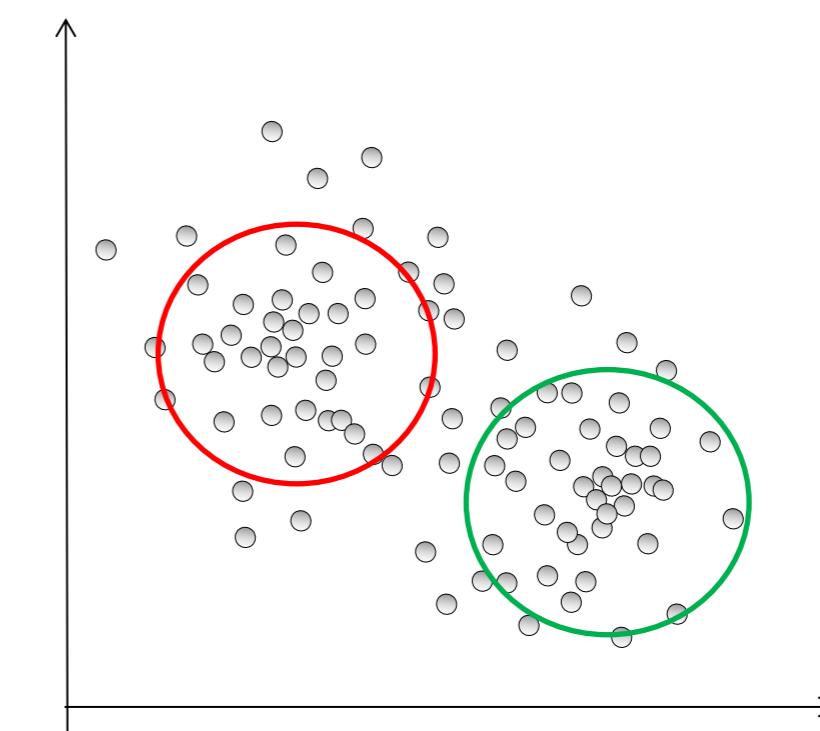
En el **aprendizaje supervisado** existe una variable objetivo a predecir.

- Si el objetivo son clases, se llama problema de clasificación.
- Si los datos son continuos, se denomina problema de predicción.



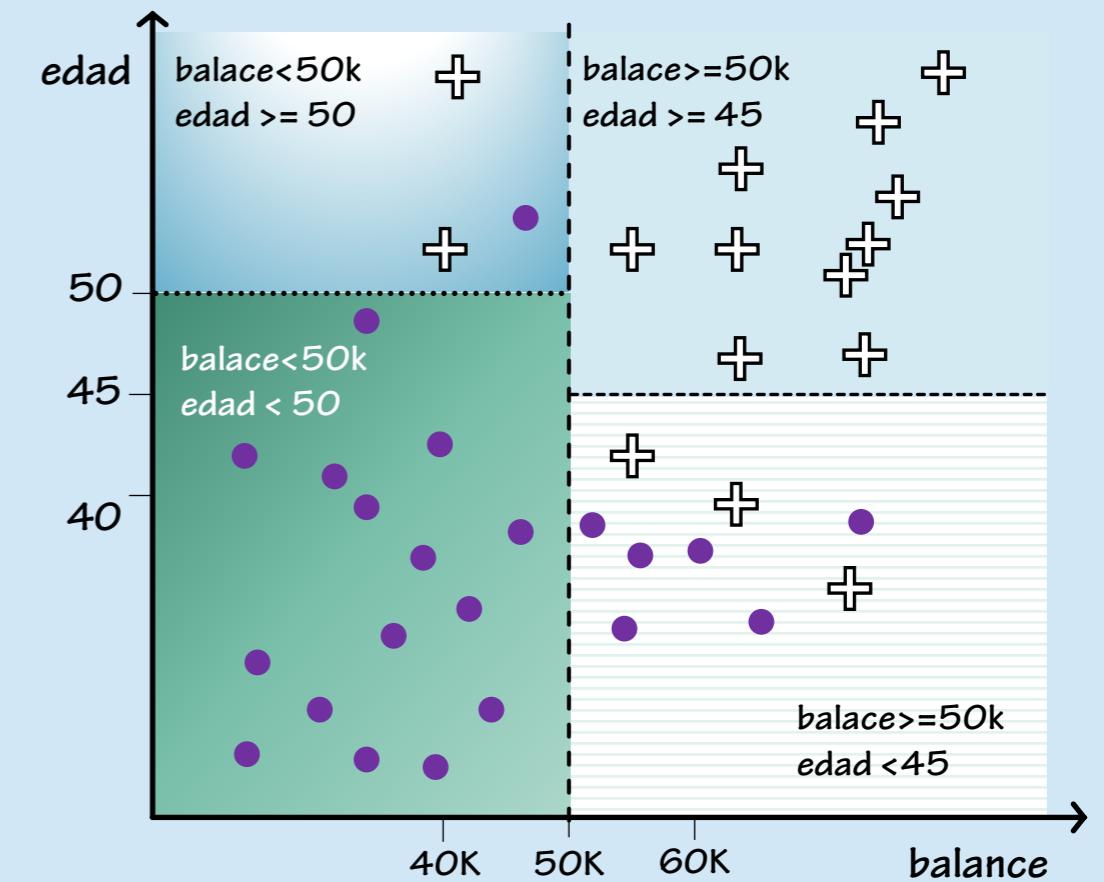
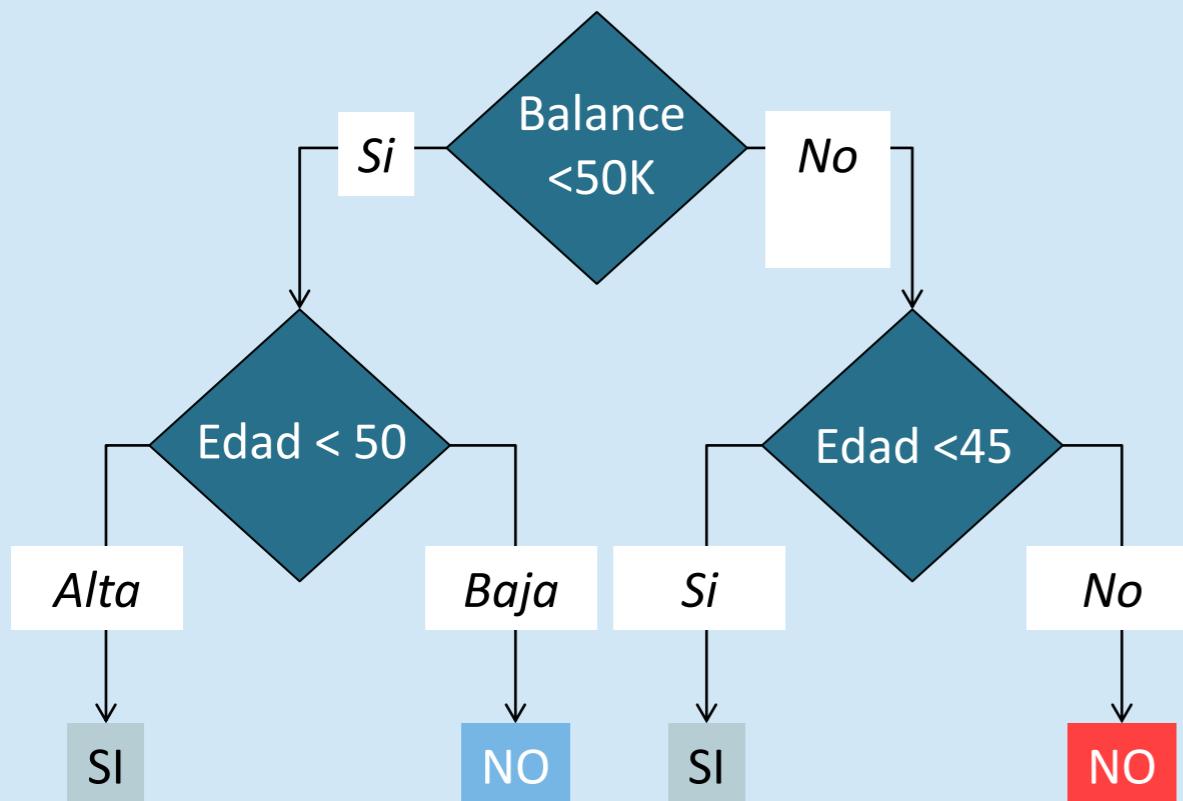
En el **aprendizaje NO supervisado** se busca aprender la estructura o relación existente en los datos.

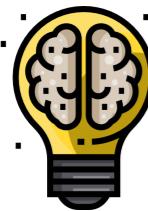
- No existe una variable objetivo



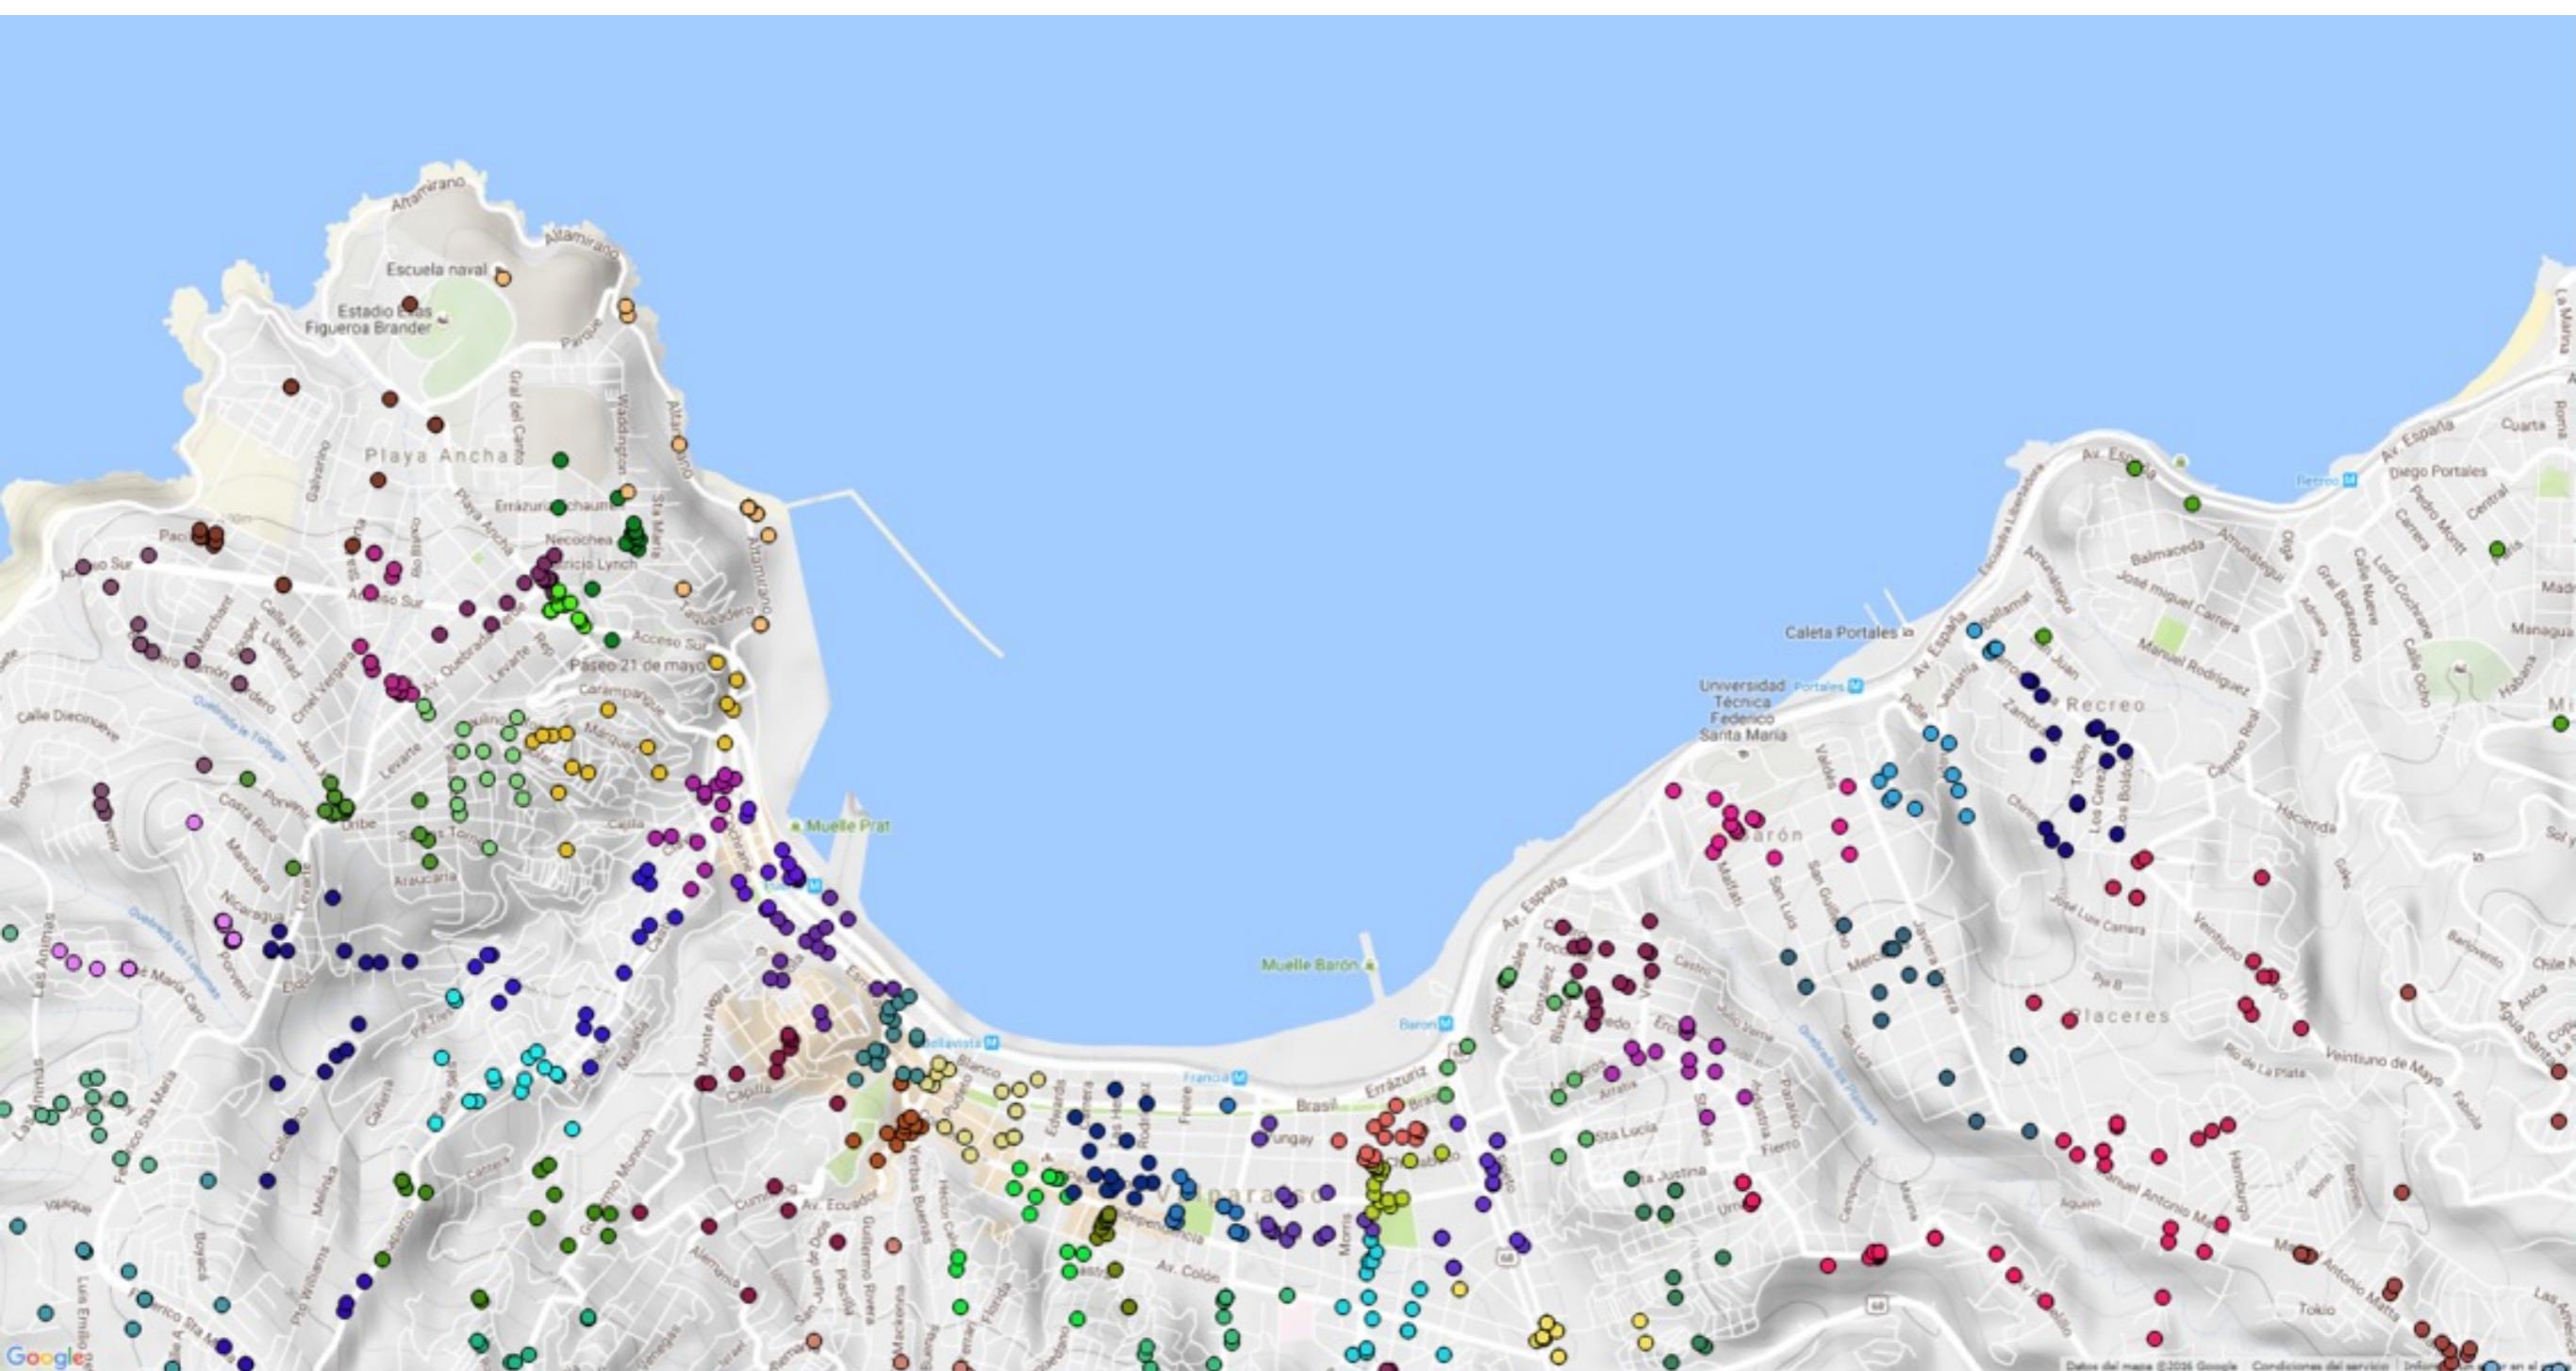


El objetivo es predecir una variable objetivo según la información disponible del problema





El objetivo de la planificación territorial es definir áreas geográficas que agrupe potenciales clientes para mejorar la distribución de una compañía.



El tipo de problema esta basado en el objetivo de la persona que analiza la tarea. Ejemplos:



De un set de datos **con etiqueta**, cree un modelo capaz de predecir si un corredor de bolsa realizará algún fraude en el futuro cercano.



Dado un set de datos **sin etiqueta**, agrupe a los corredores de bolsas en grupos de personas homogéneas basado en su información demográfica



En general, los problemas que estudiaremos se resumen en cuatro tipos:

Análisis
exploratorio de
datos

Modelos
predictivos

Modelos
descriptivos

Búsqueda de
patrones

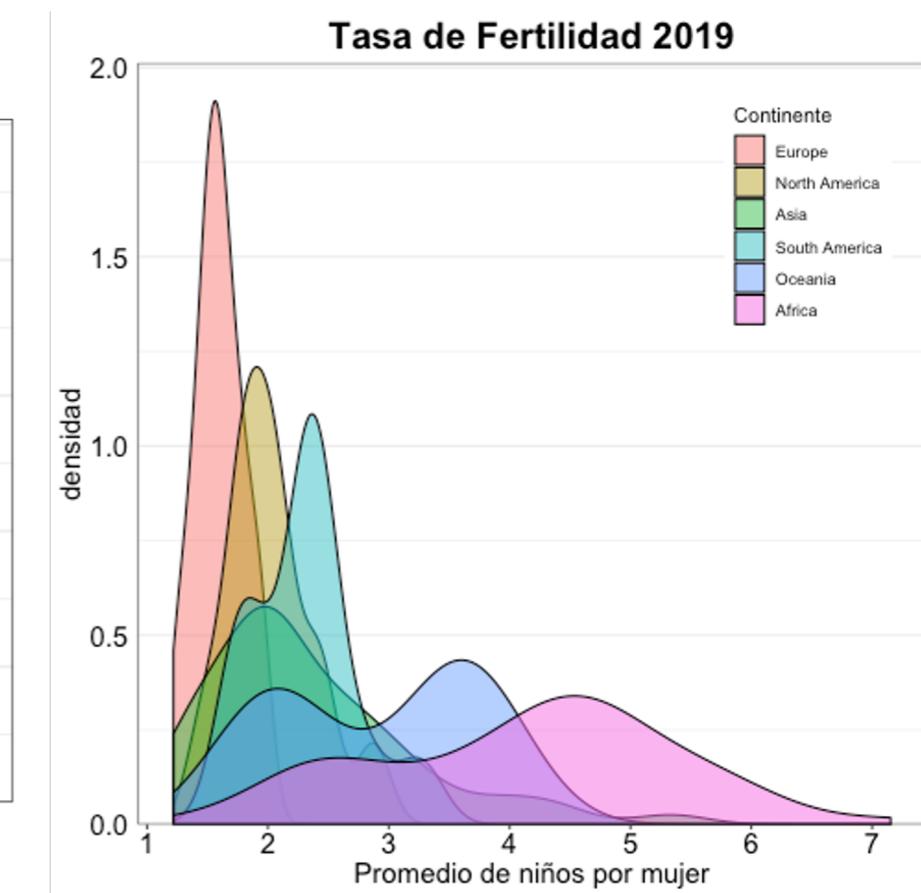
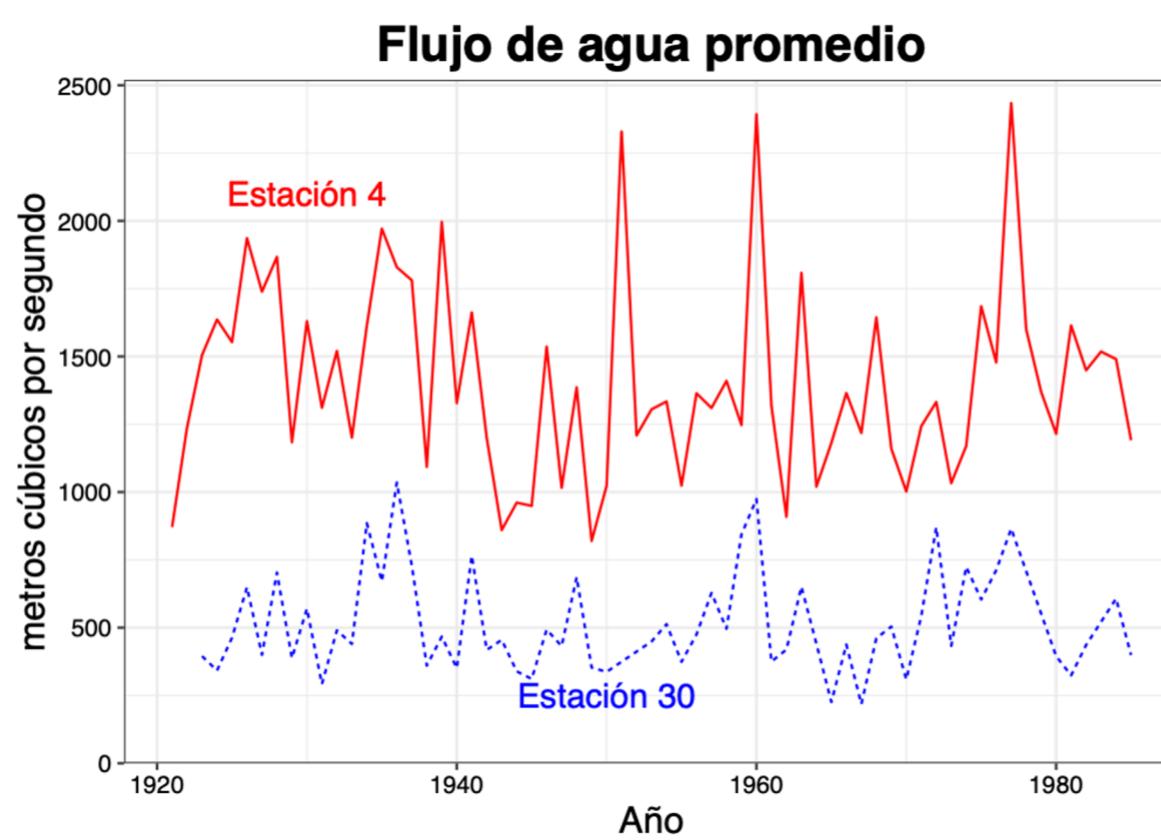
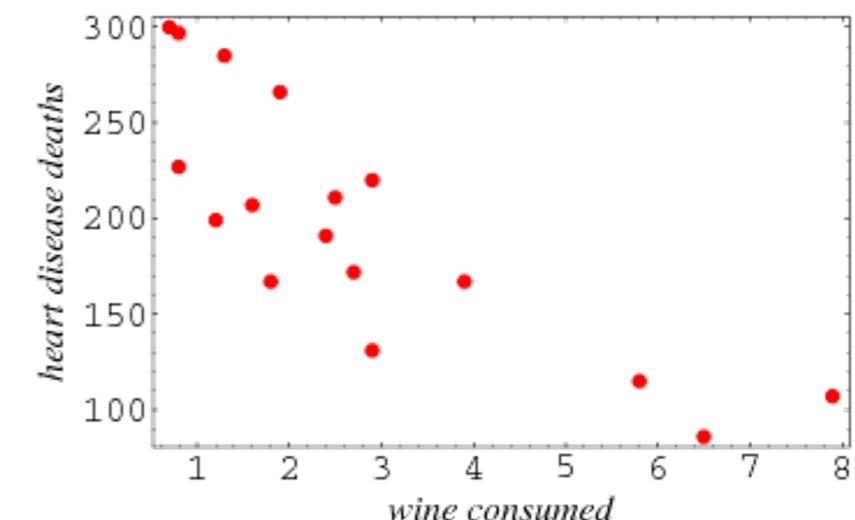
Análisis exploratorio de datos

Objetivos

- ▶ Interactuar con los datos para generar información.

Técnicas

- ▶ Métricas estadísticas, visualización, test de hipótesis, análisis de outliers.



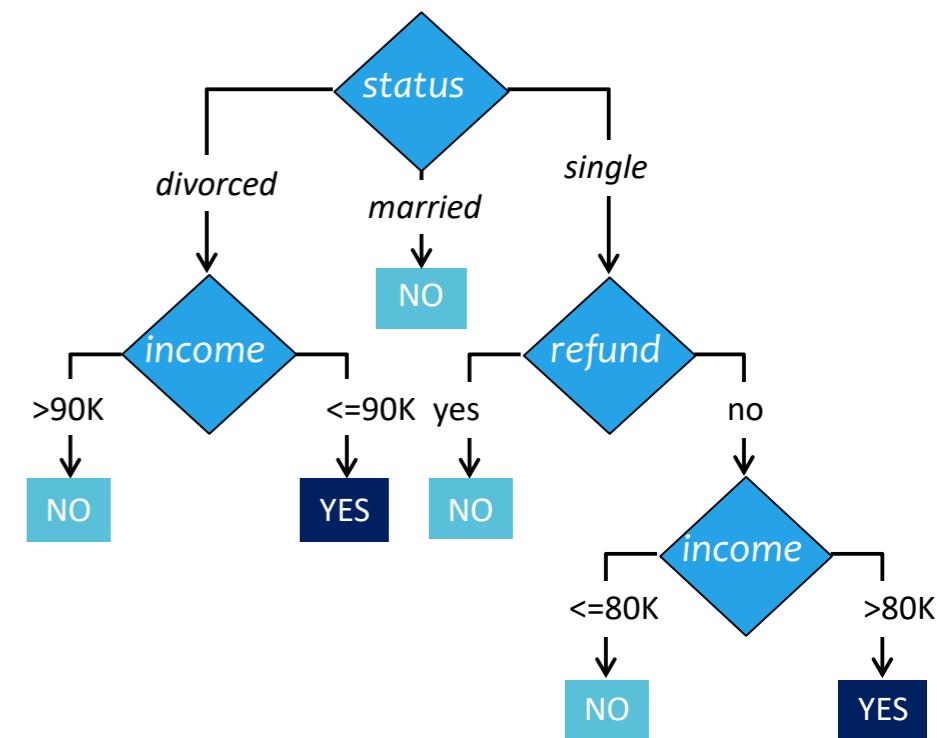
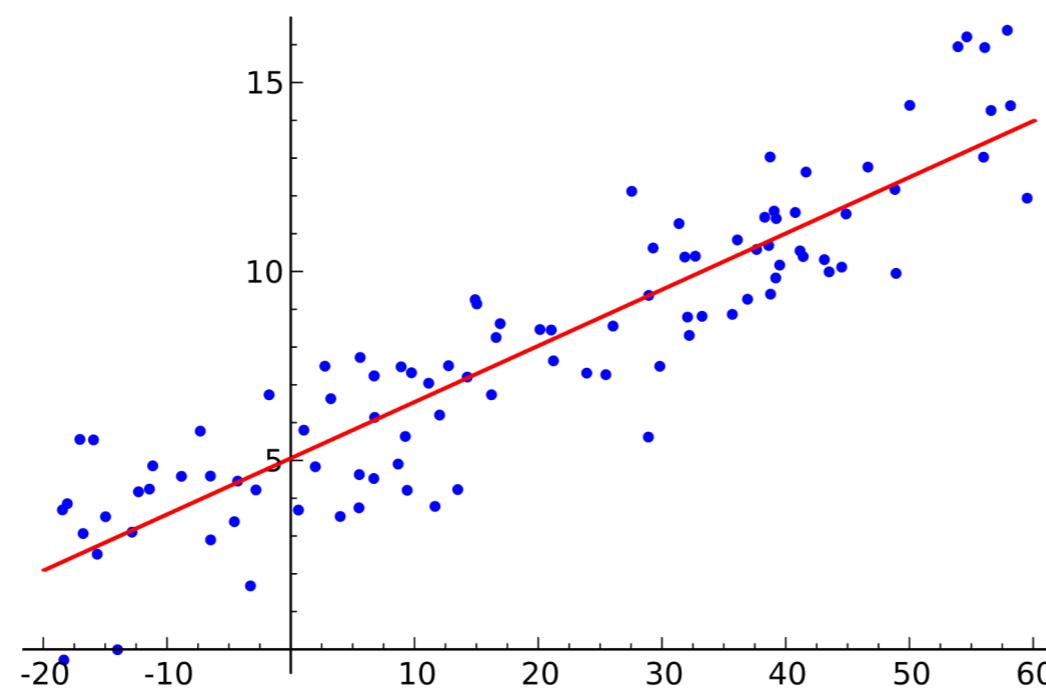
Modelos predictivos

Objetivos

► Aprender un modelo para predecir la clase desconocida de un punto observado dado sus atributos.

Técnicas

► Clasificación, Regresión



Modelos predictivos

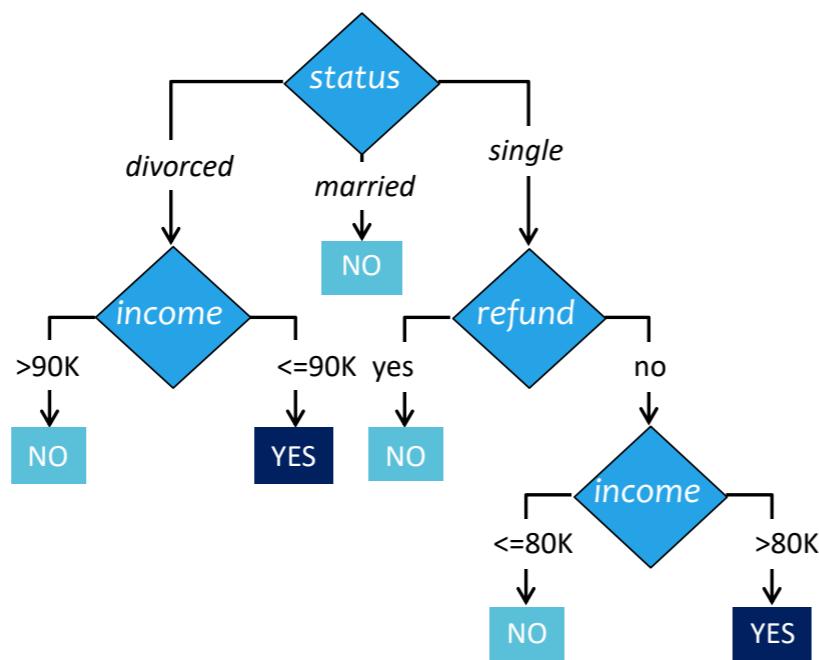
Objetivos

► Aprender un modelo para predecir la clase desconocida de un punto observado dado sus atributos.

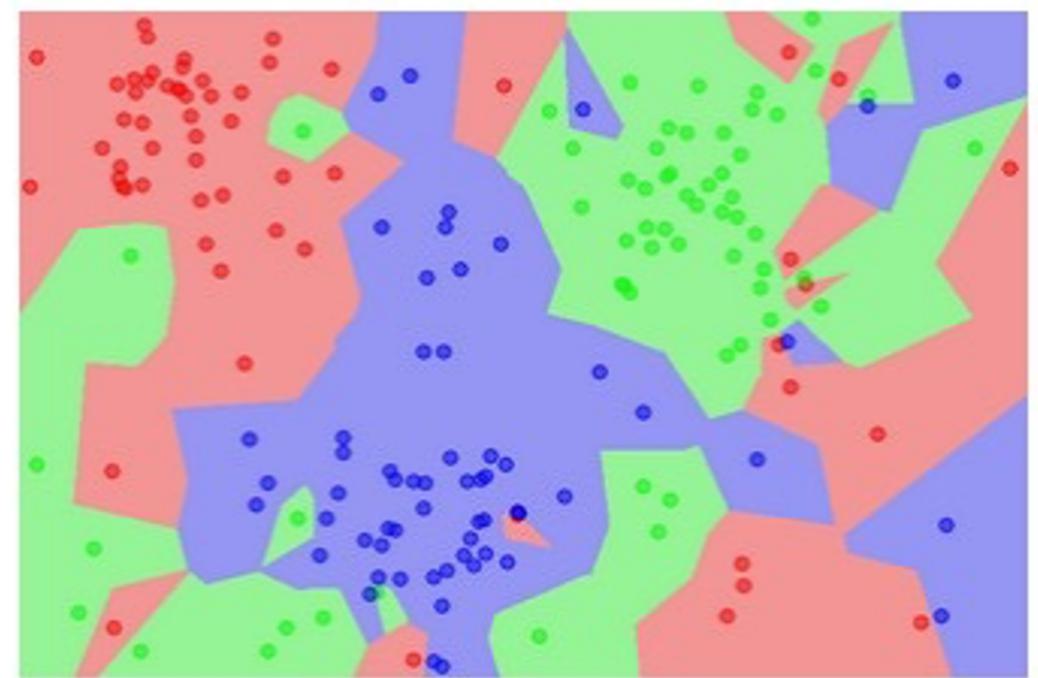
Técnicas

► Clasificación, Regresión

árbol de decisión



K-nearest neighbor



Análisis exploratorio de datos

Modelos predictivos

Objetivos

► Aprender un modelo para predecir la clase desconocida de un punto observado dado sus atributos.

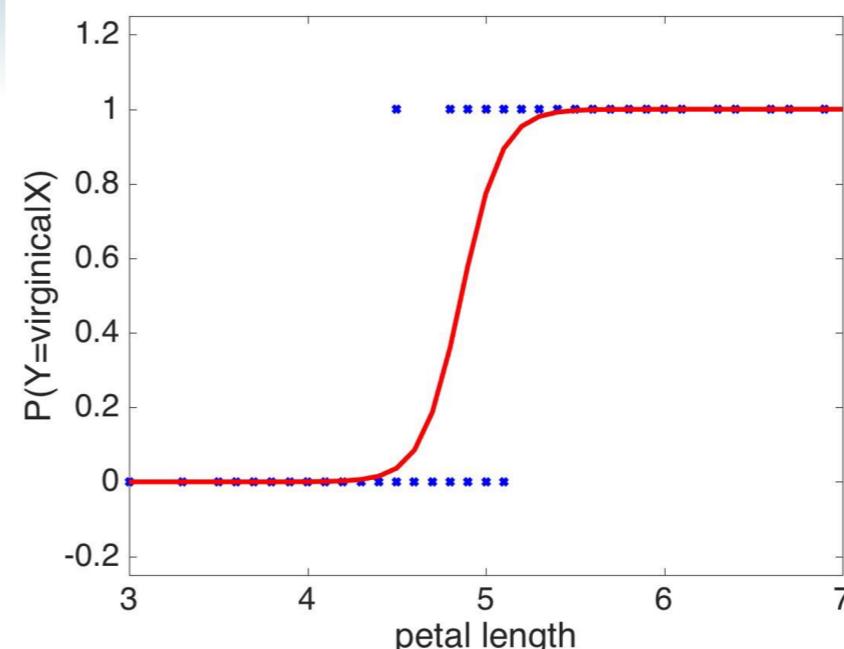
Técnicas

► Clasificación, Regresión

Naive bayes

$$clase_{MAP} = \operatorname{argmax}_{clase_k \in \text{clases}} \prod_{i=1}^n P(a_i | classe_k) \times P(classe_k)$$

Regresión logística



Análisis exploratorio de datos

Modelos predictivos

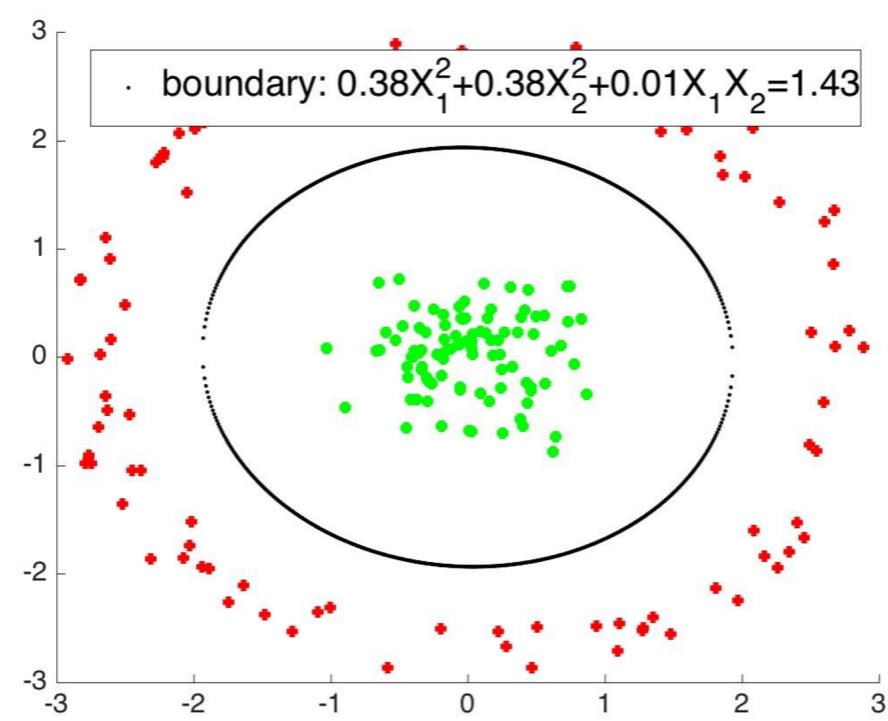
Objetivos

► Aprender un modelo para predecir la clase desconocida de un punto observado dado sus atributos.

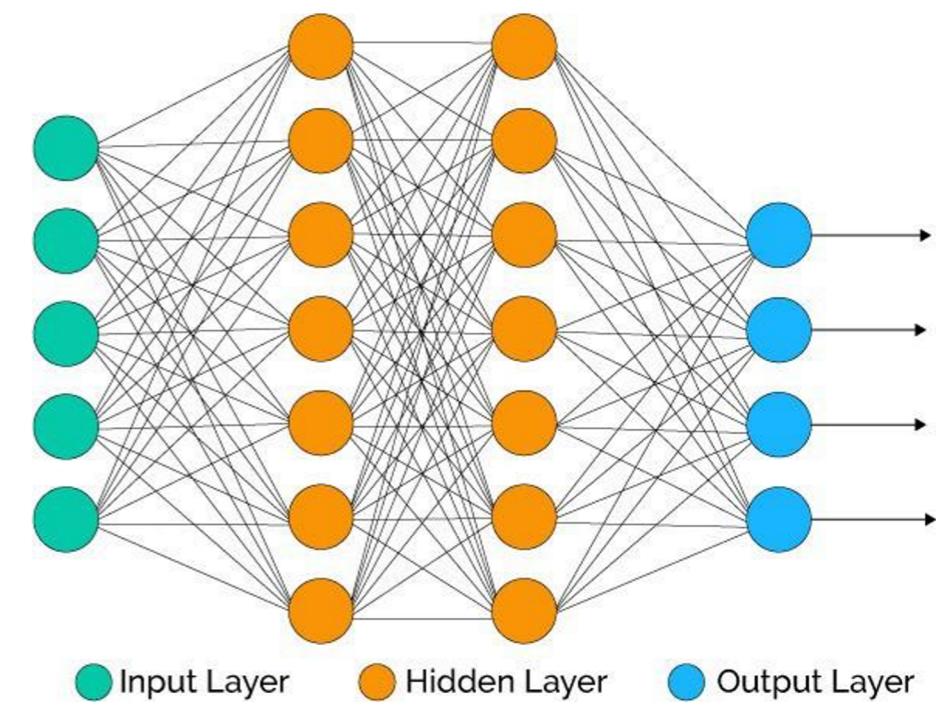
Técnicas

► Clasificación, Regresión

Support Vector Machine



Neural Networks



Modelos descriptivos

Objetivos

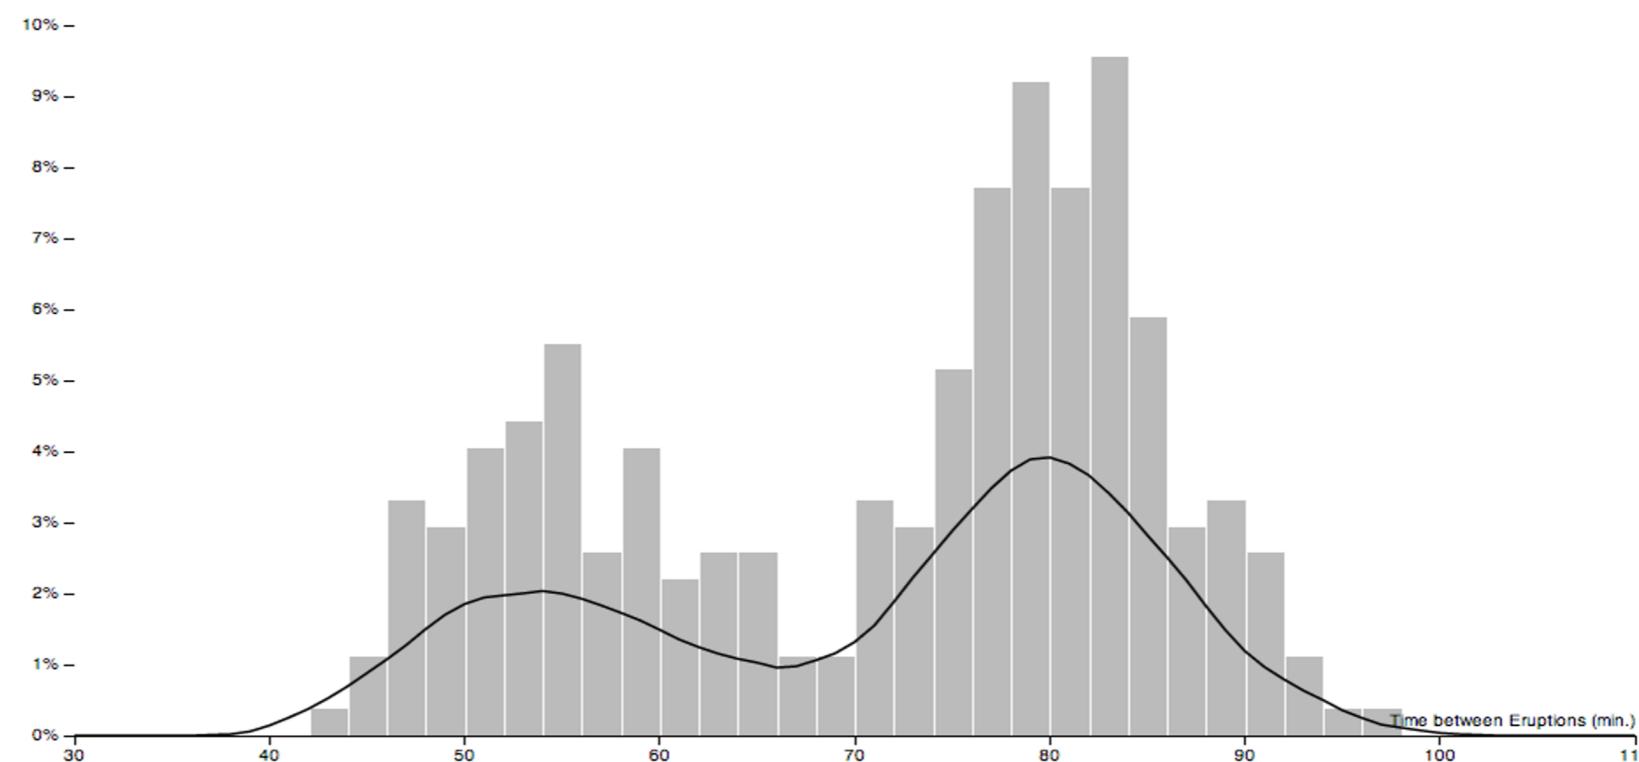
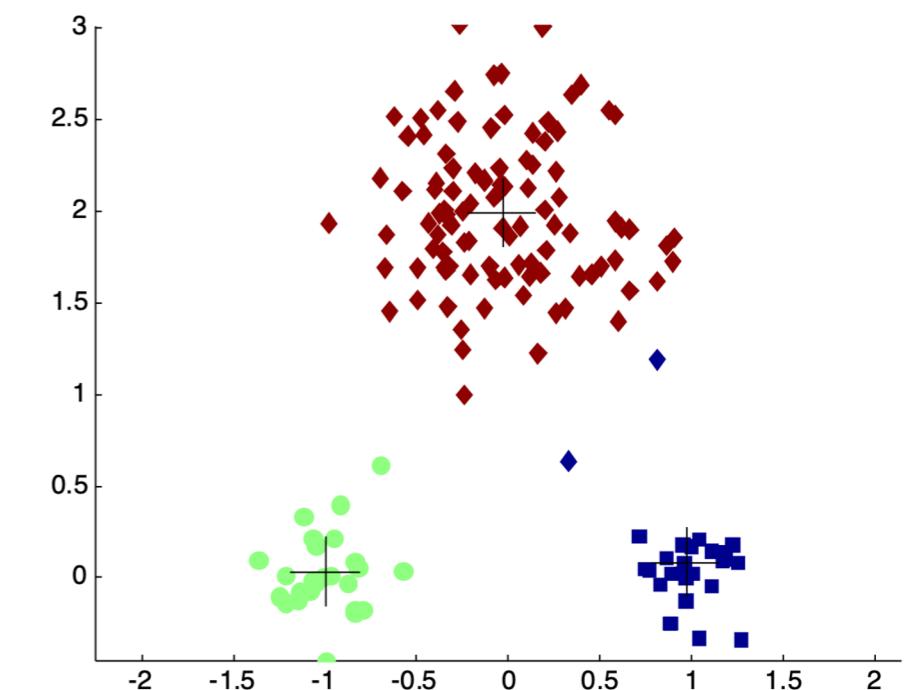
- ▶ Resumir los datos o replicar el proceso que los genera.

Técnicas

- ▶ Estimación de densidad, análisis de clusters.

Modelos predictivos

Análisis exploratorio de datos



Modelos descriptivos

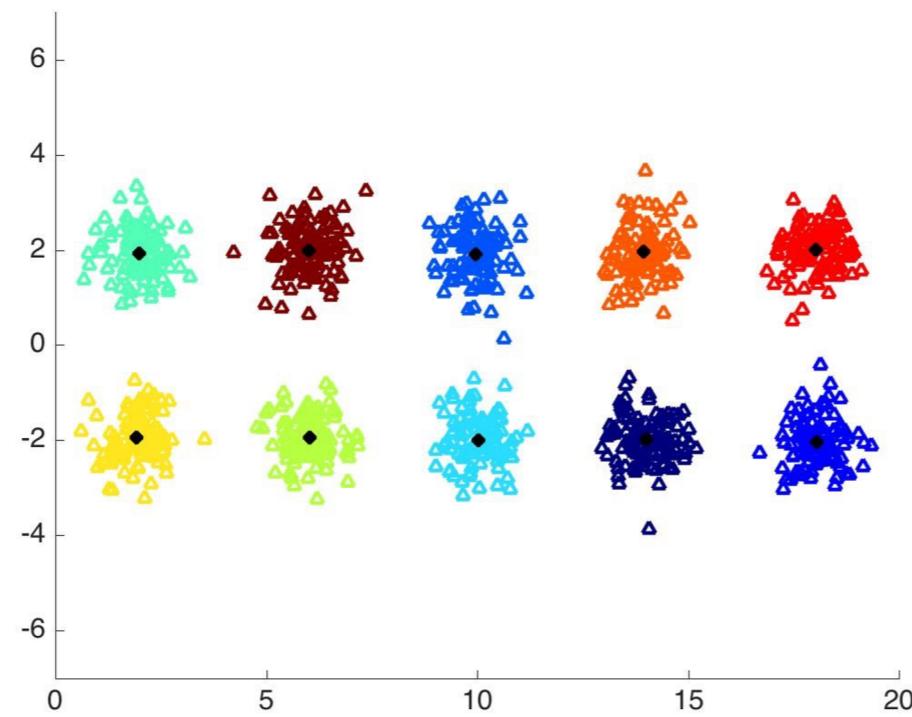
Objetivos

- ▶ Resumir los datos o replicar el proceso que los genera.

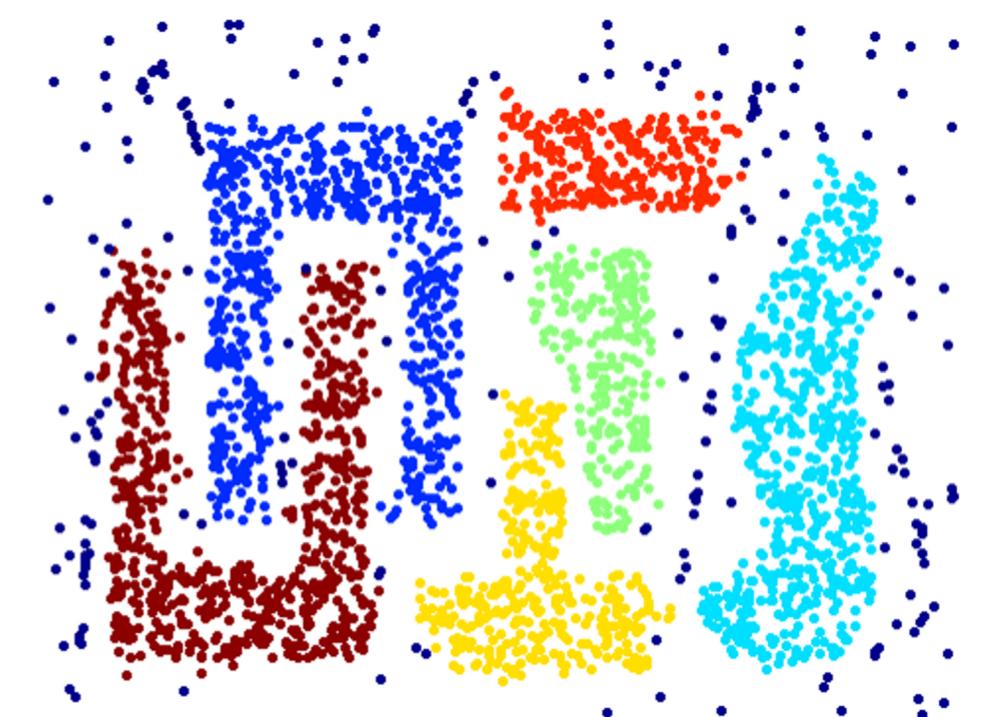
Técnicas

- ▶ Estimación de densidad, análisis de clusters.

K-means



DBSCAN



Modelos predictivos

Análisis exploratorio de datos

Modelos descriptivos

Objetivos

- ▶ Resumir los datos o replicar el proceso que los genera.

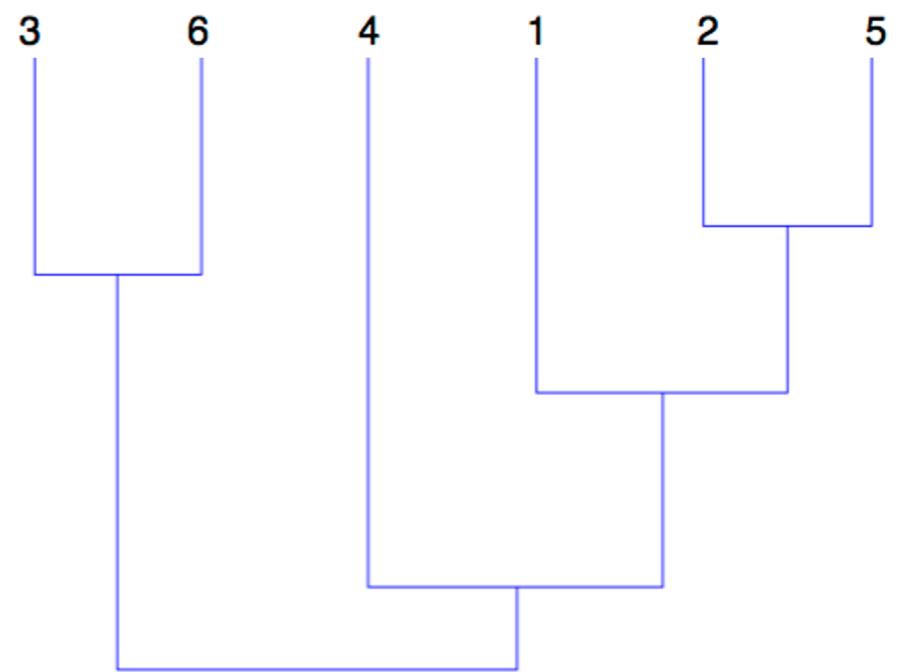
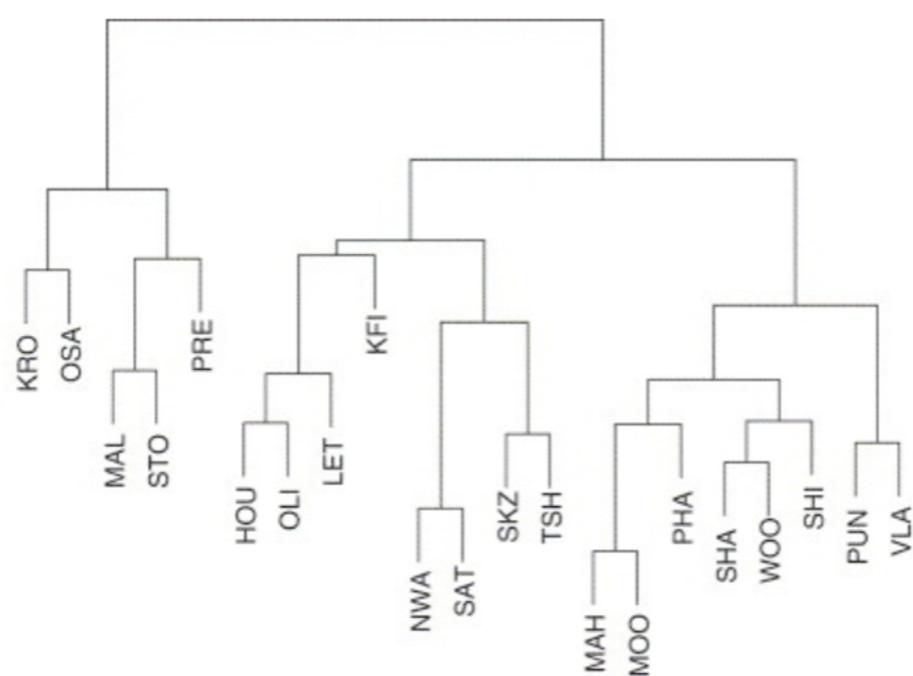
Técnicas

- ▶ Estimación de densidad, análisis de clusters.

Modelos jeráquicos

Aglomerativos

Divisivos



Modelos predictivos

Análisis exploratorio de datos

Modelos descriptivos

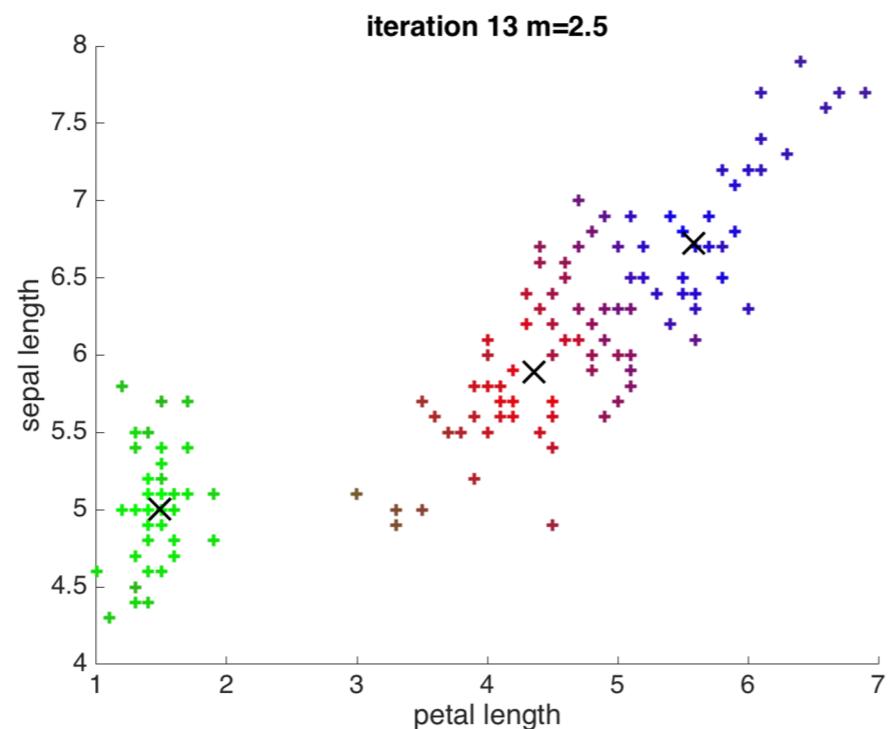
Objetivos

- ▶ Resumir los datos o replicar el proceso que los genera.

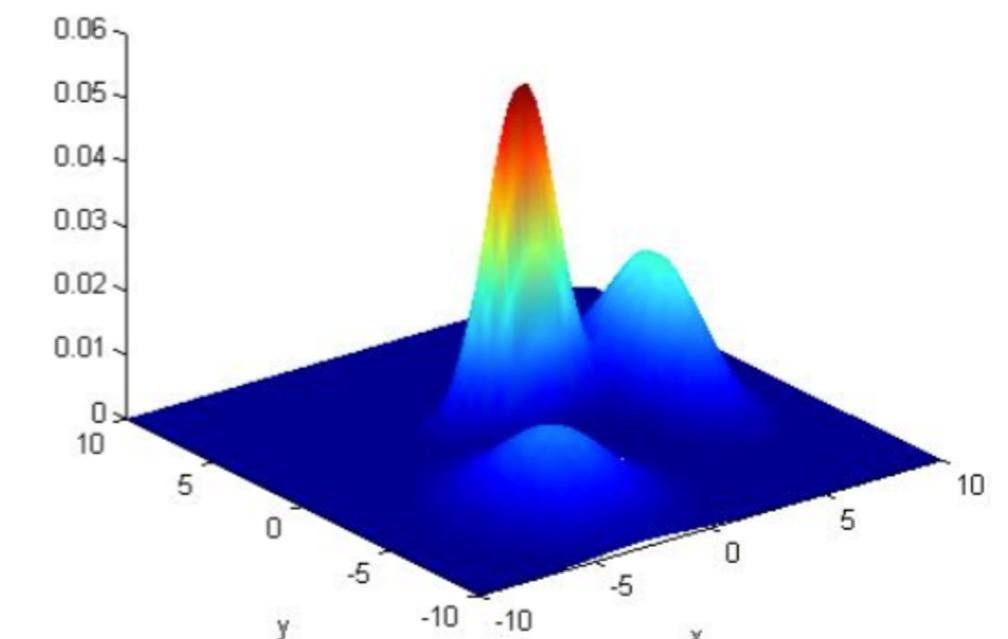
Técnicas

- ▶ Estimación de densidad, análisis de clusters.

Fuzzy C-Means



Gaussian Mixture Model



Modelos predictivos

Análisis exploratorio de datos

Búsqueda de patrones

Objetivos

- ▶ Detectar patrones y reglas que describen los datos.

Técnicas

- ▶ Reglas de asociación

Modelos descriptivos

Modelos predictivos

Análisis exploratorio de datos

Canasta de compras

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Reglas de asociación

$\{\text{Milk}, \text{Diaper}\} \rightarrow \{\text{Beer}\}$ ($s=0.4, c=0.67$)
 $\{\text{Milk}, \text{Beer}\} \rightarrow \{\text{Diaper}\}$ ($s=0.4, c=1.0$)
 $\{\text{Diaper}, \text{Beer}\} \rightarrow \{\text{Milk}\}$ ($s=0.4, c=0.67$)
 $\{\text{Beer}\} \rightarrow \{\text{Milk}, \text{Diaper}\}$ ($s=0.4, c=0.67$)
 $\{\text{Diaper}\} \rightarrow \{\text{Milk}, \text{Beer}\}$ ($s=0.4, c=0.5$)
 $\{\text{Milk}\} \rightarrow \{\text{Diaper}, \text{Beer}\}$ ($s=0.4, c=0.5$)



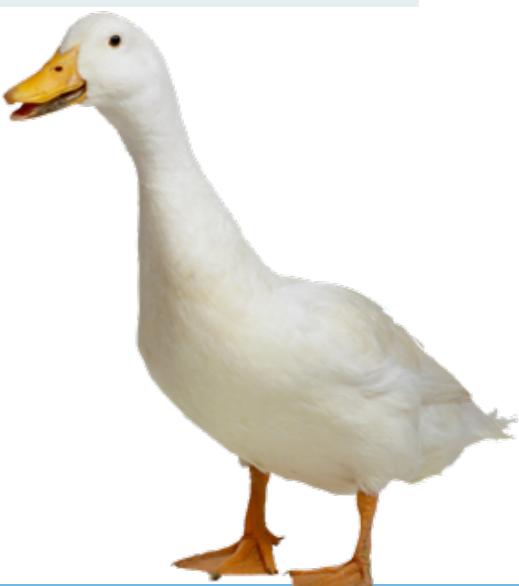
Modelos supervisados:

- Evitar sobreentrenamiento.
- Estimar en forma correcta el error de un modelo (K fold cross validation).
- Comparar algoritmos de predicción (test de hipótesis).

Modelos no supervisados:

- Evaluar el comportamiento de cada cluster (evitar encontrar ruido como un patrón).
- Comparar algoritmos de clustering
- Comparar agrupaciones obtenidas por distintos modelos.

Siempre es necesario evaluar un modelo, caso contrario podríamos estar sobreentrenando el modelo, es decir, modelando solo ruido.





Sobre- entrenamiento:

El modelo estadístico describe el ruido en vez de la verdadera estructura detrás de los datos.

