



UNIVERSIDAD ADOLFO IBÁÑEZ

RECONOCIMIENTO DE PATRONES EN IMÁGENES TICS 585

FACULTAD DE INGENIERÍA Y CIENCIAS
UNIVERSIDAD ADOLFO IBÁÑEZ

SEGUNDO SEMESTRE 2021

PROFESOR: MIGUEL CARRASCO

CLASIFICADORES SUPERVISADOS

■ Métodos

- Min-Max
- Media cero, desviación uno

OBJETIVO:

Transformar el rango de los datos originales a un nuevo intervalo.



■ Técnicas de normalización

Min-Max

Media
desviación

- El método de normalización *min-max* transforma el rango de valores originales a un rango fijo contenido entre cero y uno.

- Min-Max

$$0 \leq v_j \leq 1$$

$$v_i = f_N(u_i) = \frac{(u_i - \min(u_i))}{(\max(u_i) - \min(u_i))}$$

Muestra	u_i	$u_i - \min(u_i)$	$\frac{(u_i - \min(u_i))}{(\max(u_i) - \min(u_i))}$	v_i
muestra 1	4	2	2/8	0.25
muestra 2	6	4	4/8	0.50
muestra 3	8	6	6/8	0.75
muestra 4	2	0	0/8	0
muestra 5	10	8	8/8	1

■ Técnicas de normalización



- El método de normalización *media-desviación* transforma el rango de valores originales a media cero y desviación uno
- Media cero, desviación uno
 $\mu = 0 \quad \sigma = 1$

$$\mathbf{v}_i = f_N(\mathbf{u}_i) = \frac{\mathbf{u}_i - \mu}{\sigma_i}$$

Muestra	\mathbf{u}_i	$\mathbf{u}_i - \mu$	\mathbf{v}_i
muestra 1	4	-2	-0.63
muestra 2	6	0	0
muestra 3	8	2	0.63
muestra 4	2	-4	-1.26
muestra 5	10	4	1.26

Media
centro de gravedad de la muestra .

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

Desviación Estándar
Es una medida de dispersión que nos dice cuan alejados estamos de la media

$$\sigma = \sqrt{\frac{1}{N-1} \cdot \sum_{i=1}^N (x_i - \mu)^2}$$

$$\sigma = \sqrt{\frac{(4-6)^2 + (6-6)^2 + (8-6)^2 + (2-6)^2 + (10-6)^2}{4}} = 3.16$$

■ Supervisados

- kNN
- Mahalanobis
- Linear Discriminant Analysis
- Árboles de decisión
- Redes de Bayes
- Redes Neuronales

■ No supervisados

- Mean Shift
- K-Means
- GMM-EM
- Clustering jerárquico
- Redes autoasociativas

OBJETIVO:

Definir los rangos de aceptación y rechazo para cada clase a partir de sus mediciones



Rendimiento de clasificación binaria

- El rendimiento del clasificador permite evaluar el porcentaje de error que genera la clasificación. Para evaluar dicho rendimiento se construye **la matriz de confusión**.

es ↓ → predicho

		Sano	Enfermo
Sano	TN	FP	
Enfermo	FN	TP	

En esta matriz sólo tenemos dos clases pero pueden tener todas las que queramos

- Descripción

True Negative (TN): Número de personas **sanas** clasificadas como **sanas**

True Positive (TP): Número de personas **enfermas** clasificadas con **enfermas**

False Positive (FP): Número de personas **sanas** clasificadas con **enfermas**

False Negative (FN): Número de personas **enfermas** clasificadas como **sanas**

Idealmente estos deben tender a cero

Rendimiento de clasificación binaria

es ↓

		predicho	
		Negative	Positive
es	Negative	TN	FP
	Positive	FN	TP

True Negative (TN): Número de personas **sanas** clasificadas como **sanas**

True Positive (TP): Número de personas **enfermas** clasificadas con **enfermas**

False Positive (FP): Número de personas **sanas** clasificadas con **enfermas**

False Negative (FN): Número de personas **enfermas** clasificadas como **sanas**

True Positive
Rate o Recall

$$TPR = \frac{TP}{TP + FN}$$

True Negative
Rate

$$TNR = \frac{TN}{TN + FP}$$

False Positive
Rate (Error T.I)

$$FPR = \frac{FP}{TN + FP}$$

False Negative
Rate (Error T.2)

$$FNR = \frac{FN}{FN + TP}$$

Sensibilidad

$$S_n = \frac{TP}{TP + FN}$$

Precisión

$$P = \frac{TP}{FP + TP}$$

Especificidad

$$S_p = \frac{TN}{FP + TN}$$

F-Score

$$F = 2 \times \frac{TPR \times P}{TPR + P}$$

Más medidas en
http://en.wikipedia.org/wiki/Sensitivity_and_specificity

Rendimiento de clasificación binaria

- EJEMPLO:** Suponga que usted diseña un software para determinar automáticamente si usted es enfermo o sano a través de un algoritmo de procesamiento de imágenes.
- Luego de una posterior clasificación, estos fueron los resultados. De **100 personas sanas**, el sistema predijo que 95 estaban sanas y 5 enfermas. De **80 personas enfermas**, el sistema predijo que 10 estaban sanas y 70 enfermas

→ predicho

	Negative	Positive
Negative	TN	FP
Positive	FN	TP

es ↓

→ predicho

	Sano	Enfermo	Σ
Sano	95	5	100
Enfermo	10	70	80

es ↓

True Positive Rate o Recall	True Negative Rate
$TPR = \frac{TP}{TP + FN}$	$TNR = \frac{TN}{TN + FP}$
False Positive Rate (Error T.I)	False Negative Rate (Error T.2)
$FPR = \frac{FP}{TN + FP}$	$FNR = \frac{FN}{FN + TP}$

Sensibilidad	Precisión o PPV
$S_n = \frac{TP}{TP + FN}$	$P = \frac{TP}{FP + TP}$
Especificidad	F-Score
$S_p = \frac{TN}{FP + TN}$	$F = 2 \times \frac{TPR \times P}{TPR + P}$

Más medidas en
http://en.wikipedia.org/wiki/Sensitivity_and_specificity

Rendimiento de clasificación binaria

Resultados

1. La **sensibilidad** es 87.5%.
2. La **especificidad** es 95%.
3. La **precisión** es 93%
4. El **F-Score** es 90.32%

5. El **Error Tipo 1 o FPR** es de un 5%
6. El **Error tipo 2 o FNR** es de un 12.5%

El óptimo es 100%

El óptimo es 0%

Existen muchas técnicas de clasificación de optimización que buscan lograr el óptimo. Sin embargo, no siempre podrá ser determinado. En dicho caso deberemos determinar nuestro propio objetivo.


Rendimiento

True Positive Rate o Recall	True Negative Rate
$TPR = \frac{70}{80}$	$TNR = \frac{95}{100}$
False Positive Rate (Error T.I)	False Negative Rate (Error T.2)
$FPR = \frac{5}{100}$	$FNR = \frac{10}{80}$

Sensibilidad	Precisión
$S_n = \frac{70}{70+10}$	$P = \frac{70}{5+70} = 0.933$
Especificidad	F-Score
$S_p = \frac{95}{5+95}$	$F = 2 \times \frac{0.875 \times 0.933}{0.875 + 0.933}$

■ Supervisados



- Los clasificadores **supervisados** son aquellos donde se conoce a priori la clase de cada instancia y el número de clases de la muestra.




■ Supervisados




- El clasificador *k*-Vecinos Cercanos (*k*-NN) calcula la distancia de los *k* vecinos más cercanos al punto. Normalmente se utiliza en problemas con baja dimensión (menor a 20) y con 8 vecinos.



Usted define cuantos vecinos cercanos va a seleccionar. Esto es un parámetro del algoritmo



Hacemos un conteo de votos. Cuantos corresponde a una clase u otra




Finalmente clasificamos el punto según la clase que más votos tenga.

■ Supervisados



- **PRIMERO:** Calcular la distancia del punto que deseamos conocer su clase respecto a todos los puntos del problema.



A qué clase pertenece este punto

x	y	x	y	clase	distancia
1	5	4	1	1	5.00
		5	1	1	5.66
		5	2	1	5.00
		6	7	2	5.39
		7	6	2	6.08
		7	7	2	6.32


Podemos ocupar cualquier métrica de distancia

$$\sqrt{(4-1)^2 + (1-5)^2} = 5 \leftarrow$$

■ Supervisados



- **SEGUNDO:** Ordenamos la distancia en orden ascendente y seleccionamos los k más cercanos, donde k es un número natural mayor o igual a 1.




distancia	clase	distancia	ordenada	clase
5.00	1	5.00	1	1
5.66	1	5.00	1	1
5.00	1	5.39	2	2
5.39	2	5.66	1	1
6.08	2	6.08	2	2
6.32	2	6.32	2	2

■ Supervisados



- **TERCERO:** de la lista de puntos más cercanos, extraemos la clase de los k vecinos más cercanos.



distancia ordenada *clase* *k-clase*



5.00	1		1
5.00	1		1
5.39	2		2
5.66	1		1
6.08	2		2
6.32	2		2

Resultado de las cuatro clases más cercanas

■ Supervisados



- CUARTO: Realizamos la mayoría de votos según cada clase que se encuentre en dicha lista y seleccionamos la clase que tenga más votos.




En el ejemplo vamos
determinamos el número de
clases de los 4 vecinos más
cercanos

■ Supervisados



- La métrica de distancia de Mahalanobis mide la similitud entre dos variables aleatorias multidimensionales.



$$d_1 = (x - \bar{x}_1)^T \Sigma_1^{-1} (x - \bar{x}_1)$$

Centro de masa de la clase 1.


Matriz inversa de covarianza de la clase 1

- A diferencia de la distancia euclídea, la distancia de Mahalanobis mide la dependencia de las variables a través de la matriz de correlación, incorporando así una ponderación de las distintas escalas de cada variable.

■ Supervisados



- La métrica de distancia de Mahalanobis mide la similitud entre dos variables aleatorias multidimensionales.



$$d_1 = (x - \bar{x}_1)^T \Sigma_1^{-1} (x - \bar{x}_1)$$

$$d_2 = (x - \bar{x}_2)^T \Sigma_2^{-1} (x - \bar{x}_2)$$

Centro de masa de la clase 2.


Matriz inversa de covarianza de la clase 1

- A diferencia de la distancia euclídea, la distancia de Mahalanobis mide la dependencia de las variables a través de la matriz de correlación, incorporando así una ponderación de las distintas escalas de cada variable.

■ Supervisados



- La métrica de distancia de Mahalanobis mide la similitud entre dos variables aleatorias multidimensionales.



$$d_1 = (x - \bar{x}_1)^T \Sigma_1^{-1} (x - \bar{x}_1)$$

$$d_2 = (x - \bar{x}_2)^T \Sigma_2^{-1} (x - \bar{x}_2)$$

$$d_3 = (x - \bar{x}_3)^T \Sigma_3^{-1} (x - \bar{x}_3)$$

Centro de masa de la clase 3.


Matriz inversa de covarianza de la clase 1

- A diferencia de la distancia euclídea, la distancia de Mahalanobis mide la dependencia de las variables a través de la matriz de correlación, incorporando así una ponderación de las distintas escalas de cada variable.

■ Supervisados



- La métrica de distancia de Mahalanobis mide la similitud entre dos variables aleatorias multidimensionales. Veamos un ejemplo para clasificar un nuevo punto




A qué clase pertenece este punto

x	y	x	y	clase
1	5	4	1	1
5	1	5	1	1
5	2	5	2	1
6	7	6	7	2
7	6	7	6	2
7	7	7	7	2
1	8	1	8	3
2	7	2	7	3
2	8	2	8	3

■ Supervisados



- PRIMERO: Calcular la media de cada clase. Para ello debemos separar cada clase del conjunto de datos.




x	y	x	y	x	y	x	y
1	5	4	1	6	7	1	8
		5	1	7	6	2	7
		5	2	7	7	2	8
		μ_1	μ_2	μ_3			
		4.6	1.3	6.6	6.6		
						1.6	7.6

■ Supervisados



- **SEGUNDO:** Calcular la covarianza de cada clase. Recuerde aplicar la covarianza sobre los datos por clase y no al conjunto completo de datos.




x	y	x	y	x	y	x	y
1	5	4	1	6	7	1	8
		5	1	7	6	2	7
		5	2	7	7	2	8
COV_1		COV_2		COV_3			
0.33 0.16		0.33 -0.16		0.33 -0.16			
0.16 0.33		-0.16 0.33		-0.16 0.33			
0.33 -0.16							
-0.16 0.33							

■ Supervisados



- **TERCERO:** Por cada clase, determinar la distancia de Mahalanobis a cada una de las clases empleando la media y la covarianza de cada clase.



$$d = (x - \bar{x})^T \Sigma_1^{-1} (x - \bar{x})$$

1	5	4	1	6	7	1	8
5	1	5	1	7	6	2	7
5	2	7	7	2	8	2	8

\downarrow

-3.6	3.6	0.33	0.16	-3.6	3.6
0.16	0.33	-0.16	0.33	-5.6	-1.6
-5.6	-1.6	0.33	-0.16	-5.6	-1.6

\downarrow

-0.6	2.6	0.33	-0.16	-0.6	2.6
-0.16	0.33	-0.16	0.33	-0.16	0.33
-5.6	-1.6	0.33	-0.16	-5.6	-1.6

\downarrow

-0.6	2.6	0.33	-0.16	-0.6	2.6
-0.16	0.33	-0.16	0.33	-0.16	0.33
-5.6	-1.6	0.33	-0.16	-5.6	-1.6

$\rightarrow d = 161.33$


$\rightarrow d = 177.33$

$\rightarrow d = 37.33$

■ Supervisados



- **CUARTO:** Asignamos aquella clase que posea la menor distancia de Mahalanobis entre todas las clases o clusters



x	y	x	y	x	y	x	y
1	5	4	1	6	7	1	8
5	1	7	6	2	7	2	8
5	2	7	7	7	7	2	8


$$d = 161.33$$

$$d = 177.33$$


$$d = 37.33$$

La menor distancia se encuentra en la clase 3

■ Supervisados



- El clasificador lineal corresponde a una línea de separación entre dos clases. El problema consiste en **cómo encontrar los parámetros** que definen dicha línea.





■ Supervisados



■ *Linear Discriminant Analysis*

Es una técnica directa para encontrar los parámetros de la línea de decisión y al mismo tiempo permite determinar la clasificación de los puntos



■ Supervisados



■ Definiciones:

- En un problema de múltiples clases, la probabilidad a priori de la clase k es π_k donde
- π_k es usualmente estimado en forma empírica calculando las frecuencias del set de entrenamiento

$$\sum_{k=1}^K \pi_k = 1$$

$$\hat{\pi}_k = \frac{\# \text{ de ejemplos clase } k}{\# \text{ total de ejemplos}}$$

Objetivo: ¿Cual es la probabilidad de pertenecer a la clase k dado el conjunto de medidas x ?

En otras palabras, estimar la probabilidad a posteriori de la clase k



$$P(k | x)$$

Clase k -ésimo

Dato

■ Supervisados



■ Demostración:

- Empleando el teorema de Bayes obtenemos
- Dado que solo buscamos el máximo, descartamos el denominador. Luego buscamos el máximo de todas las clases (**recuerde que tenemos k clases**). Por lo tanto, el máximo corresponde a:

$$\begin{aligned}\hat{G}(\mathbf{x}) &= \arg \max_k \{P(k | \mathbf{x})\} \\ &= \arg \max_k \{f_k(\mathbf{x}) \cdot \pi_k\} \\ &= \arg \max_k \{\log(f_k(\mathbf{x}) \cdot \pi_k)\}\end{aligned}\quad (1)$$

función multivariada

$$P(k | \mathbf{x}) = \frac{f_k(\mathbf{x}) \cdot \pi_k}{\sum_{l=1}^K f_l(\mathbf{x}) \cdot \pi_l}$$

Gaussiana Multivariada

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (\mathbf{x} - \mu_k)^T \Sigma^{-1} (\mathbf{x} - \mu_k)}$$

covarianza interclases
media de la clase k

(2)

■ Supervisados



■ Demostración:

- Reemplazando (2) en (1) tenemos

$$\hat{G}(\mathbf{x}) = \arg \max_k \left\{ \log \left(\frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)} \cdot \pi_k \right) \right\}$$

- Evaluando el logaritmo y expandiendo términos

$$\begin{aligned} \hat{G}(\mathbf{x}) &= \arg \max_k \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \log \left(\frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \right) + \log(\pi_k) \right\} \\ &= \arg \max_k \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) - \log((2\pi)^{p/2} |\Sigma|^{1/2}) + \log(\pi_k) \right\} \\ &= \arg \max_k \left\{ \underbrace{\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k}_{-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}} - \log((2\pi)^{p/2} |\Sigma|^{1/2}) + \log(\pi_k) \right\} \end{aligned}$$

- Eliminando las constantes, el máximo corresponde a:

$$\hat{G}(\mathbf{x}) = \arg \max_k \left\{ \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \log(\pi_k) \right\}$$

■ Supervisados



■ Clasificación:


- La función lineal de decisión es

$$f_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \log(\pi_k)$$

Función LDA

- De esta forma para asignar una clase a un punto \mathbf{x} solo debemos calcular la función $f_k(\mathbf{x})$ que sea máxima.

$$f(\mathbf{x}) = \arg \max_k \{ \delta_k(\mathbf{x}) \}$$




- Recordemos que nuestro problema original consiste en buscar los parámetros de la línea de decisión.

DATOS

$$f(x_1, x_2) = w_0 + x_1 w_1 + x_2 w_2 = 0$$

INCÓGNITAS

■ Supervisados




■ Lo bueno


- LDA modela las diferencias entre las clases.
- Funciona bien si las distribuciones son normales (Gaussianas).
- Si existe una combinación lineal de las características, entonces LDA obtendrá un buen rendimiento.
- LDA es conocido por reducir la dimensionalidad. Así la proyección de múltiples dimensiones es reducida a un espacio de menor dimensión

■ Lo malo

- Si las distribuciones son significativamente no gaussianas, las proyecciones de LDA no podrán preservar la compleja estructura de los datos.




■ Supervisados



■ Ejemplo:

Supongamos que la empresa *McKoy* produce galletas de muy alta calidad, por ello tiene un muy exhaustivo control de calidad.

La empresa desea automatizar su sistema para que automáticamente determine el rango de aceptación según las características extraídas.



Curvatura	Diámetro	Control Calidad
4	3	Aceptado
5	3	Aceptado
5	4	Aceptado
5	5	Aceptado
6	5	Aceptado
2	4	Rechazado
3	4	Rechazado
3	5	Rechazado
4	6	Rechazado


■ Supervisados

- kNN
- Mahalanobis
- LDA**
- Árboles de decisión
- Bayesiano
- Redes Neuronales

■ Preliminar:

Separemos los datos en sus correspondientes clases y calculemos la media total

#	Curvatura	Diámetro	Clase
1	4	3	1
2	5	3	1
3	5	4	1
4	5	5	1
5	6	5	1
6	2	4	2
7	3	4	2
8	3	5	2
9	4	6	2



■ Supervisados

- kNN
- Mahalanobis
- LDA
- Árboles de decisión
- Bayesiano
- Redes Neuronales

■ PRIMERO:

Calcule la probabilidad de cada clase según el número de elementos por clase

#	Curvatura	Diámetro	Clase
1	4	3	1
2	5	3	1
3	5	4	1
4	5	5	1
5	6	5	1
6	2	4	2
7	3	4	2
8	3	5	2
9	4	6	2

$$\hat{\pi}_k = \frac{\# \text{ de ejemplos clase } k}{\# \text{ total de ejemplos}}$$

Probabilidad a Priori

$$\pi_1 = \frac{5}{9}, \quad \pi_2 = \frac{4}{9}$$

Media

4.11 4.33

■ Supervisados


- kNN
- Mahalanobis
- LDA
- Árboles de decisión
- Bayesiano
- Redes Neuronales

■ SEGUNDO:

Calcule la covarianza y la media de cada clase por separado

	DATOS EN CLASES	MEDIAS	COVARIANZAS																
X ₁	<table border="1"><tr><td>4</td><td>3</td></tr><tr><td>5</td><td>3</td></tr><tr><td>5</td><td>4</td></tr><tr><td>5</td><td>5</td></tr><tr><td>6</td><td>5</td></tr></table>	4	3	5	3	5	4	5	5	6	5	\bar{x}_1 <table border="1"><tr><td>5.0</td><td>4.0</td></tr></table>	5.0	4.0	$Cov(X_1)$ <table border="1"><tr><td>0.500</td><td>0.500</td></tr><tr><td>0.500</td><td>1.000</td></tr></table>	0.500	0.500	0.500	1.000
4	3																		
5	3																		
5	4																		
5	5																		
6	5																		
5.0	4.0																		
0.500	0.500																		
0.500	1.000																		
X ₂	<table border="1"><tr><td>2</td><td>4</td></tr><tr><td>3</td><td>4</td></tr><tr><td>3</td><td>5</td></tr><tr><td>4</td><td>6</td></tr></table>	2	4	3	4	3	5	4	6	\bar{x}_2 <table border="1"><tr><td>3.0</td><td>4.8</td></tr></table>	3.0	4.8	$Cov(X_2)$ <table border="1"><tr><td>0.667</td><td>0.667</td></tr><tr><td>0.668</td><td>0.917</td></tr></table>	0.667	0.667	0.668	0.917		
2	4																		
3	4																		
3	5																		
4	6																		
3.0	4.8																		
0.667	0.667																		
0.668	0.917																		
		Recuerde:	$\text{cov}(x, y) = \frac{1}{(n-1)} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$																

■ Supervisados




■ TERCERO:

Calcule la matriz de covarianza entre clases ponderando la probabilidad de cada clase.

Cov(X ₁)	
0.500	0.500
0.500	1.000
Cov(X ₂)	
0.667	0.667
0.668	0.917

$$\Sigma = \pi_1 \cdot \text{cov}(X_1) + \pi_2 \cdot \text{cov}(X_2)$$



A large grey arrow points from the two covariance matrices on the left to the resulting weighted covariance matrix Σ on the right.

Σ	
0.5741	0.5741
0.5741	0.9630

En este ejemplo tenemos dos clases, por ello la suma solo utiliza la covarianza entre dos grupos

Esta matriz será luego empleada para determinar la clasificación lineal



A large grey arrow points from the weighted covariance matrix Σ on the left down to the inverse covariance matrix Σ^{-1} on the right.

Σ^{-1}	
4.3134	-2.5714
-2.5714	2.5714

■ Supervisados

- kNN
- Mahalanobis
- LDA**
- Árboles de decisión
- Bayesiano
- Redes Neuronales

■ CUARTO:

A cada punto original, calculamos la función de decisión lineal.

$$f_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \log(\pi_k)$$

#	Curvatura	Diámetro	f_1	f_2	$\text{Max}(f_1, f_2)$
1	4	3	13.76	3.82	1
2	5	3			
3	5	4			
4	5	5			
5	6	5			
6	2	4			
7	3	4			
8	3	5			
9	4	6			

$$f_1(\mathbf{x}) = [4 \ 3] \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} - \frac{1}{2} [5 \ 4] \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} + \log\left(\frac{5}{9}\right) = 13.76$$

$$f_2(\mathbf{x}) = [4 \ 3] \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \begin{bmatrix} 3 \\ 4.8 \end{bmatrix} - \frac{1}{2} [3 \ 4.8] \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \begin{bmatrix} 3 \\ 4.8 \end{bmatrix} + \log\left(\frac{4}{9}\right) = 3.82$$

■ Supervisados



■ CUARTO:

A cada punto original, calculamos la función de decisión lineal.

#	Curvatura	Diámetro	f_1	f_2	Clasificación	Clase original
1	4	3	13.76	3.82	1	1
2	5	3	25.04	4.54	1	1
3	5	4	22.47	9.04	1	1
4	5	5	19.90	13.54	1	1
5	6	5	31.18	14.27	1	1
6	2	4	-11.37	6.86	2	2
7	3	4	-0.09	7.59	2	2
8	3	5	-2.66	12.09	2	2
9	4	6	6.05	17.31	2	2

■ Supervisados



■ Parámetros de la recta:

- Si queremos determinar los parámetros de la recta, notemos que se debe cumplir la siguiente condición. Es decir, buscamos la línea de decisión entre la clase k y la clase p

$$f_k(\mathbf{x}) = f_p(\mathbf{x})$$

$$f_k(\mathbf{x}) - f_p(\mathbf{x}) = 0$$

$$\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \log(\pi_k) - \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_p + \frac{1}{2} \boldsymbol{\mu}_p^T \Sigma^{-1} \boldsymbol{\mu}_p - \log(\pi_p) = 0$$

- Agrupando términos obtenemos

$$\mathbf{x}^T \Sigma^{-1} (\boldsymbol{\mu}_k - \boldsymbol{\mu}_p) - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \frac{1}{2} \boldsymbol{\mu}_p^T \Sigma^{-1} \boldsymbol{\mu}_p + \log\left(\frac{\pi_k}{\pi_p}\right) = 0$$

■ Supervisados



■ Parámetros de la recta:

- Finalmente la **línea de decisión** entre la clase k y la clase p es:

$$\mathbf{x}^T \Sigma^{-1} (\boldsymbol{\mu}_k - \boldsymbol{\mu}_p) - \frac{1}{2} (\boldsymbol{\mu}_k + \boldsymbol{\mu}_p)^T \Sigma^{-1} (\boldsymbol{\mu}_k - \boldsymbol{\mu}_p) + \log\left(\frac{\pi_k}{\pi_p}\right) = 0$$


- Observe con detalle la relación entre estas dos ecuaciones
¿Qué tienen en común?

Ecuación de la recta

$$w_0 + x_1 w_1 + x_2 w_2 \Rightarrow w_0 + \mathbf{x}^T \cdot \mathbf{w} = 0$$

$$\begin{aligned} & \downarrow \qquad \qquad \qquad \downarrow \\ \mathbf{w} &= -\Sigma^{-1} (\boldsymbol{\mu}_k - \boldsymbol{\mu}_p) \\ & \downarrow \\ w_0 &= -\frac{1}{2} (\boldsymbol{\mu}_k + \boldsymbol{\mu}_p)^T \Sigma^{-1} (\boldsymbol{\mu}_k - \boldsymbol{\mu}_p) + \log\left(\frac{\pi_k}{\pi_p}\right) \end{aligned}$$

■ Supervisados



- **Gráfico:** Empleando las ecuaciones y valores previos, determinamos los parámetros de la recta

$$\mathbf{w} = \Sigma^{-1}(\mu_k - \mu_p) \quad w_0 = -\frac{1}{2}(\mu_k - \mu_p)^T \Sigma^{-1}(\mu_k - \mu_p) + \log\left(\frac{\pi_k}{\pi_p}\right)$$

$$\mathbf{w} = \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \left(\begin{bmatrix} 5 & 4 \end{bmatrix} - \begin{bmatrix} 3 & 4.8 \end{bmatrix} \right) = \begin{bmatrix} 10.55 \\ -7.07 \end{bmatrix}$$

$$w_0 = -\frac{1}{2} \left(\begin{bmatrix} 5 \\ 4 \end{bmatrix} - \begin{bmatrix} 3 \\ 4.8 \end{bmatrix} \right)^T \begin{bmatrix} 4.313 & -2.571 \\ -2.571 & 2.571 \end{bmatrix} \left(\begin{bmatrix} 5 & 4 \end{bmatrix} - \begin{bmatrix} 3 & 4.8 \end{bmatrix} \right) + \log\left(\frac{5}{4}\right)$$

$$w_0 = -11.06$$

- Reemplazando los valores (forma general)

$$f(x_1, x_2) = w_0 + x_1 w_1 + x_2 w_2 = 0$$

$$f(x_1, x_2) = -11.06 + 10.55x_1 - 7.07x_2 = 0$$

■ Supervisados




■ Gráfico

Empleando las ecuaciones y valores previos, determinamos los parámetros de la recta

- Ecuación de la recta general

$$f(x_1, x_2) = -11.06 + 10.55x_1 - 7.07x_2 = 0$$



$$x_2 = \frac{10.55}{7.07}x_1 - \frac{11.06}{7.07}$$


■ Supervisados

- kNN
- Mahalanobis
- LDA**
- Árboles de decisión
- Bayesiano
- Redes Neuronales

■ Clasificación

Si tenemos un punto que deseamos evaluar si clase, simplemente verificamos a qué lado de la recta se encuentra. Veamos un ejemplo

- Forma directa $x_2 = -\frac{10.55}{7.07}x_1 + \frac{11.06}{7.07}$



- Evaluación en el punto $(7, 6)$

$$x_2 = -\frac{10.55}{7.07} \times 7 + \frac{11.06}{7.07} = 8.88$$

$$8.88 > 6$$

entonces $(7, 6) \in$

